

基於理由感知門控與稀疏評論面向知識圖譜之產品推薦

學生：預覽用

指導教授：預覽用 maniew 博士

國立陽明交通大學資訊學院碩士在職專班

摘 要

知識圖譜感知推薦在稠密且品質良好的圖譜上通常能提升準確度；然而，在評論衍生、冷啟動或隱私受限等情境中，圖譜往往稀疏或品質不穩，相關研究仍相對不足。本文以商品評論衍生的稀疏圖譜為例，過濾後每件商品平均僅有 2.4 條面向邊；實驗顯示，代表性的知識圖譜感知方法皆不如完全不使用圖譜的純協同過濾模型。主要原因在於，這些方法將圖譜訊號硬性嵌入評分流程，缺乏在圖譜不可靠時自動降低其影響的機制，使雜訊干擾協同訊號的學習。

本文提出 RA-GARK，將圖譜視為一條可調控的側通道，而非評分流程中必須使用的組件，並透過三個步驟實現。其一，將每件商品的圖譜內容整理為少數代表性面向，並以帶有語意的向量初始化，避免完全隨機的起點。其二，模型會依使用者與商品，自動選取最相關的面向。其三，由融合閘決定是否啟用此側通道：訓練初期幾乎關閉，使模型從純協同過濾出發；只有當側通道確實有幫助時才逐步打開，並在其無用時平順退回。在不更動圖譜本身的前提下，RA-GARK 將圖譜的貢獻由負面轉為正面。

本研究指出，知識圖譜感知方法在稀疏圖譜上表現不佳，關鍵並非圖譜完全沒有資訊，而是既有架構缺乏選擇性使用圖譜的能力。同一個圖譜在強制融合下可能成為負擔，但當模型能自行決定是否採用時，便可轉為助益。這種優雅退化的設計並不限於知識圖譜；對於任何需要結合可靠主訊號與品質不穩定輔助訊號的情境，例如冷啟動、多模態或跨領域推薦，同樣具有應用價值。

關鍵字：知識圖譜推薦；可退化機制；融合閘；稀疏知識圖譜；協同過濾

Contents

1	緒論	1
1.1	研究背景	1
1.2	稀疏 KG 下的經驗異常現象	1
1.3	稀疏 KG 作為現實世界的常態	2
1.4	研究問題	2
1.5	論文組織	3
1.6	研究貢獻	3
2	相關研究	4
2.1	基礎與 KG-Aware 基線	4
2.1.1	對比式知識圖譜方法	5
2.1.2	合理化感知推薦：KGRec	5
2.2	合理化典範：共同前提與分歧的可信度假設	5
2.3	閘控機制與融合閘缺口	7
2.3.1	KG-Aware 推薦中沒有融合閘	7
2.4	注意力正規化	8
2.5	總結與 RA-GARK 的定位	8
3	提出方法	10
3.1	設計原則與問題設定	10
3.1.1	架構概覽	11
3.1.2	符號	12
3.1.3	問題定式	12
3.2	區域視角：LightGCN	13
3.2.1	動機	13

3.2.2	圖的建構	13
3.2.3	傳播	14
3.2.4	層平均與輸出	14
3.3	全域視角：KG-SVD 初始化	14
3.3.1	面向槽作為物品側 KG 表示	15
3.3.2	共現矩陣	15
3.3.3	IDF 加權	16
3.3.4	截斷 SVD	16
3.3.5	重塑為槽位與量值縮放	16
3.3.6	演算法	17
3.3.7	初始化效益	17
3.4	全域視角：Softmax 合理化遮罩	17
3.4.1	動機	18
3.4.2	使用者條件之注意力 logits	18
3.4.3	Softmax 歸一化	18
3.4.4	加權聚合	19
3.4.5	Softmax 與 Sigmoid	19
3.5	區域偏置融合與對比正則化	19
3.5.1	雙側獨立閘	20
3.5.2	閘的結構	20
3.5.3	區域偏置初始化	21
3.5.4	優雅退化	21
3.5.5	融合偏置量值選擇	21
3.5.6	跨視角對比正則化	22
3.6	訓練與計算複雜度	23
3.6.1	總目標	23
3.6.2	最佳化	23
3.6.3	推論	23
3.6.4	計算複雜度	23
4	實驗與結果	25
4.1	資料集與 KG 建構	25
4.1.1	資料集	25

4.1.2	知識圖譜建構	26
4.2	實驗設定	26
4.2.1	Baseline	26
4.2.2	評估協議	27
4.2.3	超參數設定	27
4.2.4	硬體與軟體	28
4.3	主要結果	28
4.4	消融研究	30
4.5	敏感性分析	31
4.5.1	Softmax 溫度 τ	32
4.5.2	面向槽數 A	32
4.5.3	融合閘偏置 b	33
4.5.4	對比權重 λ_{CL}	33
4.5.5	結果穩定性	33
4.6	個案研究與計算成本	33
4.6.1	計算成本	35
5	結論與未來工作	36
5.1	結論	36
5.2	方法論啟示：注意力歸一化	37
5.3	限制	38
5.4	未來工作	38

1 緒論

1.1 研究背景

圖神經網路 (GNN) 已成為協同過濾的主流架構選擇。其中，LightGCN [1] 證明了只要移除 GCN 中的非線性激活與特徵變換、僅保留線性鄰居聚合，便足以在標準推薦基準上超越如 NGCF [2] 等更深層的方法。LightGCN 的簡潔與穩定使其成為一個強大且參數高效的骨幹，而後續方法如 SGL [3] 則在其上疊加額外的自監督目標。

另一條互補的研究路線，知識圖譜感知推薦 (KG-aware recommendation)，以知識圖譜 (KG) 所編碼的物品端語意來擴充協同訊號。具代表性的方法包括：KGAT [4]，在統一的使用者—物品—實體圖上傳播訊息；KGCL [5] 與 MCCLK [6]，透過對比學習對齊 KG 視角與協同視角；以及 KGRec [7]，引入邊層級的合理化 (rationalization) 機制以辨識哪些 KG 三元組對推薦負責。當 KG 稠密且品質良好時，這類方法皆能穩定地超越純協同基線。

1.2 稀疏 KG 下的經驗異常現象

本研究的起點是一個促使整篇論文展開的經驗觀察。在本研究所使用的、由評論衍生而來的 KG 資料集 (Amazon Books 子集，經篩選後每件物品平均僅有 2.4 條 aspect 邊) 上，前述四種具代表性的 KG-aware 方法全部都被完全不參考 KG 的純 LightGCN 所超越。表 1 摘要呈現這些 KG-aware 方法與無 KG 基線之間的 NDCG@20 差距。

Table 1: KG-aware 方法與純 LightGCN 之 NDCG@20 比較。

方法	NDCG@20
MCCLK [6]	0.1067
KGCL [5]	0.1073
KGAT [4]	0.1079
KGRec [7]	0.1095
純 LightGCN [1] (未使用 KG)	0.1179

我們並非主張上述四種基線本身有缺陷，它們在其原始論文所報告的稠密 KG 資料集上表現皆十分強勁。此觀察反映的，是深度 KG-CF 耦合所共同具有的一種失效模式：當 KG 過於稀疏或雜訊過多以致無法提供可靠的物品語意時，將其直接融入評分路徑會使 KG 雜訊污染本可產生純淨協同訊號的梯度流。

1.3 稀疏 KG 作為現實世界的常態

一個自然的反駁是：將此一經驗異常視為資料集的特殊性，並透過更精緻地策劃稠密 KG 或進行 KG 補全 (completion) 來填補缺失邊即可。然而，我們主張，稀疏 KG 才是實務推薦系統中更常見的情境，因此「在 KG 訊號不可靠時依然穩健」這項性質本身就值得專門研究，而非以工程繞道方式迴避。

實務上有三個常見的稀疏來源。其一，評論衍生型 KG (如本研究所使用者) 其密度繼承自使用者實際提及的主題；覆蓋本質上即不均匀。其二，冷啟動與新興領域 (新品類、低資源語言、利基垂直市場) 通常無法取得如 Freebase 或 Wikidata 等等級的人工策劃資源，KG 必須從有限訊號中自舉而來。其三，隱私受限領域，如醫療或金融推薦，刻意限制可暴露給模型的關聯訊號。在以上三種情境中，激進的 KG 補全本身亦非易事：補全會引入新的雜訊，且通常需要足夠的種子訊號才能訓練，而這恰恰是稀疏情境中所欠缺的。

由此推論，推薦器在 KG 不可靠時的穩健性，至少和它在 KG 稠密時的峰值效能同等重要。本論文以此穩健性作為主要設計目標。

1.4 研究問題

上述經驗異常與稀疏 KG 情境的實務重要性，引出兩個研究問題：

- (RQ1, 診斷) 為何既有 KG-aware 方法在稀疏 KG 下不及純 LightGCN? 它們所共同具備的結構性失效模式為何?
- (RQ2, 處方) 何種設計原則能讓模型在 KG 訊號有效時加以利用，而在訊號無效時避免 KG 雜訊污染協同過濾?

RQ1 於第 2 與第 4 章中加以回答：我們將其共同失效模式界定為在稀疏且不可靠 KG 下的必要式融合。RQ2 則於第 3 章提出，並於第 4 章實證驗證：可閘控的旁路通道設計能在 KG 訊號有用時加以利用，無用時退回純 LightGCN。

本論文的主張是：KG 不應如 KGAT 式深度融合那般，成為評分管線中的必要組件，而應作為一條可依其訊號是否有用而被明確開控的旁路通道。第 3 章將進一步給出實際的架構與最佳化設定。

1.5 論文組織

本論文後續組織如下。第 2 章從四個面向回顧相關文獻：圖協同過濾、KG-aware 推薦、深度學習中的開控機制，以及注意力正規化。第 3 章完整呈現 RA-GARK 架構：陳述設計原則、固定符號與問題形式化，並依序展開各模組，LightGCN 區域視角、含兩項創新（KG-SVD 初始化與 softmax aspect-saliency 注意力）的全域 KG 視角、具局部偏置的融合開、跨視角對比正則化，並附訓練流程與計算複雜度。第 4 章報告實驗結果、消融研究、敏感性分析、結果穩定性與個案研究。第 5 章討論關於注意力正規化的方法論啟示，承認單一資料集驗證的限制，並提出未來工作方向。

1.6 研究貢獻

本論文之主要貢獻如下：

1. **經驗性研究**：證明在稀疏評論型 KG 下，四種具代表性的 KG-aware 方法（KGAT、KGCL、MCCLK、KGRec）皆一致地被純 LightGCN 超越。我們將此歸因於這些方法缺乏一個能於 KG 不可靠時將其脫接的架構機制。
2. **RA-GARK，一個雙視角架構**：以旁路通道而非深度融合的方式整合協同訊號與 KG 衍生訊號。第 3 章將完整展開其架構與訓練程序。
3. **經驗驗證**：在稀疏評論型 KG 基準上，RA-GARK 超越了最強的 KG-aware 基線與純 LightGCN。後者的差距顯示，所提出的設計原則能在 KG 本身不變的情況下，把 KG 訊號的貢獻由淨負（四種基線之情況）翻轉為淨正。
4. **關於合理化感知設計中注意力正規化的方法論觀察**：在我們的情境中，softmax 與 sigmoid 之間的差異，暗示正規化的選擇應與合理化的語意假設相一致。我們將此視為單一資料集上的假設而非通用主張，留待後續多資料集複製驗證（第 5 章）。

2 相關研究

本章從五個面向回顧先前研究，這些面向共同促成 RA-GARK 的設計。第 2.1 節介紹協同與 KG-aware 推薦基礎，包含 LightGCN、KGAT、對比式 KG 方法與 KGRec。第 2.2 節以「KG 可信度」為視角，對比我們與 KGRec 的合理化典範。第 2.3 節回顧閘控機制並指出 KG-aware 推薦中缺少融合閘設計。第 2.4 節討論注意力正規化，第 2.5 節總結 RA-GARK 相對於上述工作的定位。

2.1 基礎與 KG-Aware 基線

LightGCN [1] 是本研究區域視角的直接前身。建立於「NGCF [2] 中的非線性特徵變換對推薦準確率貢獻甚微」這項觀察上，LightGCN 將圖卷積網路精簡至最小骨幹：反覆在使用者—物品二部圖上進行正規化鄰居聚合，再將傳播後的嵌入做簡單的層平均。此一簡化在標準推薦基準上一致地優於 NGCF，且訓練更快、更穩定。其後諸多自監督方法，如 SGL [3] 與 DCCF [8]，皆在 LightGCN 式骨幹之上疊加額外的對比目標。

在 RA-GARK 中，我們原封不動採用 LightGCN ($K = 2$) 作為區域視角：此分支內不施加任何 KG 相關運算。動機有二。其一，在我們的稀疏評論型 KG 上，純 LightGCN 已超越所有我們所評估的 KG-aware 基線。任何偏離此強預設的設計，皆須可被證實能改善而非劣化結果，這是本論文反覆訴諸的硬性設計約束。其二，將 KG 訊號隔離至獨立的全域視角（第 3 章），可避免 KG 雜訊污染協同表示的梯度流。

KGAT [4] 代表 KG-aware 推薦中的典範深度融合做法。KGAT 將使用者—物品互動圖與知識圖譜合併為一個協同知識圖（Collaborative Knowledge Graph, CKG），並以雙交互聚合器於此統一結構上傳播訊息。KG 實體嵌入因而直接參與使用者與物品表示的形成。當 KG 稠密且品質良好時，此設計相對於 CF 基線可取得顯著提升。

此處的隱含假設是 KG 可被信任，能在傳播路徑所及之處皆注入有用訊號。在我們的稀疏情境下此假設崩解：KGAT 低於純 LightGCN。其後續工作 [5, 6, 7] 沿用 KGAT 式聚合器，因此也繼承相同的脆弱性。RA-GARK 反轉此一設計選擇：我們完全不將 KG 與使用者—物品圖合併，而是將 KG 訊號導入一條專用旁路通道，當 KG 被證實不可靠時模型可衰減甚至全然脫接之。

2.1.1 對比式知識圖譜方法

KGCL [5] 對 KG 引入關係層級的結構擾動，並以 InfoNCE [9] 對比目標對齊擾動版本與原始版本。直覺是：具資訊量的 KG 結構應對隨機擾動具有不變性，而雜訊邊則不應。KGCL 在稠密 KG 情境下顯著優於 KGAT。然而在我們的稀疏情境中，擾動後的 KG 保留的邊過少，對比目標無法提供可靠監督。

MCCLK [6] 將對比對齊擴展至三個視角（協同、語意與結構）並對三者兩兩施加對比損失。雖然此多視角設計在稠密 KG 基準上取得 SOTA，但同樣繼承稠密 KG 的假設：在稀疏 KG 下，三個視角中有兩個（語意與結構）訊號不足，對比對齊淪為由雜訊主導而非由結構主導的正則化。

RA-GARK 同樣納入跨視角對比學習，但其角色刻意受限。我們的對比損失（ $\mathcal{L}_{aCL}$ 與 $\mathcal{L}_{uCL}$ ，第 3.5.6 節）僅作為小權重（ $\lambda = 0.005$ ）的輔助幾何正則化項，並關鍵地在 KG 側施加 stop-gradient，使對比梯度從不反向傳遞至 SVD 初始化的 aspect 嵌入。相較於 KGCL/MCCLK，此處的對比學習是表層的對齊層，而非主要的融合機制；協同與 KG 訊號的實際整合，是由一個明確的閘所執掌（第 2.3 節）。

2.1.2 合理化感知推薦：KGRec

KGRec [7] 是與本工作最直接相關的研究。它是第一個將合理化選擇明確化的 KG-aware 推薦器：KGRec 不將每條 KG 三元組視為同等具資訊量，而是對每條 KG 邊計算一個基於注意力的重要性分數，並以 Bernoulli dropout 隨機移除高注意力邊，迫使模型不依賴少數主導邊；其穩健性接著由原始圖與被丟邊版本之間的對比目標來強化。整套合理化機制建立於 KGAT 式聚合器之上，因此合理化作用於使用者—物品—實體統一圖的訊息傳遞路徑之內。在我們的稀疏基準上，KGRec 是四個 KG-aware 基線中最強者，但仍低於純 LightGCN。

RA-GARK 在精神上採納合理化感知典範，但在結構上多處與 KGRec 有別，下節詳述之。

2.2 合理化典範：共同前提與分歧的可信度假設

KGRec [7] 與 RA-GARK 都認同「並非所有 KG 邊都對推薦同等貢獻、需要明確的選擇機制」這項觀察。然而二者對 KG 整體可信度所作的假設有所不同，此一假設並蔓延至各自分歧的設計選擇。

KGRec 的隱含假設是：具資訊量的邊存在於 KG 中，因此合理化任務簡化為將其找出；隨機 dropout 配合對比學習已足以辨識並放大有用子集。KG 整體作為證據體系被假定為可靠的，僅是個別邊的權重需被調整。

RA-GARK 的前提較弱。我們不假設 KG 整體是可靠的。aspect-saliency softmax (第 3.4 節) 在 KG 具資訊量時選取合理化依據，但具局部偏置的融合閘 (第 3.5 節) 可在閘的梯度顯示無益時，另外地脫接整條 KG 通道。此可信度差異展現於四項設計分歧上：

- **合理化粒度**：KGRec 在邊 (KG 三元組) 層級進行選擇。RA-GARK 將每件物品的 KG 語意聚合為 $A = 4$ 個潛在面向槽 (槽位內容由 IDF 加權商品一面向共現矩陣之截斷 SVD 投影得到) 並在槽位層級進行選擇。此槽位數為模型設計參數，與每件物品所擁有的原始面向標籤數無關；粒度雖較邊層級選擇為粗，但直接產生可解讀的每物品 aspect 偏好。
- **選擇機制**：KGRec 採用離散 Bernoulli dropout 配合對比學習。RA-GARK 採用可微分的 softmax 注意力，能端到端訓練，並將推論期的權重作為可解釋性產物外露。
- **作用位置**：KGRec 在 KGAT 訊息傳遞路徑之內施加合理化；合理化與聚合糾纏在一起。RA-GARK 將合理化置於與 LightGCN 區域視角分離的旁路通道，僅於後期由閘將兩者結合。
- **對 KG 可信度的處理**：KGRec 沒有任何架構機制可脫接 KG。RA-GARK 的偏置初始化融合閘正提供此一機制：訓練起始時 $\alpha^{(0)} \approx 0.993$ ，模型實質上即為純 LightGCN；唯當學習顯示 KG 通道能降低損失時，閘才會被打開。

表 2 將上述四項軸線並列對照。

Table 2: KGRec 與 RA-GARK 之合理化典範比較。

軸線	KGRec	RA-GARK
合理化粒度	KG 三元組 (邊)	A 個潛在面向槽
選擇機制	Bernoulli dropout + CL	Softmax 注意力
作用位置	KGAT 訊息傳遞之內	旁路通道，後期融合
KG 可信度處理	無脫接機制	偏置初始化融合閘

因此我們不將 RA-GARK 定位為對 KGRec 的工程性改良，而是基於對 KG 可信度不同前提之另一種設計。此一區別在經驗上是否重要，則於第 4 章中作答。

2.3 開控機制與融合開缺口

RA-GARK 的融合開有兩個 KG-aware 推薦之外的近親，二者皆啟發本研究設計。

Highway Networks [10] 引入可學習的開 $T(\mathbf{x})$ ，於變換訊號 $H(\mathbf{x})$ 與恆等跳接間進行插值： $\mathbf{y} = T(\mathbf{x}) \cdot H(\mathbf{x}) + (1 - T(\mathbf{x})) \cdot \mathbf{x}$ 。其關鍵設計選擇為對 T 的負偏置初始化：訓練之初 $T \approx 0$ ，網路表現為恆等映射。其後訓練僅在變換有益處之處才打開閘門。此設計原本是為了應對極深網路訓練的困難，但「將開偏置至已知安全的預設，僅在學習認為合理時才覆寫」此結構性樣式，遠遠超出深度的脈絡而具有普適性。RA-GARK 將此樣式由網路內跳接移植至雙視角融合：融合開上的 +5 偏置扮演與 Highway 之負偏置相同的角色，對 KG 通道提供優雅退化保證。

專家混合 (Mixture-of-Experts) 開控，以多任務推薦中的 MMoE [11] 與 PLE [12] 為代表，以開控網路對多個專家塔加權。雖然概念上類似多管線選擇，但兩項重要性質與 RA-GARK 不同。其一，MMoE/PLE 中的專家為同質候選者（皆為相同架構、僅以任務特定目標訓練的實例）因此並無「某專家本質上比另一者較不可靠」的概念。其二，這些架構中的開採對稱初始化（訓練起始不偏向任何特定專家），適用於對稱專家情境，但不適用於我們不對稱的情境，在我們的設定中，一條通道（LightGCN）已知是強預設，另一條（KG）已知有時並不具資訊量。

另有一條工作線是對比式雙視角推薦器，例如 SGL [3] 與 DCCF [8]，這類方法以擾動單一圖（邊 dropout、節點 dropout、隨機漫步）來建構多個視角。此類方法中兩個視角位於相同訊號空間，對比對齊已足以整合二者。RA-GARK 的兩個視角則在結構上異質：區域視角為使用者—物品二部圖，全域視角為物品—aspect 的 KG。僅靠對比學習進行隱式對齊，無法調整兩個異質訊號空間的相對權重；明確的開是必要的。

2.3.1 KG-Aware 推薦中沒有融合開

儘管開控在深度學習中已相當成熟，我們所調研的 KG-aware 推薦文獻中，未見任何方法將融合開作為協同訊號與 KG 訊號之間的整合機制。表 3 摘要了四個被基準測試的基線與另外三個知名 KG-aware 方法（CKAN [13]、MKR [14]、KGIN [15]）所採用的整合機制。在這個集合中，KG 訊號是透過直接實體傳播、對比對齊、邊層級 dropout、注意力、跨特徵單元或意圖解耦模組來整合。沒有任何機制允許 KG 通道在訊號不可靠時被結構性地脫接。

Table 3: 代表性推薦方法中的 KG 整合機制。

方法	KG 整合機制	可脫接？
KGAT [4]	直接實體訊息傳播	否
KGCL [5]	擾動 KG 對比學習	否
MCCLK [6]	多視角對比對齊	否
KGRec [7]	邊層級 dropout + KGAT 聚合器	否
CKAN [13]	協同一知識注意力	否
MKR [14]	跨特徵轉移單元	否
KGIN [15]	KG 上的意圖解耦	否
RA-GARK (本研究)	偏置初始化的融合閘	是

我們刻意作出一個範圍狹義的主張。我們不主張 RA-GARK 是 KG-aware 推薦中首個使用「任何閘」的方法，因 KG-aware 文獻浩繁，無法窮舉列舉。可辯護的主張為：在我們所檢視的方法中，沒有任何一個以偏置初始化的融合閘於稀疏或不可靠 KG 下提供架構優雅退化。我們在第 4 章的消融顯示，此一初始化在本設定中確實是不可忽略的設計選擇。

2.4 注意力正規化

一個橫跨多領域的相關問題是：在選擇合理化依據時，應對注意力權重套用 sigmoid 或 softmax？文獻並未匯聚於單一答案。DIN [16] 對使用者行為歷史套用 sigmoid 注意力，所基於的假設是每筆歷史行為與候選物品的相關性彼此獨立。NAIS [17] 對歷史互動套用 softmax 注意力以衡量物品相似度，AFM [18] 則對特徵交互套用 softmax。各工作中的選擇皆以其注意力所依附的語意假設為依據。

我們在第 4 章報告一項單一資料集的觀察：對於我們的 aspect-saliency 合理化，將 softmax 替換為 sigmoid 會產生我們所量測到最大的單一元件變化。我們將其解讀為支持「正規化應與合理化的語意假設相符」此一設計啟發，但明確將此觀察定位為待多資料集複製驗證的假設（第 5 章）。

2.5 總結與 RA-GARK 的定位

表 4 從四個設計面向匯整比較。在本章所討論的方法中，RA-GARK 是唯一同時將純 LightGCN 區域聚合器與閘控後期融合的 KG 訊號相結合者，也是唯一將合理化作用於物品—aspect 粒度而非 KG 邊粒度者。

Table 4: KG-aware 推薦方法之設計比較。

方法	區域聚合器	KG 整合	合理化
KGAT	雙交互	直接傳播	無
KGCL	KGAT 式	傳播 + CL	無
MCCLK	多視角	多視角 CL	無
KGRec	KGAT 式	傳播 + 邊 dropout	邊 Bernoulli
RA-GARK	純 LightGCN	開控後期融合	Aspect softmax

我們並不將 RA-GARK 定位為相對於四個基線的嚴格改進。RA-GARK 在設計空間中佔據一個不同的位置，其特徵在於將 KG 視為可被明確開控的旁路通道，而非必要的管線組件。此選擇在我們的稀疏 KG 情境中產出強勁結果，而基於開控的優雅退化性質，在 KG 品質不均或模型部署於 KG 密度差異各異的多個領域時，或許亦能派上用場。然而，當 KG 稠密且品質一致地可靠時，KGAT 或 KGRec 這類深度融合方法可能仍較佳，因為後期融合的設計犧牲了深度融合架構所具有的部分表徵表達力。

3 提出方法

本章呈現 RA-GARK 之完整方法。第 3.1 節說明核心設計原則、架構資料流、符號與問題定式。第 3.2 至 3.5.6 節依模組於前向傳遞中的順序逐一詳述各模組。第 3.6 節說明訓練程序與計算複雜度。

3.1 設計原則與問題設定

第 1 章的經驗觀察是：在本研究稀疏的評論衍生知識圖譜（KG）上，四種具代表性的 KG-aware 方法（KGAT、KGCL、MCCLK、KGRec）皆被純 LightGCN 一致地超越。

這些基線所共有的結構性失因在於：KG 被當作評分管線的必要組件串接進來，KG 實體嵌入直接參與訊息傳遞，且無任何架構性的開關能在 KG 被證實不可靠時將其脫接。因此 KG 雜訊與協同表示共享同一條梯度流。

RA-GARK 圍繞一個直接面對此失效模式的核心設計原則：

KG 不應為評分管線的必要組件，而應為一條旁路通道；其對最終分數的貢獻由一個學習得到的閘決定，閘在初始化時偏置至一個安全預設（純協同過濾），僅在訓練訊號顯示 KG 通道能降低損失時才被打開。

此原則衍生三項架構層級的後果，並共同定義 RA-GARK：

1. **雙條平行視角**：區域視角透過在使用者—物品互動圖上運行 LightGCN 產生純協同表示 $(u_{\text{loc}}, i_{\text{loc}})$ ，過程中完全不涉及 KG。全域視角則由獨立的使用者嵌入表與物品端的潛在面向槽產生 KG 表示 $(u_{\text{glo}}, i_{\text{glo}})$ ，過程中亦不涉及協同訊號。直至融合階段之前，兩條視角在結構上完全分離。
2. **後期、閘控的融合**：兩條視角僅在最終評分階段被融合閘合併；該閘針對每組（使用者，物品）配對輸出一個混合權重 $\alpha \in (0, 1)$ 。閘以偏置初始化使 $\alpha^{(0)} \approx 0.993$ ，模型訓練起點實質等同於純 LightGCN，KG 通道僅在梯度將 α 推低時逐步開啟。

3. **合理化感知的物品端聚合**：每件物品的 KG 語意儲存於 $A = 4$ 個潛在面向槽中，槽位內容由 IDF 加權商品一面向矩陣之截斷 SVD 產生；softmax aspect-saliency 注意力依（使用者, 物品）配對選取代表該物品的潛在槽。

每項後果均於下方第 3.2 至 3.5.6 節中數學化。本章其餘部分先固定符號與問題陳述（第 3.1.2 至 3.1.3 節），再依各模組於前向傳遞中之參與順序逐一展開。

3.1.1 架構概覽

圖 1 勾勒了推論時的資料流。模型被布置為對應區域與全域視角的兩條水平泳道，於右側由融合階段匯合。區域視角（上方泳道）對使用者—物品互動圖套用 LightGCN，得到 (u_{loc}, i_{loc}) 。全域視角（下方泳道）直接以查表得到使用者的全域嵌入 u_{glo} ，並對物品的 $A = 4$ 個潛在面向槽施加 softmax 合理化遮罩以得 i_{glo} ；面向槽本身為 SVD 初始化（圖中以虛線標註）。兩條視角由獨立的使用者側與物品側融合閘混合，每個閘的偏置初始化為 +5；最終分數為內積 $\langle u_{final}, i_{final} \rangle$ 。為求清晰，跨視角對比學習路徑於圖中省略，詳見第 3.5.6 節。




Figure 1: RA-GARK 架構。

兩項結構性質值得在形式化呈現之前先點明。其一， u_{glo} 並不經過合理化遮罩模組，而是由直接查表得到，並逕送至使用者側融合閘；合理化遮罩僅作用於物品側，符合「合理化回答的是『此物品的哪個面向對此使用者重要』」這一語意。其二，KG-SVD 步驟為初始化而非前向運算：SVD 於訓練前計算一次以設定面向槽參數的初值，其後槽位即如其他參數般以梯度下降更新。

3.1.2 符號

本論文後續使用之符號列於表 5。

Table 5: RA-GARK 公式化所使用之符號。

符號	意義
$\mathcal{U}, \mathcal{I}$	使用者集合與物品集合
$\mathcal{R} \subseteq \mathcal{U} \times \mathcal{I}$	已觀察到的使用者—物品互動
$\mathcal{G}_{\text{KG}}$	物品—面向知識圖譜（評論衍生）
$\mathcal{A}$	$\mathcal{G}_{\text{KG}}$ 中出現之 unique 面向標籤集合
A	每件物品的潛在面向槽數（ $A = 4$ ）
d	嵌入維度（除另行指定， $d = 128$ ）
K	LightGCN 傳播層數（ $K = 2$ ）
$u_{\text{loc}}, i_{\text{loc}} \in \mathbb{R}^d$	區域視角（LightGCN）嵌入
$u_{\text{glo}} \in \mathbb{R}^d$	全域視角使用者嵌入（直接查表）
$\mathbf{a}_i \in \mathbb{R}^{A \times d}$	物品 i 之潛在面向槽（SVD 初始化）
$i_{\text{glo}} \in \mathbb{R}^d$	全域視角物品嵌入（合理化遮罩後）
$\alpha_u, \alpha_i \in (0, 1)$	使用者側與物品側融合閘輸出
$\hat{y}(u, i) \in \mathbb{R}$	對配對 (u, i) 之預測偏好分數

3.1.3 問題定式

推薦任務 本文處理隱式回饋設定下的 top- K 推薦。給定 $\mathcal{U}$ 、 $\mathcal{I}$ 、已觀察到的互動 $\mathcal{R}$ ，以及物品—面向 KG $\mathcal{G}_{\text{KG}}$ ，目標是為每位使用者 $u \in \mathcal{U}$ 產生一個由其尚未互動過之物品所組成的排序清單，並以排序指標（NDCG@ K 、Recall@ K 、Hit@ K ）對保留之測試互動集進行評估。

評分函數 RA-GARK 對每組 (u, i) 配對指派 Eq. (1) 中的內積分數：

$$\hat{y}(u, i) = \langle u_{\text{final}}, i_{\text{final}} \rangle, \quad (1)$$

其中 u_{final} 與 i_{final} 由 Eq. (2) 的區域與全域表示閘控融合產生：

$$u_{\text{final}} = \alpha_u u_{\text{loc}} + (1 - \alpha_u) u_{\text{glo}}, \quad i_{\text{final}} = \alpha_i i_{\text{loc}} + (1 - \alpha_i) i_{\text{glo}}. \quad (2)$$

閘輸出 α_u, α_i 分別由獨立的 MLP 計算（第 3.5 節）。在本論文採用的偏置初始化下， $\alpha_u^{(0)}, \alpha_i^{(0)} \approx 0.993$ ，因此 $\hat{y}^{(0)}(u, i) \approx \langle u_{\text{loc}}, i_{\text{loc}} \rangle$ ，即訓練起點之分數實質為純 LightGCN 之分數，直至閘藉學習而調整。

訓練目標 我們最佳化 Eq. (3) 中的目標，即以 Bayesian Personalized Ranking (BPR) [19] 損失為主體，並輔以兩條跨視角對比正則化：

$$\mathcal{L} = \mathcal{L}_{\text{BPR}} + \lambda_{\text{CL}}(\mathcal{L}_{\text{aCL}} + \mathcal{L}_{\text{uCL}}), \quad (3)$$

其中 Eq. (4) 的 BPR 項針對每組已觀察配對 $(u, i^+) \in \mathcal{R}$ 與一個取樣的負例物品 $i^- \notin \mathcal{R}_u$ 計算：

$$\mathcal{L}_{\text{BPR}} = -\log \sigma(\hat{y}(u, i^+) - \hat{y}(u, i^-)), \quad (4)$$

而 $\mathcal{L}_{\text{aCL}}, \mathcal{L}_{\text{uCL}}$ 分別為 $(i_{\text{loc}}, i_{\text{glo}})$ 與 $(u_{\text{loc}}, u_{\text{glo}})$ 之間的 InfoNCE 式對齊損失；全域側施加 stop-gradient 以避免對比梯度擾動 SVD 初始化之面向槽（第 3.5.6 節）。對比權重 λ_{CL} 固定為 0.005，使對比的角色為輔助而非主要。

3.2 區域視角：LightGCN

區域視角僅由使用者—物品互動圖產生純協同表示 $(u_{\text{loc}}, i_{\text{loc}})$ ；此分支內部完全不施加任何 KG 運算。其架構與 LightGCN [1] 完全相同。

3.2.1 動機

選擇 LightGCN 作為區域視角骨幹的理由有三。其一，在本論文所使用之稀疏評論衍生 KG 上，純 LightGCN 已超越我們所評估的全部四個 KG-aware 基線（第 1 章），故為任何後續設計必須可被證實能改善的最強無 KG 起點。其二，其參數化極為精簡（僅有使用者與物品的嵌入表，傳播過程中無任何學習權重）這限制了兩條視角後續耦合時 KG 雜訊得以滲入協同梯度流的接觸面。其三，傳播為純線性，故每層對最終表示的貢獻可由閉式之層平均直接讀出，從而能在不受非線性干擾的前提下，理性化關於閘的放置（第 3.5 節）與對比對齊（第 3.5.6 節）的設計決策。

3.2.2 圖的建構

令 $\mathbf{R} \in \{0, 1\}^{|\mathcal{U}| \times |\mathcal{I}|}$ 為由 $\mathcal{R}$ 衍生的使用者—物品互動矩陣，其中 $\mathbf{R}_{u,i} = 1$ 當且僅當 $(u, i) \in \mathcal{R}$ 。據此建構 Eq. (5) 中的二部圖鄰接矩陣：

$$\mathbf{A} = \begin{bmatrix} \mathbf{0} & \mathbf{R} \\ \mathbf{R}^\top & \mathbf{0} \end{bmatrix} \in \mathbb{R}^{(|\mathcal{U}|+|\mathcal{I}|) \times (|\mathcal{U}|+|\mathcal{I}|)}, \quad (5)$$

並使用 Eq. (6) 的對稱歸一化形式：

$$\tilde{\mathbf{A}} = \mathbf{D}^{-1/2} \mathbf{A} \mathbf{D}^{-1/2}, \quad \mathbf{D} = \text{diag}(\mathbf{A} \mathbf{1}). \quad (6)$$

此歸一化降低了與高度使用者或熱門物品相鄰之邊的權重，於實務上有助於穩定長尾互動分布下的訓練。

3.2.3 傳播

令 $\mathbf{E}^{(0)} \in \mathbb{R}^{(|\mathcal{U}|+|\mathcal{I}|) \times d}$ 為初始嵌入表，前 $|\mathcal{U}|$ 列為使用者嵌入，其餘 $|\mathcal{I}|$ 列為物品嵌入；兩區塊皆以 Xavier-normal 初始化。第 ℓ 層由 Eq. (7) 的單次歸一化鄰居聚合得到：

$$\mathbf{E}^{(\ell+1)} = \tilde{\mathbf{A}} \mathbf{E}^{(\ell)}, \quad \ell = 0, 1, \dots, K-1. \quad (7)$$

過程中無任何可學習權重矩陣、無非線性、無自迴圈偏置，整個區域視角所有可學習參數即為 $\mathbf{E}^{(0)}$ 的 $|\mathcal{U}|d + |\mathcal{I}|d$ 個元素。

3.2.4 層平均與輸出

採用 Eq. (8) 中 LightGCN 標準的層平均：

$$\bar{\mathbf{E}} = \frac{1}{K+1} \sum_{\ell=0}^K \mathbf{E}^{(\ell)}, \quad (8)$$

並由 $\bar{\mathbf{E}}$ 對應列讀出 u_{loc} 與 i_{loc} 。本論文使用 $K=2$ ，與原始 LightGCN 論文一致，亦為我們純區域驗證損失趨於平台的深度。

如此得到的嵌入對僅由使用者—物品互動圖提供資訊；區域視角僅透過第 3.5 節之融合階段參與最終分數 $\hat{y}(u, i)$ ，訓練過程中不容許任何 KG 訊號改變 u_{loc} 或 i_{loc} 。

3.3 全域視角：KG-SVD 初始化

全域視角引入一獨立的使用者側嵌入 u_{glo} （直接查表，見下文）與一物品側參數張量以儲存各物品之 KG 語意。此物品側張量為 RA-GARK 中唯一容許 KG 內容進入模型之處。本節說明該張量之參數化方式及其值如何初始化。圖 2 提供四階段初始化流程之視覺概觀，其餘內容則將每階段形式化。




Figure 2: 物品面向槽之 KG-SVD 初始化。

3.3.1 面向槽作為物品側 KG 表示

每件物品 i 在全域視角中由 Eq. (9) 的面向槽張量表示：

$$\mathbf{a}_i \in \mathbb{R}^{A \times d}, \quad A = 4 \quad (9)$$

將所有物品的張量集合為一可學習參數 $\mathbf{A}_{KG} \in \mathbb{R}^{|I| \times A \times d}$ 。初始化（下節說明）之後， $\mathbf{A}_{KG}$ 即如其他參數般以梯度下降更新。

此處有一關鍵釐清：槽位數 $A = 4$ 為模型超參數，不對應於每件物品的固定原始面向標籤數。在本論文使用的評論衍生 KG 中，每件物品平均僅持有 2.4 條面向邊，全域面向標籤詞彙遠大於 A ($|\mathcal{A}| \gg A$)。此四個槽位為面向誘導語意子空間中的潛在方向，跨全體物品共同學習，而非綁定於特定標籤。

3.3.2 共現矩陣

從 Eq. (10) 定義的二值物品一面向共現矩陣 $\mathbf{M} \in \{0, 1\}^{|I| \times |\mathcal{A}|}$ 出發：

$$\mathbf{M}_{i,a} = \begin{cases} 1, & (i, a) \in \mathcal{G}_{KG}, \\ 0, & \text{否則} \end{cases} \quad (10)$$

$\mathbf{M}$ 的每一列因此是一個稀疏指示向量：每件物品至多只有少數幾個非零項；經剪枝後（第 4.1 節）全域密度對應於每列平均 2.4 個 1。

3.3.3 IDF 加權

部分面向標籤橫跨許多物品（如「文筆優美」、「引人入勝」），其他則高度特定（如某個利基類型或主題）。若不修正，後續 SVD 將由高頻標籤主導，所產生的潛在方向實質上只是熱門度先驗。我們以 Eq. (11) 的標準逆文件頻率（IDF）重新加權緩解此問題：

$$\text{idf}(a) = \log \left(\frac{|\mathcal{I}|}{|\{i : \mathbf{M}_{i,a} = 1\}| + 1} \right) + 1, \quad (11)$$

並依 Eq. (12) 重新縮放 $\mathbf{M}$ 各行：

$$\tilde{\mathbf{M}}_{i,a} = \text{idf}(a) \cdot \mathbf{M}_{i,a}. \quad (12)$$

分母中之 $+1$ 避免對所有物品支持已被剪除之面向除以零；對數外之 $+1$ 防止最大頻率面向的 IDF 退化為零。兩項調整皆為標準作法。

3.3.4 截斷 SVD

對 $\tilde{\mathbf{M}}$ 計算 Eq. (13) 中秩 k 之截斷 SVD：

$$\tilde{\mathbf{M}} \approx \mathbf{U}_k \Sigma_k \mathbf{V}_k^\top, \quad \mathbf{U}_k \in \mathbb{R}^{|\mathcal{I}| \times k}, \quad (13)$$

其中 $k = A \cdot d$ 。左奇異矩陣 $\mathbf{U}_k$ 每件物品一列；各列位於一 k 維潛在子空間，於其中 IDF 加權的面向共現於秩 k 下被最佳解釋。

接著依 Eq. (14) 形成每件物品的潛在嵌入，將每個分量以對應奇異值之平方根縮放：

$$\mathbf{E}_{\text{KG}} = \mathbf{U}_k \Sigma_k^{1/2} \in \mathbb{R}^{|\mathcal{I}| \times k}. \quad (14)$$

此平方根縮放使譜能量均勻分布於左右因子，為標準選擇，所得嵌入之兩兩內積近似 IDF 加權共現內容。

3.3.5 重塑為槽位與量值縮放

寬度為 $k = Ad$ 的展平嵌入 $\mathbf{E}_{\text{KG}}$ 依 Eq. (15) 被重塑為每件物品 A 個寬度 d 的槽：

$$\mathbf{A}_{\text{KG}}^{(0)}[i, k, :] = \mathbf{E}_{\text{KG}}[i, kd : (k+1)d], \quad k = 0, \dots, A-1. \quad (15)$$

槽因此是 SVD 輸出中互不相交的連續區塊；它們不對應於可獨立解讀的面向標籤。

由於 $\mathbf{E}_{\text{KG}}$ 之量值依賴於 $|\mathcal{I}|$ 、 $|\mathcal{A}|$ 與 $\tilde{\mathbf{M}}$ 的譜，未經縮放的 SVD 輸出與模型他處 Xavier 初始化參數不在同一量級。我們因此將整個 $\mathbf{A}_{\text{KG}}^{(0)}$ 重新縮放，使其經驗標準差匹配 Xavier-normal 目標 $\sigma = \sqrt{2/(A+d)}$ 。此縮放保留 SVD 輸出的角度幾何（也正是我們想注入的）同時使槽位量值與其餘最佳化過程相容。

3.3.6 演算法

完整初始化可總結為五步：

1. 由 $\mathcal{G}_{\text{KG}}$ 建構二值共現矩陣 $\mathbf{M}$ (Eq. (10))。
2. 套用 IDF 列加權得 $\tilde{\mathbf{M}}$ (Eq. (12))。
3. 計算秩 $k = Ad$ 之截斷 SVD： $\tilde{\mathbf{M}} \approx \mathbf{U}_k \Sigma_k \mathbf{V}_k^\top$ (Eq. (13))。
4. 形成 $\mathbf{E}_{\text{KG}} = \mathbf{U}_k \Sigma_k^{1/2}$ 並重塑為 $\mathbf{A}_{\text{KG}}^{(0)} \in \mathbb{R}^{|\mathcal{I}| \times A \times d}$ (Eq. (15))。
5. 整體重新縮放使標準差匹配 Xavier-normal 目標。

若 $|\mathcal{A}| < Ad$ ，SVD 秩被限制為 $|\mathcal{A}| - 1$ ，剩餘槽維度於縮放前以小量高斯雜訊（標準差 0.01）填補；在我們的實驗中 $|\mathcal{A}| \gg Ad$ ，故此降階路徑不被觸發。

3.3.7 初始化效益

KG-SVD 初始化的貢獻於第 4.4 節以消融衡量：將其替換為相同張量形狀之 Xavier-normal 隨機初始化會損失 6.0% NDCG@20。其解釋是：SVD 初始化在訓練起點即保留了面向誘導語意子空間的角度幾何；其後梯度下降可微調此幾何，但在我們的稀疏 KG 條件下，難以由隨機初始化恢復，能恢復此幾何的梯度訊號需流經對比損失（ $\lambda_{\text{CL}} = 0.005$ ），訊號微弱。

3.4 全域視角：Softmax 合理化遮罩

給定物品的面向槽張量 $\mathbf{a}_i \in \mathbb{R}^{A \times d}$ 與使用者側全域嵌入 $u_{\text{glo}} \in \mathbb{R}^d$ ，合理化遮罩模組選取 A 個潛在槽中最能在該使用者下代表該物品者，得到全域視角物品嵌入 i_{glo} 。使用者側全域嵌入本身為 Eq. (16) 的直接查表：

$$u_{\text{glo}} = \mathbf{E}_u^{\text{glo}}, \quad \mathbf{E}^{\text{glo}} \in \mathbb{R}^{|\mathcal{U}| \times d}, \quad (16)$$

其中 $\mathbf{E}^{\text{glo}}$ 為與區域視角使用者表分離的可學習參數；使用者側不施加任何合理化運算。

3.4.1 動機

每件物品的 KG 語意分散儲存於 $\mathbf{a}_i$ 的 A 個潛在槽中；不同槽位編碼 SVD 可見之不同語意面向。合理化模組的職責即在（使用者, 物品）配對之條件下，於全域視角中挑出最能代表該物品之槽。Eq. (17) 將槽 logit 同時條件於 u_{glo} 與槽嵌入，因此選擇於結構上為 per-(使用者, 物品)；至於訓練完成之模型是否實際運用使用者維度、抑或退化為物品條件之路由，則為實證問題，於第 4.6 節個案研究中檢視。

3.4.2 使用者條件之注意力 logits

對每個槽 $k \in \{1, \dots, A\}$ ，計算 Eq. (17) 中的純量 logit：

$$\ell_{u,i,k} = \text{MLP}([u_{\text{glo}} \parallel \mathbf{a}_{i,k}]) \in \mathbb{R}, \quad (17)$$

其中 $\parallel$ 表沿嵌入維度串接，MLP 參數於所有槽與物品間共享。MLP 為 Eq. (18) 的兩層前饋區塊：

$$\text{MLP}(\mathbf{z}) = \mathbf{w}^\top \cdot \text{LeakyReLU}(\mathbf{W} \mathbf{z}), \quad (18)$$

其中 $\mathbf{W} \in \mathbb{R}^{d \times 2d}$ 、 $\mathbf{w} \in \mathbb{R}^d$ 。跨槽共享參數至關重要：它迫使 MLP 學到一個與槽無關的「此槽與此使用者契合程度」概念，而非為每個槽記憶各自的評分函數。

3.4.3 Softmax 歸一化

A 個 logit 透過 Eq. (19) 中帶溫度 τ 之 softmax 歸一化為槽位機率分布：

$$w_{u,i,k} = \frac{\exp(\ell_{u,i,k}/\tau)}{\sum_{k'=1}^A \exp(\ell_{u,i,k'}/\tau)}. \quad (19)$$

依建構 $\sum_k w_{u,i,k} = 1$ ， A 個槽位權重彼此競爭：增加某槽相對權重必使其餘槽位下降。我們使用 $\tau = 0.5$ ，相對於無資訊先驗（ $\tau = 1$ 在 $\text{logit} = 0$ 時得完全均勻）銳化分布，將質量集中於對使用者最相關之槽。溫度掃描見第 4.5.1 節。

3.4.4 加權聚合

全域視角物品嵌入為 Eq. (20) 的槽加權平均：

$$i_{\text{glo}} = \sum_{k=1}^A w_{u,i,k} \cdot \mathbf{a}_{i,k} \in \mathbb{R}^d. \quad (20)$$

實作上即為「合理化遮罩」步驟：softmax 權重作為槽維度上的軟遮罩，被遮罩之槽位再加總回單一 d 維向量。雖然 Eq. (19) 與 Eq. (20) 概念上為兩步，但在程式中於單一模組 (KGRationaleMasking) 內以一次前向呼叫完成。

3.4.5 Softmax 與 Sigmoid

一個自然的替代是對每個槽獨立以 sigmoid 評分： $w_{u,i,k} = \sigma(\ell_{u,i,k})$ ，不施加跨槽歸一化。兩種運算於下游融合閘所關注之一項結構性質上不同：Softmax 產生之權重總和為 1，所得 i_{glo} 之模長無論 logit 尺度為何皆有界於 $\max_k \|\mathbf{a}_{i,k}\|$ ；sigmoid 之輸出總和不受限，所得 i_{glo} 之模長隨 logit 動態範圍縮放。

實證上 sigmoid 變體會使本基準 NDCG@20 下降 19.2% (第 4.4 節)，是我們所觀察到單一元件影響最大者。第 4.6 節之個案研究暗示其因：合理化模組運作於刻意被節制之 KG 通道內，最終產生之是軟尖峰權重 ($\max_k w_k \approx 0.28$ 、其餘約 0.24)，而非單由 Softmax 名稱所推測之近 one-hot 向量。於 Softmax 下此即意謂 i_{glo} 之模長維持有界且可預測，融合閘之校準 (第 3.5.3 節) 因而能穩定將 KG 貢獻維持於分數中所欲之小比例；於 sigmoid 下逐槽模長則隨 logit 漂移，恰好破壞了閘所依賴之「有界貢獻」性質。Softmax 之承載性角色因此為「為被節制之輔助通道提供模長受控之歸一化」，而非強制諸槽間之 one-hot 競爭。我們在第 5 章對此發現作更謹慎之討論，並明確將其定位為單一資料集觀察，需多資料集複製驗證。

3.5 區域偏置融合與對比正則化

融合閘是將 RA-GARK 設計原則 (KG 為可被閘控之旁路通道) 落實為具體運算的架構機制。它將區域與全域表示結合為最終嵌入，並由其產生分數。圖 3 以使用者側為例呈現訊號流；圖中被標註的 $b = +5$ 框預告了第 3.5.3 節將展開的偏置初始化設計，物品側結構完全相同。




Figure 3: 結合區域與全域視角之區域偏置融合閘。

3.5.1 雙側獨立閘

RA-GARK 使用兩個獨立融合閘，使用者側與物品側各一。兩者皆為純量閘，以該側區域與全域嵌入之串接為條件，如 Eq. (21) 與 Eq. (22) 所示：

$$\alpha_u = \text{Gate}_u([u_{\text{loc}} \parallel u_{\text{glo}}]) \in (0, 1), \quad (21)$$

$$\alpha_i = \text{Gate}_i([i_{\text{loc}} \parallel i_{\text{glo}}]) \in (0, 1). \quad (22)$$

兩閘參數獨立；經驗上共享參數會劣化結果，因為在稀疏 KG 下 KG 訊號對使用者側與物品側嵌入的邊際資訊量不同。

兩個純量閘接著透過 Eq. (2) 已定義之融合規則作用；最終分數為內積 $\hat{y}(u, i) = \langle u_{\text{final}}, i_{\text{final}} \rangle$ ，如 Eq. (1) 已述。

3.5.2 閘的結構

每個 Gate 為 Eq. (23) 定義之帶 sigmoid 頭的小型 MLP：

$$\text{Gate}(\mathbf{z}) = \sigma(\mathbf{w}^\top \tanh(\mathbf{W}\mathbf{z}) + b), \quad (23)$$

其中 $\mathbf{W} \in \mathbb{R}^{d \times 2d}$ 、 $\mathbf{w} \in \mathbb{R}^d$ 、 b 為純量偏置、 σ 為邏輯函數。隱藏層寬度與嵌入維度一致。第一層權重 $\mathbf{W}$ 以 Xavier-uniform 初始化、偏置為零；第二層權重 $\mathbf{w}$ 同樣以 Xavier-uniform 初始化；第二層偏置 b 即下節要特別初始化者。

我們選擇以 MLP 而非線性閘作為融合函數，原因在於此處的閘不是學一個固定混合比例，而是根據區域與全域表示的聯合狀態做條件式決策。線性閘只能在串接後的向量上學到仿射判別；加入隱藏層與非線性後，模型才有能力表達諸如「只有當某個(使用者, 物品)配對的全域視角確實提供有用訊號時，才開啟 KG 通道」這類依樣本而變動的行為。換言之，MLP 不是為了單純增加模型容量，而是為了讓閘能學到樣本相依的開啟策略，同時仍受 sigmoid 輸出範圍所約束。

3.5.3 區域偏置初始化

關鍵設計選擇為 Eq. (23) 中純量偏置 b 的初始化。當 $b = 0$ ，訓練起點之閘輸出約為 $\sigma(0) = 0.5$ ，即區域與全域 50/50 混合。由於全域視角部分由帶雜訊之 KG 初始化，50/50 起點將使區域表示整個訓練過程中皆暴露於 KG 雜訊；而第 1 章已觀察到此正是深度融合基線的失效模式。

我們改將兩個閘的偏置皆初始化為 $b = +5$ 。訓練起點之閘輸出因此如 Eq. (24) 所示：

$$\alpha^{(0)} \approx \sigma(b) = \sigma(5) \approx 0.993, \quad (24)$$

初始混合約為 Eq. (25) 中偏向區域視角的組合：

$$u_{\text{final}}^{(0)} \approx 0.993 u_{\text{loc}}^{(0)} + 0.007 u_{\text{glo}}^{(0)}, \quad (25)$$

物品側類似。換言之，RA-GARK 訓練起點實質為純 LightGCN。KG 通道起初僅開啟 0.7%；唯當 BPR 損失對 b 之梯度將 b 向下推動時（亦即拓寬 KG 通道能降低損失時）通道才會被擴大。偏置作為一個學習得到的、傾向安全預設之先驗。

3.5.4 優雅退化

區域偏置初始化提供結構性保證：若 KG 結果為完全無資訊，閘將維持於 $\alpha \approx 1$ 附近，KG 項對分數的貢獻被上界約為 $0.007 \cdot \|\mathbf{a}\| \cdot \|\mathbf{u}\|$ ，模型於經驗上與純 LightGCN 無從區分。第 1 章所列之四個基線皆無此性質：每個都強制 KG 實體嵌入無論其是否具資訊量皆參與傳播路徑。

此即 Highway Networks [10] 嚴格架構意義下的優雅退化性質，自網路內部跳接移植至視角間融合。據我們所知，尚無 KG-aware 推薦器採此設計。

3.5.5 融合偏置量值選擇

偏置量值之選擇依單一原則：大到使初始閘輸出絕對偏向區域、小到使 b 之梯度非零而能於訓練中調整閘。於 $b = +5$ ， $\sigma'(5) = \sigma(5)(1 - \sigma(5)) \approx 0.007$ ，雖小但未消失。 $b = +10$ 之後 b 上之梯度於數值上可忽略，閘無法學會開啟。 $b = +5$ 為使 $\alpha^{(0)} > 0.99$ 同時保持 $\sigma'(b) > 10^{-3}$ 之最小整數，並通過敏感性掃描不需進一步調整（第 4.5.3 節）。完全移除偏置初始化（設 $b = 0$ ）會損失 3.7% NDCG@20（第 4.4 節）。

3.5.6 跨視角對比正則化

區域與全域視角於結構上異質：一者為來自互動的協同表示，另一者為 KG 衍生表示，二者位於不同歸納子空間。若無任何明確對齊，兩表示在訓練過程中可能漂移至 $\mathbb{R}^d$ 中彼此不相容之區域，此時融合閘所合併的向量並非直接可比。跨視角對比正則化即在處理此幾何錯位。

在架構中的角色 於 RA-GARK 中，對比損失扮演刻意受限之角色。它們並非主要整合機制，此角色由融合閘擔任（第 3.5 節），而是將兩視角推向共享角度幾何的正則化項。具體而言，我們刻意不使用對比學習讓 KG 通道「掙得」其進入模型之資格，如 KGCL [5] 與 MCCLK [6] 所為；那將重新引入「將 KG 訊號視為必經主融合路徑」的失效模式。

面向層級對比損失 對訓練批次中每件物品 i ，Eq. (26) 的面向層級損失將其投影後的區域嵌入與其 A 個面向槽分別對比：

$$\mathcal{L}_{\text{aCL}} = \frac{1}{A} \sum_{k=1}^A \text{InfoNCE}(g(i_{\text{loc}}), \text{sg}[\mathbf{a}_{i,k}]), \quad (26)$$

其中 $g: \mathbb{R}^d \rightarrow \mathbb{R}^d$ 為可學習投影頭（兩層 MLP 加 ReLU），僅施加於區域側輸入； $\text{sg}[\cdot]$ 表示 stop-gradient；InfoNCE 為 Eq. (27) 的標準對比目標：

$$\text{InfoNCE}(\mathbf{x}, \mathbf{y}) = -\log \frac{\exp(\langle \mathbf{x}, \mathbf{y} \rangle / \tau_{\text{CL}})}{\sum_{j=1}^B \exp(\langle \mathbf{x}, \mathbf{y}_j \rangle / \tau_{\text{CL}})}, \quad (27)$$

$\tau_{\text{CL}} = 0.2$ 、 B 為批次大小（負例為批次內其餘物品）。向量於內積之前皆作 ℓ_2 歸一化。

使用者層級對比損失 對稱之使用者層級損失如 Eq. (28) 所示，用以對齊區域與全域使用者嵌入：

$$\mathcal{L}_{\text{uCL}} = \text{InfoNCE}(g(u_{\text{loc}}), \text{sg}[u_{\text{glo}}]). \quad (28)$$

投影頭 g 與 $\mathcal{L}_{\text{aCL}}$ 共享，因兩損失皆作用於區域側輸入，且我們希望投影編碼單一之「區域視角如何映射至全域視角角度幾何」變換。

全域側 Stop-Gradient Eq. (26) 與 Eq. (28) 中 KG 側之 stop-gradient 在結構上至關重要。若無，對比梯度會反向傳遞至 SVD 初始化的面向槽與全域使用者表，逐漸破壞 KG-

SVD 初始化所安裝之角度幾何（第 3.3 節）。配合 stop-gradient 後，對比損失作用不對稱：能將區域視角拉向全域視角已有之幾何，但無法把全域視角向任何方向推動。KG 衍生語意子空間被保留為外部參照，由區域視角承擔對齊代價。

損失權重 Eq. (3) 中對比權重 λ_{CL} 固定為 0.005。此值小到使對比損失於總梯度中貢獻一非主導比例（BPR 仍為主要訊號），亦與第 3.5.6 節所賦予對比正則化之角色一致：幾何先驗，非主要學習目標。我們不對 λ_{CL} 作資料集相關調參。

3.6 訓練與計算複雜度

3.6.1 總目標

完整訓練損失即為 Eq. (3) 中的目標。BPR 損失提供主要排序訊號；對比項提供跨視角幾何對齊。

3.6.2 最佳化

以 Adam（預設 $\beta_1 = 0.9, \beta_2 = 0.999, \epsilon = 10^{-8}$ ）最佳化 Eq. (3)，學習率 10^{-3} 、批次大小 128，最多訓練 80 epochs。以驗證集 NDCG@20 之耐心 10 早停。每批次包含 128 組三元組 (u, i^+, i^-) ，其中 i^- 自 $\mathcal{R}_u$ 之外的物品均勻取樣。Eq. (7)–Eq. (8) 之 LightGCN 傳播於每批次重新計算一次，並於該批次內正負例評分時共用。

3.6.3 推論

推論時，於評估開始時計算 LightGCN 傳播一次並快取 $\bar{\mathbf{E}}$ 。對每個查詢使用者 u ，以單次批次矩陣乘法計算全部物品集合之分數：面向槽、合理化權重、 i_{glo} 、物品閘以及與 u_{final} 之內積，皆於整個物品集合上以向量化形式同時評估。

3.6.4 計算複雜度

令 B 為批次大小、 $|\mathcal{E}_{UI}|$ 為已觀察使用者—物品互動數、 $|\mathcal{I}|$ 為物品數、 A 為槽位數、 d 為嵌入維度、 K 為 LightGCN 層數。每批次訓練成本分解如下：

Table 6: RA-GARK 各模組之每批次訓練成本。

模組	成本
LightGCN 傳播	$O(\mathcal{E}_{\mathcal{U}\mathcal{I}} d K)$
u_{glo} 查表	$O(B d)$
面向槽讀取	$O(B A d)$
合理化遮罩	$O(B A d)$
使用者與物品融合閘	$O(B d^2)$
BPR 與對比損失	$O(B d)$

LightGCN 傳播項主導訓練成本，與純 LightGCN 基線完全一致。KG 側之新增（面向讀取、合理化遮罩、融合閘）貢獻為 A 與 d 之線性項，皆相對於傳播為小。RA-GARK 之每 epoch 牆鐘時間因此於純 LightGCN 之小常數倍以內，並於同一硬體與相同嵌入維度下與 KGRec 大致相等（精確牆鐘數字見第 4.6.1 節）。

全集合推論由使用者條件之物品側合理化遮罩步驟 $O(B \cdot |\mathcal{I}| \cdot A \cdot d)$ 主導，於本論文使用之資料集規模下可行。

4 實驗與結果

本章在第 1 章所動機之稀疏評論衍生 KG 上評估 RA-GARK。第 4.1 節整理資料集與 KG 建構流程，其中後者沿用既有工作，並非本文貢獻。第 4.2 節說明評估協議與 baseline 重現設定。第 4.3 與 4.4 節報告主結果與逐元件消融。第 4.5 節檢查超參數敏感性與種子穩定性。第 4.6 節以個別 (使用者, 物品) 配對展示合理化模組的可解釋性，並報告計算成本。

4.1 資料集與 KG 建構

4.1.1 資料集

我們的實驗使用 Amazon Books 評論語料的一個子集，並將其處理為使用者—物品互動圖與物品—面向知識圖譜。表 7 摘要過濾後之統計。移除低互動使用者與物品、剪裁罕見面向標籤後（見下文），工作資料集包含 905 位使用者、1,399 件物品、22,265 筆正向互動，以及分布於 2,098 個獨立面向標籤上的 3,370 條 KG 邊。每件物品平均攜帶 2.4 條面向邊；在此稀疏程度下，我們所測的四個 KG-aware baseline 均敗給純 LightGCN（第 1 章）。

Table 7: 前處理後之資料集統計。

統計	數值
# 使用者	905
# 物品	1,399
# 互動	22,265
#KG 邊（過濾後）	3,370
# 獨立面向	2,098
每物品平均邊數	2.4
互動密度	1.76%

互動以使用者分層方式切為 70/15/15 之 train/validation/test，確保每位至少觀察到三

件物品的使用者皆出現於三個切分。產生切分之隨機種子固定為 42，且於所有 baseline 重現中共用，以排除切分變異作為混淆因子。

4.1.2 知識圖譜建構

本文所用之物品一面向 KG 由 [20] 之流程自原始商品評論建構，我們不加修改地直接使用。由於建構本身非本文貢獻，僅就理解結果所需之步驟作扼要說明：對每本書，先以 ResNet 與 Qwen-VL 自封面影像萃取物品側視覺特徵，再由 BART 與 Mistral 自評論池生成統一文字摘要；接著自摘要抽取面向出現，形成 $(item, has_aspect, aspect)$ 三元組。原始抽取共得 13,905 條候選邊。

兩道過濾將其縮減為工作 KG。其一，移除頻率前 2% 之面向標籤（經驗上多為「well-written」「engaging」等通用讚詞），理由是此類標籤幾乎不攜帶物品鑑別資訊，且會主導後續 SVD 譜（第 3.3 節）。其二，以一份小型手工策劃之停用詞清單移除領域特定通用詞（如「character_development」「highly_recommended」）。兩道過濾合計丟棄 75.7% 之原始邊，留下分布於 2,098 個獨立標籤上的 3,370 條具體面向附著。

此過濾後之 KG 為所有 KG-aware 方法（含 RA-GARK）於本評估中之唯一外部訊號。過濾在各方法間以相同方式套用，使比較反映模型差異，而非 KG 清潔度差異。

4.2 實驗設定

4.2.1 Baseline

我們將 RA-GARK 與五個 baseline 比較：純 LightGCN [1] 作為非 KG 對照，以及四個代表性 KG-aware 推薦器，KGAT [4]、KGCL [5]、MCCLK [6]、KGRec [7]。此四個 KG-aware baseline 涵蓋第 2 章所綜述之主要整合範式：深度聚合器融合（KGAT）、跨視角對比學習（KGCL、MCCLK）、邊層級合理化學習（KGRec）。

- **LightGCN** 移除圖協同過濾中的特徵轉換與非線性 activation，僅保留歸一化使用者—物品傳播與層平均嵌入；在本文稀疏評論情境中作為最強非 KG 對照。
- **KGAT** 透過使用者—物品—實體圖上的 attention message passing 注入 KG 資訊，代表 KG 實體直接參與表示傳播的深度融合類方法。
- **KGCL** 將協同推薦與互動視角、KG 視角增強之間的對比學習結合，透過跨視角一致性正則化推薦器。

- **MCCLK** 以多個對比目標延伸 KG-aware 對比推薦，目標是對齊協同、語意與知識感知訊號。
- **KGRec** 於 KG 邊上學習 rationale，是動機上最接近 RA-GARK 的 baseline；但其 rationale 機制作用於邊選擇，而非本文的閘控面向槽融合。

所有 baseline 皆由作者公開程式碼於相同處理後之 KG（第 4.1.2 節）與相同使用者分層切分上重現。我們保留各 baseline 已發表之超參數預設，而非逐一重新調參，原因在於針對四種不同超參數空間重新調參會引入比較偽影；原作者最了解自己模型的最佳配置。唯一介入為固定嵌入維度 $d = 128$ （與 RA-GARK 一致），並對齊最佳化預算（epoch 與 early-stopping patience）。此選擇刻意保守：可能低估 baseline 於本資料集所能達之上限，但可確保比較不受調參投入不均所污染。

4.2.2 評估協議

我們採用全項目排序協議：對每位測試使用者，於 $\mathcal{I}$ 中排除其訓練集已觀察項後，對其餘所有物品評分，並將排序後之候選清單與留存測試正樣本比對計算 top- K 指標。此為嚴格協議；採樣式評估（例如對 100 隨機負樣本排序）等變體未使用，因其於隱式回饋設定下已被證實會誇大模型差異。

我們以 NDCG@20 為主要指標，Recall@20、HR@20、MAP@20 為次要指標。Early stopping 以 validation NDCG@20 為依據（patience 10），測試指標取自最佳 validation NDCG@20 所對應的 epoch。本章所報數字皆為此協議下之測試指標。

4.2.3 超參數設定

RA-GARK 之超參數總結於表 8。這些值並未經聯合調參：最佳化設定與嵌入維度沿用 LightGCN 預設；合理化溫度 $\tau = 0.5$ 與融合閘偏置 $b = +5$ 為第 3.4.3 與 3.5.3 節所論證之設計選擇；面向槽數 $A = 4$ 由第 3.3.1 節之設計理據固定；對比權重 $\lambda_{CL} = 0.005$ 為第 3.5.6 節所論證之小量輔助值。

Table 8: 實驗所使用之 RA-GARK 超參數設定。

超參數	值
嵌入維度 d	128
LightGCN 層數 K	2
面向槽數 A	4
合理化溫度 τ	0.5
融合閘偏置 b (初始化)	+5
對比權重 λ_{CL}	0.005
InfoNCE 溫度 τ_{CL}	0.2
最佳化器	Adam ($\beta_1=0.9, \beta_2=0.999$)
學習率	10^{-3}
Batch size	128
最大 epoch	80
Early-stopping patience	10
隨機種子	42

4.2.4 硬體與軟體

為確保實驗設定具可重現性，所有實驗皆於單張 NVIDIA GeForce RTX 3090 GPU (24GB 記憶體) 上執行。模型以 PyTorch 2.6.0 搭配 CUDA 12.6 實作，並以 FP32 訓練。每 epoch 牆鐘時間於第 4.6.1 節報告。

4.3 主要結果

表 9 與表 10 分別報告 Top-20 與 Top-10 的主要測試集結果。RA-GARK 取得 NDCG@20 = 0.1243，較最強 KG-aware baseline (KGRec) 提升 +13.5%，較純 LightGCN 提升 +5.4%。提升於各次要排序指標 (HR、Recall、MAP) 與兩個 cutoff 下皆一致；在 Top-10 下，RA-GARK 亦於 NDCG@10、HR@10、Recall@10 與 MAP@10 領先所有 baseline。對 KGRec 之最大相對增益為 MAP@20 的 +18.8%，顯示正確檢索物品之排序品質亦優於 baseline。

Table 9: Top-20 評估下之推薦表現比較。

模型	NDCG@20	HR@20	Recall@20	MAP@20
MCCLK [6]	0.1067	0.4530	0.1720	0.0497
KGCL [5]	0.1073	0.4696	0.1827	0.0479
KGAT [4]	0.1079	0.4773	0.1807	0.0491
KGRec [7]	0.1095	0.4729	0.1834	0.0500
LightGCN [1]	0.1179	0.4917	0.1937	0.0555
RA-GARK	0.1243	0.4972	0.2020	0.0594
Δ vs KGRec	+13.5%	+5.1%	+10.1%	+18.8%
Δ vs LightGCN	+5.4%	+1.1%	+4.3%	+7.0%

在 Top-20 cutoff 下，此結果有兩種讀法值得分開敘述。其一（較 KGRec +13.5%）顯示在相同 KG 下，RA-GARK 的設計選擇在同一資料集上產生比最強既有 KG-aware 方法更佳的推薦器。其二（較純 LightGCN +5.4%）在方法論上更具意義。在同一稀疏 KG 情境中，四個 KG-aware baseline 皆低於無 KG 對照；RA-GARK 是此處所評 KG-aware 配置中，唯一將 KG 訊號由淨負債轉為淨資產者。把 Top-20 與 Top-10 一起看，這個提升顯然不是只靠較深推薦列表撐出來的，而是排序訊號本身真的較強。

Table 10: Top-10 評估下之推薦表現比較。

模型	NDCG@10	HR@10	Recall@10	MAP@10
MCCLK [6]	0.0804	0.3182	0.1047	0.0416
KGCL [5]	0.0809	0.3260	0.1096	0.0410
KGAT [4]	0.0786	0.3215	0.1102	0.0388
KGRec [7]	0.0874	0.3249	0.1155	0.0465
LightGCN [1]	0.0908	0.3436	0.1201	0.0483
RA-GARK	0.0966	0.3558	0.1265	0.0520
Δ vs KGRec	+10.5%	+9.5%	+9.5%	+11.8%
Δ vs LightGCN	+6.4%	+3.6%	+5.4%	+7.7%

更嚴格的 Top-10 cutoff 保留相同排序，並降低增益只是來自較深推薦列表的可能性。RA-GARK 在 NDCG@10 上較 KGRec 提升 +10.5%，較純 LightGCN 提升 +6.4%，

且 HR、Recall 與 MAP 亦呈現一致增益。促成此翻轉之架構機制，也就是將 KG 通道置於偏置初始化之融合開後，使其僅在貢獻降低損失時才啟用，將於下一節詳細審視；這也是 Top-20 與 Top-10 兩個表格結論彼此一致的原因。

4.4 消融研究

我們衡量主要架構選擇之貢獻，方式為逐一移除單一元件並在其他設定固定下從頭重新訓練。為了讓結構更清楚，這些消融分為三類：核心架構元件（KG-SVD 初始化、Softmax 合理化遮罩、區域偏置融合開）、輔助正則項（使用者側與面向側對比損失），以及診斷變體（移除全域視角、以單一可學習純量 α 取代 per-(使用者, 物品) 開、或停用合理化選擇）。所有列皆使用種子 = 42。由於消融分析的目的在於隔離排序品質變化，本文回報 NDCG 與 MAP，而不列入 HR 與 Recall 等偏向覆蓋率的指標；表 11 與表 12 分別呈現相同消融集合於 Top-20 與 Top-10 下的結果。

Table 11: RA-GARK 設計元件之消融結果（Top-20 評估）。

模型	NDCG@20	MAP@20
RA-GARK（完整）	0.1243	0.0594
w/o softmax 頭	0.1005	0.0451
w/o KG-SVD 初始化	0.1171	0.0545
w/o 融合開偏置	0.1194	0.0555
w/o MLP 開	0.1180	0.0552
w/o 使用者 CL ($\mathcal{L}_{uCL}$)	0.1192	0.0563
w/o 面向 CL ($\mathcal{L}_{aCL}$)	0.1200	0.0570
w/o 合理化選擇	0.1213	0.0568
w/o 全域視角（純 CL 雙視角）	0.1219	0.0575

NDCG@20 反映較大幅度的整體排序退化；NDCG@10 則使用更嚴格 cutoff，因此絕對降幅略小。兩者的相對排序仍然穩定：核心架構列造成最大變化，對比列提供較小但一致的輔助效果，而診斷變體則確認這些增益不是單一 toggle 的偶然產物。讀這兩張表時，重點應放在同一排名模式是否跨 cutoff 持續成立，而不是某一個 delta 的絕對大小。

Table 12: RA-GARK 設計元件之消融結果 (Top-10 評估)。

模型	NDCG@10	MAP@10
RA-GARK (完整)	0.0960	0.0519
w/o softmax 頭	0.0785	0.0397
w/o KG-SVD 初始化	0.0922	0.0479
w/o 融合閘偏置	0.0923	0.0482
w/o MLP 閘	0.0926	0.0484
w/o 使用者 CL ($\mathcal{L}_{uCL}$)	0.0924	0.0492
w/o 面向 CL ($\mathcal{L}_{aCL}$)	0.0940	0.0502
w/o 合理化選擇	0.0943	0.0495
w/o 全域視角 (純 CL 雙視角)	0.0949	0.0504

元件貢獻 綜合兩個消融 cutoff，核心架構列主導排序損失，而對比列則提供較小但一致的輔助效果。影響最大者為 softmax 頭：NDCG@20 由 0.1243 降至 0.1005，MAP@20 由 0.0594 降至 0.0451，NDCG@10 由 0.0960 降至 0.0785，MAP@10 由 0.0519 降至 0.0397。其他核心元件亦不可忽略：移除 KG-SVD 時 NDCG@20 = 0.1171、MAP@20 = 0.0545；移除融合閘偏置時為 0.1194 與 0.0555；以純量閘取代 per-(u,i) MLP 閘時為 0.1180 與 0.0552。兩條對比損失的幅度較小，但維持穩定收益。

Softmax 與 sigmoid w/o softmax 列在兩個 cutoff 的 NDCG 與 MAP 下皆是最大消融。這即是我們於第 5 章發展之方法論觀察的實證基礎：於本合理化模組中，注意力歸一化之選擇不是調參細節，而是與合理化語意假設綁定的設計選擇，也就是 A 個槽位彼此競爭，而非各自獨立相關。

對比損失提供較小但非平凡的排序品質增益。移除使用者側 CL 使 NDCG@20 由 0.1243 降至 0.1192；移除面向級 CL 則降至 0.1200。我們解讀此量級與第 3.5.6 節賦予對比正則化之輔助角色一致：其推動幾何，但不承擔整合負荷。

4.5 敏感性分析

我們沿讀者最可能質疑之四個超參數軸探究 RA-GARK 之敏感性：Softmax 溫度 τ 、潛在面向槽數 A 、融合閘偏置 b 、對比權重 λ_{CL} 。各軸於其他設定固定為表 8 之值、種

子 = 42 下掃描。主結果中的最佳設定 ($\text{NDCG@20} = 0.1243$) 作為本節錨點，圖 4 總覽四個 sweep 的量測趨勢。




Figure 4: RA-GARK 在 NDCG@20 下對四個主要超參數之敏感性。

此圖作為趨勢檢視，而非第二份結果表；其重點在於各設計選擇於預設值附近是否穩定，而不是再多列一份排序摘要。

4.5.1 Softmax 溫度 τ

圖 4 之 τ 面板報告 $\tau \in \{0.05, 0.1, 0.5, 1.0\}$ 之 NDCG@20 。預設 $\tau = 0.5$ 仍為最佳設定，達 0.1243。銳化至 $\tau = 0.1$ 或 $\tau = 0.05$ 分別使 NDCG@20 降至 0.1219 與 0.1227；平坦化至 $\tau = 1.0$ 亦低於預設值。此圖像與第 3.4.3 節之分析一致： $\tau = 0.5$ 時槽 logit 被放大至足以產生鑑別性權重而不塌縮於單一槽。將 τ 向下推會使合理化更具選擇性，可能丟棄次要槽位之有用質量；將 τ 向上推則會使分布平坦化為跨槽之均勻平均。

4.5.2 面向槽數 A

圖 4 之 A 面板掃描 $A \in \{2, 3, 4, 6, 8\}$ ，並對應縮放 SVD 秩 $k = A \cdot d$ 。預設 $A = 4$ 取得最佳 NDCG@20 。較少槽數會不足以配置潛在 KG 幾何；較多槽數則會稀釋本已稀疏的物品一面向證據。因此本文保留 $A = 4$ 作為主結果所使用之設計預設。

4.5.3 融合開偏置 b

偏置掃描為目前已完成之敏感性實驗中最具資訊量者。圖 4 之 b 面板顯示 b 於 $\{0, +2, +5, +10\}$ 之 NDCG@20。預設 $b = +5$ 最佳。於 $b = 0$ (無區域偏置) 下模型損失 3.8% NDCG@20 (0.1196)， $b = +2$ 則回補大部分缺口 (0.1224, -1.5%)。於 $b = +10$ 下 $\sigma'(b)$ 已數值上小至開無法於訓練中適應，NDCG@20 降至 0.1175。此設計可運作之窗 $b \in (0, +10)$ 為窄；以 $b = +5$ 作為 $\alpha^{(0)} > 0.99$ 且 $\sigma'(b) > 10^{-3}$ 之最小整數 (第 3.5.5 節) 的選擇於此獲得實證驗證。

4.5.4 對比權重 λ_{CL}

圖 4 之 λ_{CL} 面板掃描 $\lambda_{\text{CL}} \in \{0, 0.001, 0.005, 0.01, 0.05\}$ 。預設 $\lambda_{\text{CL}} = 0.005$ 最佳；移除此輔助損失或將其加得過強，皆會降低 NDCG@20。這與表 11 與表 12 之元件消融一致：兩條對比通道提供較小但非零的增益，其角色是正則化而非主要整合機制。

4.5.5 結果穩定性

我們報告主結果對非本質之最佳化細節之穩健性。於架構與資料集切分固定、僅變動最佳化細節 (weight decay 開關、scheduler 開關、multi-negative sampling、額外之 $\mathcal{L}_{\text{kgCL}}$ 正則化) 之探索性實驗，皆落在所報 0.1243 的 ± 0.003 NDCG@20 內。本資料集之有效效能上限因此約為 0.124，且表 9 之方法排序與表 11、表 12 之消融效應排序於此誤差帶內均穩健。

資料集規模較小 (905 使用者、1,399 物品)，測試集變異之主要來源為使用者分層切分本身，而非最佳化隨機性。固定切分後即移除較大之變異來源；其後切分內殘餘變異約與我們所報較小消融效應之量級相當，並不影響第 4.3 與第 4.4 節所得之比較性結論。

4.6 個案研究與計算成本

為檢視合理化模組實際學到什麼，我們自訓練集中取樣 5 件熱門物品 (每件至少 3 條 KG 面向邊)，並記錄訓練完成之模型對其中三位互動使用者所產生之 Softmax 面向權重 $w_{u,i,k}$ 。正文以熱圖進行詮釋，精確數值則移至附錄保存。




Figure 5: 取樣使用者—物品配對之 Softmax 面向權重熱圖。

圖 5 呈現兩項明確之經驗模式，二者皆與一般對合理化模組所期望的強 per-(使用者, 物品) 選擇敘事不符。更重要的是，這裡看到的是物品條件化而非使用者條件化，這正是後文要展開的重點。

物品層級槽位專化 五件取樣物品之 argmax 槽各異（槽 1、槽 0、槽 1、槽 0、槽 3），主導槽承載一個小但穩定之質量超額（通常 0.27–0.29，其餘約 0.24）。合理化模組因此學得了物品條件之四槽偏好：不同物品將其 KG 貢獻路由至不同槽向，且該選擇於所有與該物品互動之使用者間穩定。

使用者條件選擇性 對任一物品，三位取樣使用者所產生之權重向量幾乎相同，物品內跨使用者之差異至多 ± 0.003 。Eq. (17) 之使用者條件化在結構上存在，但於訓練完成之模型中，使用者輸入對槽分布之擾動不超過量測雜訊。權重雖明顯高於主導槽上之均勻值，但並非使用者特定。

詮釋 此模式與第 3.1 節之設計原則一致而非衝突。融合閘以偏置初始化，使 KG 通道於訓練起點開啟約 0.7%，且整個訓練過程中僅佔分數之一小部分；表 11 與表 12 之消融顯示移除整個全域視角僅損失 1.9% NDCG@20，將合理化改為均勻平均僅損失 0.3%。回傳至合理化模組之梯度因而相應偏小，足以決定每件物品該用哪個槽（一個大小為 $|I| \times A$ 之物品層級選擇問題），但不足以在其之上再學得使用者特定之再加權，因後者需於緊縮 KG 貢獻下區分 $|U| \times |I| \times A$ 個槽權重。個案研究因此不應讀為合理化模組之失敗，而是優雅退化性質之直接證據：KG 通道僅學得開允許其影響損失之結

構量，而對純 LightGCN 之 5.3% 提升（表 9）因此可歸因於在 KG-SVD 初始化幾何之上的物品層級槽路由，而非 per-user 合理化指派。我們明確區分此點，俾後續於較稠密 KG 上使用合理化模組之工作（其中較寬閘原則上能允許使用者層級分化湧現）知曉應觀察何種訊號。

4.6.1 計算成本

於本文硬體上，RA-GARK 每 epoch 訓練牆鐘時間約 1.5 秒，與純 LightGCN（1.4 s）及匹配嵌入維度之 KGRec（1.5 s）幾乎不可區分。三者主導成本皆為 LightGCN 傳播 $O(|\mathcal{E}_{UI}| \cdot d \cdot K)$ ，RA-GARK 與 baseline 共享此項。KG 側額外項（面向槽讀取 $O(B \cdot A \cdot d)$ 、合理化遮罩 $O(B \cdot A \cdot d)$ 、兩個融合閘 $O(B \cdot d^2)$ ）在 $A = 4$ 、 $B = 128$ 下相對傳播甚小，已於第 3.6.4 節之複雜度表分析。

全項目推論主導於 per-user 之物品側合理化步驟，成本為 $O(|\mathcal{I}| \cdot A \cdot d)$ ；於本資料集（ $|\mathcal{I}| = 1,399$ 、 $A = 4$ 、 $d = 128$ ）此值遠在 GPU 記憶體預算內，對所有測試使用者計分每 epoch 不到一秒。RA-GARK 因此並非比所改進之 baseline 更昂貴；表 9 之增益來自設計選擇，而非更大之計算預算。

5 結論與未來工作

5.1 結論

本論文始於一個具體的經驗異常：在本文使用的稀疏評論衍生知識圖譜上，四個代表性 KG-aware 推薦器（KGAT、KGCL、MCCLK、KGRec）皆一致地敗給純 LightGCN（第 1 章，並於第 4.3 節重現）。我們主張，其共同的架構成因在於：這些 baseline 將 KG 視為計分管線中的強制元件，使 KG 嵌入直接參與訊息傳遞，卻缺乏在 KG 不可靠時將其脫接的結構性機制。原本期望作為語意訊號的雜訊，因此進入產生協同表示的同一條梯度流；當 KG 品質低於某個門檻時，這項交換便轉為淨負。

RA-GARK（第 3 章）則圍繞單一設計原則展開（第 3.1 節），亦即 KG 應作為一條旁路通道，其對最終分數的貢獻由可學習的閘決定；此閘在初始化時偏向安全預設（純協同過濾），只有當訓練訊號顯示 KG 通道能降低損失時才逐步打開。三項具體設計選擇落實此原則，並於第 4.4 節逐一衡量：

- **KG-SVD 初始化**為每件物品建立面向槽，使模型在訓練起點即保留面向誘導語意子空間的角度幾何。移除其代價為 6.0% NDCG@20。
- **Softmax 合理化遮罩**對 A 個潛在槽進行歸一化，編碼「使用者對某物品的偏好由少數互相競爭的語意面向主導」這一假設。將跨槽 Softmax 換為元素級 sigmoid 的代價為 19.2% NDCG@20，是本論文中單一元件影響最大者。
- **區域偏置融合閘**以純量偏置 $b = +5$ 初始化，使 $\alpha^{(0)} \approx 0.993$ ，因此 RA-GARK 的訓練起點本質上即為純 LightGCN。將其還原為 $b = 0$ 的代價為 3.7% NDCG@20。

三項齊備下，RA-GARK 於本基準上取得 $\text{NDCG@20} = 0.1242$ ，較最強 KG-aware baseline（KGRec）提升 +13.4%，較純 LightGCN 提升 +5.3%，且每 epoch 牆鐘成本基本相當（第 4.6.1 節）。其中 +5.3% 在方法論上更具意義：在同一筆資料上，四個既有 KG-aware 方法將 KG 訊號變成淨負擔，而 RA-GARK 的設計選擇則將其轉回淨助益。

因此，本論文可總結為一句話：當 KG 不可靠時，架構最需要的不是更好的 KG 聚合器，而是一個能將 KG 結構性脫接的開關。

本論文之價值，與其說在於具體數字，不如說在於此一重新定位：它將稀疏 KG 推薦的困難歸因於架構而非 KG 本身，在強制融合下成為負擔的同一個 KG，一旦其使用被設計為結構上可選，便能在不更動 KG 的前提下轉為助益。循此觀點，優雅退化（將輔助通道於初始化偏向安全預設、僅在訓練訊號足以支持時才開啟）是一種可重用的設計原則，用以整合任何事先無法保證可靠性之訊號，而非僅適用於評論衍生知識圖譜之特定手段。此原則能否推廣至本文所研究之單一稀疏基準以外，則為第 5.4 節所探討之經驗問題。

個案研究為上述論點補上定性證據。它顯示 RA-GARK 並非將 KG 當作被動的側特徵；合理化模組會依據 KG 所編碼之商品語意調節推薦，因此模型對某件商品的偏好，除了協同歷史外，也可由面向層級的內容加以解釋。換言之，本論文不僅說明在合適架構下 KG 能改善排序，也說明 KG 能作為語意訊號，改變推薦器區分不同商品的方式。

5.2 方法論啟示：注意力歸一化

本論文觀察到之單一元件最大影響並不在 RA-GARK 所貢獻之任何新架構元件，而在於推薦文獻中常被視為調參細節之選擇：合理化模組之注意力頭採用 Softmax（跨面向競爭）或 sigmoid（逐面向獨立）。於本基準上，僅將此單一模組之 Softmax 替換為 sigmoid 即損失 19.2% NDCG@20（第 4.4 節），達一般超參數調參之 1–3% 擺動的數倍。

推薦文獻對此選擇無共識。DIN [16] 對歷史物品採用 per-target sigmoid 注意力；NAIS [17]、AFM [18] 對特徵互動採用 Softmax 歸一化；KGRec [7] 採邊層級 Bernoulli 決策，結構上接近 sigmoid。此等選擇皆與其目標任務之語意內部一致。我們於第 4.6 節之個案研究檢視顯示，本設定下訓練完成之 Softmax 權重並非近 one-hot，而僅為軟尖峰（四槽中 $\max_k w_k \approx 0.28$ ），因此實際發揮作用之機制不可能為 one-hot 之競爭選擇。Softmax 提供而 sigmoid 不具之性質實為結構性者：權重和為 1 之歸一化使全域視角物品嵌入之模長無論 logit 尺度為何皆有界於 $\max_k \|\mathbf{a}_{i,k}\|$ ，而 sigmoid 所產生之模長則隨 logit 漂移。於 KG 通道刻意被融合閘節制（第 3.5.3 節）之設計中，將通道貢獻維持有界且可預測，正為閘之校準所依賴；sigmoid 引入之模長漂移即為我們所相信導致 19.2% 退化之原因。

我們將此定位為假說而非方法論主張。證據僅來自單一資料集，於其他資料集、其他被節制方式不同之架構上其效應大小與機制皆未知。此假說具體至足以由複製驗證證偽：當合理化式之注意力頭饋入一輔助通道，且其貢獻由融合閘約束為分數中一小

比例時，承載性之性質為該頭之模長控制（和為一之歸一化），而非 *one-hot* 競爭；以獨立 *sigmoid* 頭替換 *Softmax* 頭將以遠超一般超參數雜訊之幅度降低排序品質。若此於我們的設定之外仍成立，歸一化對競爭即成為合理化結構之顯式設計軸，而非調參細節。

5.3 限制

本論文之貢獻受三項限制所界定，我們明確陳述以避免主張範圍模糊。

單一稀疏基準 本論文所有量化結果皆於單一資料集上報告：Amazon Books 評論之一子集，含 905 位使用者、1,399 件物品，以及 2,098 個面向標籤上之 3,370 條物品一面向 KG 邊（第 4.1 節）。選擇此基準是因其展現本論文所動機之經驗異常，但並未主張 RA-GARK 之設計選擇可不變地轉移至其他推薦資料集或其他 KG 架構。特別是，核心觀察（純 LightGCN 勝過所測四個 KG-aware baseline）於 KG 較稠密、較經策劃、或與推薦訊號較對齊之資料集上未必成立。

稀疏 KG 情境 RA-GARK 是針對稀疏評論衍生 KG 所設計，亦即側資訊雖可提供語意，但其雜訊已高到使強制融合可能得不償失。正是在此情境下，區域偏置閘、KG-SVD 初始化與 *Softmax* 合理化遮罩才被校準並展現效果。在較稠密且較乾淨的 KG 情境中，同樣「預設 KG 關閉」的偏置可能過於保守，反而應考慮深度融合或 KG 優先之架構。

KG 建構來源 物品一面向 KG 本身由 [20] 之流程建構，結合視覺與文字編碼器（ResNet、Qwen-VL、BART、Mistral）以抽取評論衍生面向出現。我們直接採用此 KG，不對建構流程提出修改。本論文之貢獻完全位於建模面，視 KG 為固定輸入。

稠密 KG 驗證邊界 RA-GARK 為稀疏 KG 情境而設計並評估，此情境下 KG 訊號不可靠。我們不對其於 KG 稠密且準確時之行為作任何主張。在該情境（KGAT、KGIN 之傳統主場）「預設 KG 關閉」之偏置初始化閘正是錯誤之歸納先驗，而我們所批評之深度融合 baseline 反而可能為合適選擇。第 5.4 節討論閘應如何重新配置以處理對稱情境。

5.4 未來工作

由以上貢獻與限制，自然引出四個方向。

注意力歸一化發現之多資料集複製 第 5.2 節所表述之方法論假說具體至足以於其他合理化感知推薦基準、其他物品屬性架構、以及相鄰領域之合理化模組（順序推薦、對話式推薦）上測試。一次乾淨複製（固定資料集與模型其餘部分、僅切換合理化頭之歸一化）將使其自單一資料集觀察提升為一般設計指引，或銳化其成立之條件。

稠密 KG 驗證 如限制所提，RA-GARK 尚未於 KG 稠密且策劃良好之資料集上評估。自然之後續為將 RA-GARK 與 KG-aware baseline 並列執行於標準稠密 KG 基準（如 Amazon-Book / Last-FM 配 Freebase 衍生 KG）。預期結果為區域偏置融合閘優雅退化為與純 LightGCN 加小幅 KG 貢獻相當之行為而不崩壞；至於 RA-GARK 是否於該情境匹配深度融合 baseline，為一個值得回答之經驗問題。

閘控原則之跨領域轉移 區域偏置融合閘背後之架構原則（於初始化偏向安全預設、僅在訓練訊號指示輔助通道能降低損失時打開）並不專屬於 KG-aware 推薦。同樣構造原則上可轉移至任何主訊號穩健、輔助訊號高變異之情境：含側資訊之冷啟動、單一模態雜訊時之多模態融合、異質預測器之集成式後期融合。我們所觀察之核心效應是否能在等轉移下倖存，為開放問題。

反向稀疏情境：CF 稀疏配 KG 稠密 本論文所研究情境之對稱反面，為使用者—物品互動圖稀疏（如冷啟動、新使用者、新領域）而 KG 稠密可靠之情況。彼時閘所應編碼之安全預設與本文所用者相反：LightGCN 此時為不可靠之一側，KG 衍生之全域視角應為預設打開之通道。此為 KGAT、KGIN 等稠密 KG 工作之傳統設定；本文分析暗示於初始化偏向安全預設此項設計動作可跨兩情境轉移，而偏置之具體方向則由資料集決定。

具體而言，將 RA-GARK 改造至此情境需三項協同變更：融合偏置應自 +5 翻轉為負值，使 KG 通道預設打開；KG-SVD 之角色可能由初始化轉為主要推論路徑；區域視角則可能需要不同之正則化，方能於互動訊號稀少時維持有用。對反向情境之完整架構處理需同時重新設計區域視角與閘方向性，留待後續研究。

Bibliography

- [1] X. He, K. Deng, X. Wang, Y. Li, Y. Zhang, M. Wang, LightGCN: Simplifying and powering graph convolution network for recommendation, in: Proc. ACM SIGIR, 2020, pp. 639–648.
- [2] X. Wang, X. He, M. Wang, F. Feng, T.-S. Chua, Neural graph collaborative filtering, in: Proc. ACM SIGIR, 2019, pp. 165–174.
- [3] J. Wu, X. Wang, F. Feng, X. He, L. Chen, J. Lian, X. Xie, Self-supervised graph learning for recommendation, in: Proc. ACM SIGIR, 2021, pp. 726–735.
- [4] X. Wang, X. He, Y. Cao, M. Liu, T.-S. Chua, KGAT: Knowledge graph attention network for recommendation, in: Proc. ACM SIGKDD, 2019, pp. 950–958.
- [5] Y. Yang, C. Huang, L. Xia, C. Li, Knowledge graph contrastive learning for recommendation, in: Proc. ACM SIGIR, 2022, pp. 1434–1443.
- [6] D. Zou, W. Wei, X.-L. Mao, Z. Wang, M. Qiu, F. Zhu, X. Cao, Multi-level cross-view contrastive learning for knowledge-aware recommender system, in: Proc. ACM SIGIR, 2022, pp. 1358–1368.
- [7] Y. Yang, C. Huang, L. Xia, C. Huang, Knowledge graph self-supervised rationalization for recommendation, in: Proc. ACM SIGKDD, 2023, pp. 3046–3056.
- [8] X. Ren, L. Xia, J. Zhao, D. Yin, C. Huang, Disentangled contrastive collaborative filtering, in: Proc. ACM SIGIR, 2023, pp. 1137–1146.
- [9] A. van den Oord, Y. Li, O. Vinyals, Representation learning with contrastive predictive coding, arXiv preprint arXiv:1807.03748 (2018).
- [10] R. K. Srivastava, K. Greff, J. Schmidhuber, Highway networks, arXiv preprint arXiv:1505.00387 (2015).

- [11] J. Ma, Z. Zhao, X. Yi, J. Chen, L. Hong, E. H. Chi, Modeling task relationships in multi-task learning with multi-gate mixture-of-experts, in: Proc. ACM SIGKDD, 2018, pp. 1930–1939.
- [12] H. Tang, J. Liu, M. Zhao, X. Gong, Progressive layered extraction (PLE): A novel multi-task learning (MTL) model for personalized recommendations, in: Proc. ACM RecSys, 2020, pp. 269–278.
- [13] Z. Wang, G. Lin, H. Tan, Q. Chen, X. Liu, CKAN: Collaborative knowledge-aware attentive network for recommender systems, in: Proc. ACM SIGIR, 2020, pp. 219–228.
- [14] H. Wang, F. Zhang, M. Zhao, W. Li, X. Xie, M. Guo, Multi-task feature learning for knowledge graph enhanced recommendation, in: Proc. The Web Conference (WWW), 2019, pp. 2000–2010.
- [15] X. Wang, T. Huang, D. Wang, Y. Yuan, Z. Liu, X. He, T.-S. Chua, Learning intents behind interactions with knowledge graph for recommendation, in: Proc. The Web Conference (WWW), 2021, pp. 878–887.
- [16] G. Zhou, X. Zhu, C. Song, Y. Fan, H. Zhu, X. Ma, Y. Yan, J. Jin, H. Li, K. Gai, Deep interest network for click-through rate prediction, in: Proc. ACM SIGKDD, 2018, pp. 1059–1068.
- [17] X. He, Z. He, J. Song, Z. Liu, Y.-G. Jiang, T.-S. Chua, NAIS: Neural attentive item similarity model for recommendation, IEEE Transactions on Knowledge and Data Engineering 30 (12) (2018) 2354–2366.
- [18] J. Xiao, H. Ye, X. He, H. Zhang, F. Wu, T.-S. Chua, Attentional factorization machines: Learning the weight of feature interactions via attention networks, in: Proc. International Joint Conference on Artificial Intelligence (IJCAI), 2017, pp. 3119–3125.
- [19] S. Rendle, C. Freudenthaler, Z. Gantner, L. Schmidt-Thieme, BPR: Bayesian personalized ranking from implicit feedback, in: Proc. Conference on Uncertainty in Artificial Intelligence (UAI), 2009, pp. 452–461.
- [20] I.-N. Ho, Llm-enhanced multimodal product recommendation with review aspect-specific knowledge graphs, Master’s thesis, Institute of Information Management, National Yang Ming Chiao Tung University (2024).