

稀疏知識圖譜下基於理由感知閘控的雙視角推薦架構

學生：預覽用

指導教授：預覽用 博士

國立陽明交通大學
資訊學院碩士在職專班

摘要

知識圖譜感知 (KG-aware) 推薦系統將商品語意引入圖式協同過濾，當知識圖譜 (KG) 稠密且品質良好時，普遍能有效提升推薦準確性，相關方法已蓬勃發展。然而當 KG 本身稀疏或品質不佳時——此即評論衍生、冷啟動、隱私受限等現實場景下的常態——既有研究的探討相當有限。本文以書評衍生 KG 為例（過濾後每件商品平均僅 2.4 條邊），觀察到四個代表性 KG-aware 方法 (KGAT、KGCL、MCCLK、KGRec) 皆不及完全不使用 KG 的純 LightGCN。共同結構原因在於：這些方法皆將 KG 訊號作為計分管線之必經成分，缺乏在 KG 不可信時將其切斷或弱化的機制，因此 KG 雜訊一併被融入產生協同表示的梯度流。

為解決此一問題，本文提出 RA-GARK (Rationale-Aware Gating over Review-Aspect Knowledge graphs)，一個雙視角推薦架構，將 KG 視為可被閘控之側通道而非必經元件。核心設計為一個本地偏置融合閘 (local-biased fusion gate)：當使用者—商品互動圖與 KG 進行合併考量時，閘根據每組 (使用者, 商品) 配對動態調整兩條訊號的相對權重，使模型能依情況彈性適應——KG 對該配對具資訊量時加大其貢獻，反之則退回以協同訊號為主，藉此提升預測分數與推薦效果。融合閘之偏置初始化為 +5，使訓練起點實質等同於純 LightGCN，僅在梯度顯示 KG 有益時才逐步開啟，提供結構性的優雅退化保證。除此之外，本文以四個潛在面向槽 (latent aspect slots) 儲存每件商品之 KG 語意——槽位數 $A = 4$ 為模型設計參數，與每件商品所擁有之原始面向標籤數無關；其內容由 IDF 加權商品—面向共現矩陣之截斷 SVD 投影而得，跨全體商品共同學習語意子空間，並透過 softmax 注意力依 (使用者, 商品) 配對挑選最具顯著性的潛在面向。

在稀疏書評衍生 KG 之實驗設定下，RA-GARK 於 NDCG@20 達到 0.1238，較最強 KG-aware 基準 KGRec 提升 13.1%，並較純 LightGCN 提升 5.0%。後者顯示：所提之動態權重調整機制能在 KG 本身不變的情況下，將其貢獻自「無益」翻轉為「有益」。元件式消融顯示，softmax 注意力若被替換為 sigmoid 將造成 7.0% 之 NDCG 下降；偏置初始化融合閘與 KG-SVD 初始化則各貢獻 5.3%。本文另提出關於注意力歸一化之方法論

觀察作為待驗證假說，並明確指出該觀察目前僅有單一資料集支持，需多資料集複現方能升格為通用結論。

關鍵字：知識圖譜推薦；可退化機制；理由感知學習；融合閘；稀疏知識圖譜；注意力歸一化；協同過濾

Rationale-Aware Gating over Review-Aspect Knowledge Graphs for Recommendation under Sparse KG

Student : Preview

Advisor: Dr. Preview

Degree Program of Computer Science
National Yang Ming Chiao Tung University

Abstract

Knowledge-graph-aware (KG-aware) recommender systems augment graph collaborative filtering with item-side semantics drawn from a knowledge graph (KG); on dense, high-quality KGs they generally improve recommendation accuracy, and the regime is well studied. The setting in which the KG itself is sparse or unreliable—which is the practical default for review-derived KGs, cold-start domains, and privacy-constrained applications—has, by contrast, received little dedicated attention. On a sparse review-derived KG (with on average 2.4 aspect edges per item after filtering), we observe that four representative KG-aware methods (KGAT, KGCL, MCCLK, and KGRec) are uniformly outperformed by pure LightGCN that does not consult the KG at all. The shared structural cause is that each method injects KG signal into the scoring path as a mandatory component, with no mechanism to disengage or attenuate when the KG is unreliable; KG noise therefore contaminates the gradient flow that produces the collaborative representation.

To address this gap, this thesis proposes RA-GARK (Rationale-Aware Gating over Review-Aspect Knowledge graphs), a dual-view recommendation architecture that treats the KG as an explicitly gated side channel rather than a mandatory pipeline component. Its core design is a local-biased fusion gate: when the user–item interaction graph and the KG are jointly considered, the gate dynamically adjusts the relative weight of the two signals per (user, item) pair, allowing the model to adapt flexibly—amplifying the KG when it is informative for that pair, and falling back to the collaborative signal when it is not, thereby improving the predicted score and the resulting recommendation. The gate’s bias is initialized to +5, so that training begins as effectively pure LightGCN and the KG channel is opened only when gradients indicate it helps, providing a structural graceful-degradation guarantee. Two further design choices support this gating principle. Each item’s KG semantics are stored in $A = 4$ *latent* aspect slots (a model hyperparameter, independent of how many raw aspect tags any individual item

carries); the slot contents are obtained by a truncated SVD of an IDF-weighted item–aspect co-occurrence matrix, which projects all items into a shared latent semantic subspace and serves as the optimization starting point. A softmax aspect-saliency attention then selects, per (user, item) pair, the most salient latent slot to participate in the global view.

On the sparse review-derived KG benchmark, RA-GARK reaches $\text{NDCG@20} = 0.1238$, exceeding the strongest KG-aware baseline (KGRec) by +13.1% and pure LightGCN by +5.0%. The latter demonstrates that the proposed dynamic weighting mechanism flips the contribution of KG signal from net-negative to net-positive even when the KG itself is unchanged. Component-wise ablations show that replacing softmax with sigmoid attention costs 7.0% NDCG@20 , while removing the bias-initialized fusion gate or the KG-SVD initialization each costs 5.3%. We additionally report a single-dataset methodological observation that the choice of attention normalization should align with the semantic assumption of the rationale, and explicitly frame this as a hypothesis pending multi-dataset replication rather than a general claim.

Keywords: knowledge-graph-aware recommendation; graceful degradation; rationale-aware learning; fusion gate; sparse knowledge graph; attention normalization; collaborative filtering.

Contents

1	緒論	1
1.1	研究背景	1
1.2	稀疏 KG 下的經驗異常現象	1
1.3	稀疏 KG 作為現實世界的常態	2
1.4	研究問題	2
1.5	研究貢獻	3
1.6	論文組織	4
2	相關研究	5
2.1	基礎：LightGCN 與 KGAT	5
2.2	對比式知識圖譜方法	6
2.3	合理化感知推薦：KGRec	6
2.4	合理化典範：共同前提與分歧的可信度假設	7
2.5	深度學習中的閘控機制	8
2.6	缺口：KG-Aware 推薦中沒有融合閘	8
2.7	注意力正規化	9
2.8	總結與 RA-GARK 的定位	10
3	方法	11
3.1	設計原則：KG 作為可被閘控的旁路通道	11
3.2	架構概覽	12
3.3	符號	13
3.4	問題定式	13
3.5	模組摘要	14

Chapter 1

緒論

1.1 研究背景

圖神經網路 (GNN) 已成為協同過濾的主流架構選擇。其中，LightGCN [1] 證明了只要移除 GCN 中的非線性激活與特徵變換、僅保留線性鄰居聚合，便足以在標準推薦基準上超越如 NGCF [2] 等更深層的方法。LightGCN 的簡潔與穩定使其成為一個強大且參數高效的骨幹，而後續方法如 SGL [3] 則在其上疊加額外的自監督目標。

另一條互補的研究路線——知識圖譜感知推薦 (KG-aware recommendation) ——以知識圖譜 (KG) 所編碼的物品端語意來擴充協同訊號。具代表性的方法包括：KGAT [4]，在統一的使用者—物品—實體圖上傳播訊息；KGCL [5] 與 MCCLK [6]，透過對比學習對齊 KG 視角與協同視角；以及 KGRec [7]，引入邊層級的合理化 (rationalization) 機制以辨識哪些 KG 三元組對推薦負責。當 KG 稠密且品質良好時，這類方法皆能穩定地超越純協同基線。

1.2 稀疏 KG 下的經驗異常現象

本研究的起點是一個促使整篇論文展開的經驗觀察。在本研究所使用的、由評論衍生而來的 KG 資料集 (Amazon Books 子集，經篩選後每件物品平均僅有 2.4 條 aspect 邊) 上，前述四種具代表性的 KG-aware 方法全部都被完全不參考 KG 的純 LightGCN 所超越。表 1 摘要呈現此一差距。

我們並非主張上述四種基線本身有缺陷——它們在其原始論文所報告的稠密 KG 資料集上表現皆十分強勁。此觀察反映的，是深度 KG-CF 耦合所共同具有的一種失效模式：當 KG 過於稀疏或雜訊過多以致無法提供可靠的物品語意時，將其直接融入評分路

Table 1: 在我們的稀疏評論型 KG 上，代表性 KG-aware 方法之 NDCG@20 表現，並與純 LightGCN 對照。四種 KG-aware 方法皆不及不使用 KG 的基線。

方法	NDCG@20
MCCLK [6]	0.1067
KGCL [5]	0.1073
KGAT [4]	0.1079
KGRec [7]	0.1095
純 LightGCN [1] (未使用 KG)	0.1179

徑會使 KG 雜訊污染本可產生純淨協同訊號的梯度流。

1.3 稀疏 KG 作為現實世界的常態

一個自然的反駁是：將此一經驗異常視為資料集的特殊性，並透過更精緻地策劃稠密 KG 或進行 KG 補全 (completion) 來填補缺失邊即可。然而，我們主張，稀疏 KG 才是實務推薦系統中更常見的情境，因此「在 KG 訊號不可靠時依然穩健」這項性質本身就值得專門研究，而非以工程繞道方式迴避。

實務上有三個常見的稀疏來源。其一，評論衍生型 KG——如本研究所使用者——其密度繼承自使用者實際提及的主題；覆蓋本質上即不均勻。其二，冷啟動與新興領域——新品類、低資源語言、利基垂直市場——通常無法取得如 Freebase 或 Wikidata 等等級的人工策劃資源，KG 必須從有限訊號中自舉而來。其三，隱私受限領域，如醫療或金融推薦，刻意限制可暴露給模型的關聯訊號。在以上三種情境中，激進的 KG 補全本身亦非易事：補全會引入新的雜訊，且通常需要足夠的種子訊號才能訓練——而這恰恰是稀疏情境中所欠缺的。

由此推論，推薦器在 KG 不可靠時的穩健性，至少和它在 KG 稠密時的峰值效能同等重要。本論文以此穩健性作為主要設計目標。

1.4 研究問題

上述經驗異常與稀疏 KG 情境的實務重要性，引出兩個研究問題：

- (RQ1, 診斷) 為何既有 KG-aware 方法在稀疏 KG 下不及純 LightGCN？它們所共同具備的結構性失效模式為何？

- (RQ2, 處方) 何種設計原則能讓模型在 KG 訊號有效時加以利用，而在訊號無效時避免 KG 雜訊污染協同過濾？

本論文的主張是：KG 不應如 KGAT 式深度融合那般，成為評分管線中的必要組件，而應作為一條可依其訊號是否有效而被明確開控的旁路通道。具體而言，此原則由三項設計選擇實現：以 softmax 為基礎的 aspect-saliency 注意力，用於對每組使用者—物品配對選取 KG 合理化依據；以 KG 驅動的 SVD 初始化，用以保留語意幾何；以及具有局部偏置的融合閘（local-biased fusion gate），其初始化內建了當 KG 訊號終究不具資訊量時優雅退化回純 LightGCN 的能力。

1.5 研究貢獻

本論文之主要貢獻如下：

1. **經驗性研究**：證明在稀疏評論型 KG 下，四種具代表性的 KG-aware 方法（KGAT、KGCL、MCCLK、KGRec）皆一致地被純 LightGCN 超越。我們將此歸因於這些方法缺乏一個能於 KG 不可靠時將其脫接的架構機制。
2. **RA-GARK，一個雙視角架構**：以旁路通道而非深度融合的方式整合協同訊號與 KG 衍生訊號。RA-GARK 由三項核心要素組成，且彼此皆獨立必要：
 - **Softmax aspect-saliency 注意力**（第 ?? 節）。每件物品的 KG 語意儲存於 $A = 4$ 個潛在面向槽中——此槽位數為模型設計參數，與每件物品所擁有的原始面向標籤數無關——槽位內容由 IDF 加權商品—面向共現矩陣之截斷 SVD 投影而得；softmax 正規化的注意力為給定的使用者—物品配對選取最足以代表該物品的潛在槽位。將 softmax 改為 sigmoid 會使 NDCG@20 下降 7.0%，是我們所觀察到單一元件影響最大者。
 - **具局部偏置的融合閘**（第 ?? 節）。融合閘以 +5 的正偏置初始化，使 $\alpha^{(0)} \approx 0.993$ 。因此模型在訓練之初幾乎等同於純 LightGCN，僅當梯度顯示 KG 通道有幫助時，閘門才會被打開。此設計提供了四種基線所缺乏的、結構性的優雅退化保證。若移除此偏置初始化，NDCG@20 會損失 5.3%。
 - **KG-SVD 初始化**（第 ?? 節）。aspect 槽位的嵌入由 IDF 加權的物品—aspect 矩陣之截斷 SVD 初始化而來，將 KG 的語意幾何保留為最佳化的起點。將其換為隨機初始化會損失 5.3% NDCG@20。

3. **經驗驗證**：在稀疏評論型 KG 基準上，RA-GARK 達到 $\text{NDCG@20} = 0.1238$ ，較最強的 KG-aware 基線 (KGRec) 高出 +13.1%，更重要的是，較純 LightGCN 也高出 +5.0%。後者的差距顯示，所提出的設計原則能在 KG 本身不變的情況下，把 KG 訊號的貢獻由淨負（四種基線之情況）翻轉為淨正。
4. **關於合理化感知設計中注意力正規化的方法論觀察**。在我們的情境中，softmax 與 sigmoid 之間異常顯著的差距，暗示正規化的選擇應與合理化的語意假設相一致。我們將此視為單一資料集上的假設而非通用主張，留待後續多資料集複製驗證（第 ?? 章）。

1.6 論文組織

本論文後續組織如下。第 ?? 章從四個面向回顧相關文獻：圖協同過濾、KG-aware 推薦、深度學習中的閘控機制，以及注意力正規化。第 ?? 章呈現 RA-GARK 的整體架構並形式化推薦問題。第 ?? 章詳述各模組，包括區域視角、含兩項創新（KG-SVD 初始化與 softmax aspect-saliency 注意力）的全域 KG 視角、具局部偏置的融合閘，以及跨視角對比正則化。第 ?? 章報告實驗結果、消融研究、敏感性分析與個案研究。第 ?? 章討論關於注意力正規化的方法論啟示，承認單一資料集驗證與種子敏感性的限制，並作結。

Chapter 2

相關研究

本章從四個面向回顧先前研究，這些面向共同促成 RA-GARK 的設計。第 2.1 節介紹我們區域與全域視角所立足的兩項基礎：作為協同過濾骨幹的 LightGCN，與作為深度 KG-CF 融合典範的 KGAT。第 2.2 節回顧那些在不明確閘控下對齊協同與 KG 視角的對比式 KG 方法。第 2.3 節討論與本工作最為相關的合理化感知方法 KGRc，第 2.4 節則以「KG 可信度」為視角，對比我們與 KGRc 的合理化典範。第 2.5 與 2.6 節廣泛回顧深度學習中的閘控機制，並觀察到既有 KG-aware 方法皆未採用融合閘以提供架構層級的優雅退化。第 2.8 節總結 RA-GARK 相對於上述工作的定位。

2.1 基礎：LightGCN 與 KGAT

LightGCN [1] 是本研究區域視角的直接前身。建立於「NGCF [2] 中的非線性特徵變換對推薦準確率貢獻甚微」這項觀察上，LightGCN 將圖卷積網路精簡至最小骨幹：在使用者—物品二部圖上進行正規化的鄰居聚合 $\mathbf{E}^{(\ell+1)} = \tilde{\mathbf{A}}\mathbf{E}^{(\ell)}$ ，最終嵌入則取各層平均 $\bar{\mathbf{E}} = \frac{1}{K+1} \sum_{\ell=0}^K \mathbf{E}^{(\ell)}$ 。此一簡化在標準推薦基準上一致地優於 NGCF，且訓練更快、更穩定。其後諸多自監督方法，如 SGL [3] 與 DCCF [8]，皆在 LightGCN 式骨幹之上疊加額外的對比目標。

在 RA-GARK 中，我們原封不動採用 LightGCN ($K = 2$) 作為區域視角：此分支內不施加任何 KG 相關運算。動機有二。其一，在我們的稀疏評論型 KG 上，純 LightGCN 已達 $\text{NDCG}@20 = 0.1179$ ，超越所有我們所評估的 KG-aware 基線。任何偏離此強預設的設計，皆須可被證實能改善而非劣化結果——這是本論文反覆訴諸的硬性設計約束。其二，將 KG 訊號隔離至獨立的全域視角（第 ?? 章），可避免 KG 雜訊污染協同表示的梯度流。

KGAT [4] 代表 KG-aware 推薦中的典範深度融合做法。KGAT 將使用者—物品互動圖與知識圖譜合併為一個協同知識圖 (Collaborative Knowledge Graph, CKG)，並以雙交互聚合器於此統一結構上傳播訊息。KG 實體嵌入因而直接參與使用者與物品表示的形成。當 KG 稠密且品質良好時，此設計相對於 CF 基線可取得顯著提升。

此處的隱含假設是 KG 可被信任，能在傳播路徑所及之處皆注入有用訊號。在我們的稀疏情境下此假設崩解：KGAT 僅達 $\text{NDCG}@20 = 0.1079$ ，低於純 LightGCN。其後續工作 [5, 6, 7] 沿用 KGAT 式聚合器，因此也繼承相同的脆弱性。RA-GARK 反轉此一設計選擇：我們完全不將 KG 與使用者—物品圖合併，而是將 KG 訊號導入一條專用旁路通道，當 KG 被證實不可靠時模型可衰減甚至全然脫接之。

2.2 對比式知識圖譜方法

KGCL [5] 對 KG 引入關係層級的結構擾動，並以 InfoNCE [9] 對比目標對齊擾動版本與原始版本。直覺是：具資訊量的 KG 結構應對隨機擾動具有不變性，而雜訊邊則不應。KGCL 在稠密 KG 情境下顯著優於 KGAT。然而在我們的稀疏情境中，擾動後的 KG 保留的邊過少，對比目標無法提供可靠監督： $\text{NDCG}@20$ 降至 0.1073。

MCCLK [6] 將對比對齊擴展至三個視角——協同、語意與結構——並對三者兩兩施加對比損失。雖然此多視角設計在稠密 KG 基準上取得 SOTA，但同樣繼承稠密 KG 的假設：在稀疏 KG 下，三個視角中有兩個（語意與結構）訊號不足，對比對齊淪為由雜訊主導而非由結構主導的正則化 ($0.1067 \text{NDCG}@20$)。

RA-GARK 同樣納入跨視角對比學習，但其角色刻意受限。我們的對比損失 ($\mathcal{L}_{\text{aCL}}$ 與 $\mathcal{L}_{\text{uCL}}$ ，第 ?? 節) 僅作為小權重 ($\lambda = 0.005$) 的輔助幾何正則化項，並關鍵地在 KG 側施加 stop-gradient，使對比梯度從不反向傳遞至 SVD 初始化的 aspect 嵌入。相較於 KGCL/MCCLK，此處的對比學習是表層的對齊層，而非主要的融合機制；協同與 KG 訊號的實際整合，是由一個明確的閘所執掌 (第 2.5 節)。

2.3 合理化感知推薦：KGRec

KGRec [7] 是與本工作最直接相關的研究。它是第一個將合理化選擇明確化的 KG-aware 推薦器：KGRec 不將每條 KG 三元組視為同等具資訊量，而是對每條 KG 邊計算一個基於注意力的重要性分數，並以 Bernoulli dropout 隨機移除高注意力邊，迫使模型不依賴少數主導邊；其穩健性接著由原始圖與被丟邊版本之間的對比目標來強化。整套合理化機制建立於 KGAT 式聚合器之上，因此合理化作用於使用者—物品—實體統

一圖的訊息傳遞路徑之內。在我們的稀疏基準上，KGRec 取得 $\text{NDCG}@20 = 0.1095$ ，為四個 KG-aware 基線中最強者，但仍低於純 LightGCN。

RA-GARK 在精神上採納合理化感知典範，但在結構上多處與 KGRec 有別，下節詳述之。

2.4 合理化典範：共同前提與分歧的可信度假設

KGRec [7] 與 RA-GARK 都認同「並非所有 KG 邊都對推薦同等貢獻、需要明確的選擇機制」這項觀察。然而二者對 KG 整體可信度所作的假設有所不同，此一假設並蔓延至各自分歧的設計選擇。

KGRec 的隱含假設是：具資訊量的邊存在於 KG 中，因此合理化任務簡化為將其找出；隨機 dropout 配合對比學習已足以辨識並放大有用子集。KG 整體作為證據體系被假定為可靠的，僅是個別邊的權重需被調整。

RA-GARK 的前提較弱。我們不假設 KG 整體是可靠的。aspect-saliency softmax（第 ?? 節）在 KG 具資訊量時選取合理化依據，但具局部偏置的融合閘（第 ?? 節）可在閘的梯度顯示無益時，另外地脫接整條 KG 通道。此可信度差異展現於四項設計分歧上：

- **合理化粒度。** KGRec 在邊（KG 三元組）層級進行選擇。RA-GARK 將每件物品的 KG 語意聚合為 $A = 4$ 個潛在面向槽——槽位內容由 IDF 加權商品—面向共現矩陣之截斷 SVD 投影得到——並在槽位層級進行選擇。此槽位數為模型設計參數，與每件物品所擁有的原始面向標籤數無關；粒度雖較邊層級選擇為粗，但直接產生可解讀的每物品 aspect 偏好。
- **選擇機制。** KGRec 採用離散 Bernoulli dropout 配合對比學習。RA-GARK 採用可微分的 softmax 注意力，能端到端訓練，並將推論期的權重作為可解釋性產物外露。
- **作用位置。** KGRec 在 KGAT 訊息傳遞路徑之內施加合理化；合理化與聚合糾纏在一起。RA-GARK 將合理化置於與 LightGCN 區域視角分離的旁路通道，僅於後期由閘將兩者結合。
- **對 KG 可信度的處理。** KGRec 沒有任何架構機制可脫接 KG。RA-GARK 的偏置初始化融合閘正提供此一機制：訓練起始時 $\alpha^{(0)} \approx 0.993$ ，模型實質上即為純 LightGCN；唯當學習顯示 KG 通道能降低損失時，閘才會被打開。

因此我們不將 RA-GARK 定位為對 KGRec 的工程性改良，而是基於對 KG 可信度不同前提之另一種設計。此一區別在經驗上是否重要，則於第 ?? 章中作答。

2.5 深度學習中的閘控機制

RA-GARK 的融合閘有兩個 KG-aware 推薦之外的近親，二者皆啟發本研究設計。

Highway Networks [10] 引入可學習的閘 $T(\mathbf{x})$ ，於變換訊號 $H(\mathbf{x})$ 與恆等跳接間進行插值： $\mathbf{y} = T(\mathbf{x}) \cdot H(\mathbf{x}) + (1 - T(\mathbf{x})) \cdot \mathbf{x}$ 。其關鍵設計選擇為對 T 的負偏置初始化：訓練之初 $T \approx 0$ ，網路表現為恆等映射。其後訓練僅在變換有益處之處才打開閘門。此設計原本是為了應對極深網路訓練的困難，但「將閘偏置至已知安全的預設，僅在學習認為合理時才覆寫」此結構性樣式，遠遠超出深度的脈絡而具有普適性。RA-GARK 將此樣式由網路內跳接移植至雙視角融合：融合閘上的 +5 偏置扮演與 Highway 之負偏置相同的角色，對 KG 通道提供優雅退化保證。

專家混合 (Mixture-of-Experts) 閘控，以多任務推薦中的 MMoE [11] 與 PLE [12] 為代表，以閘控網路對多個專家塔加權。雖然概念上類似多管線選擇，但兩項重要性質與 RA-GARK 不同。其一，MMoE/PLE 中的專家為同質候選者——皆為相同架構、僅以任務特定目標訓練的實例——因此並無「某專家本質上比另一者較不可靠」的概念。其二，這些架構中的閘採對稱初始化（訓練起始不偏向任何特定專家），適用於對稱專家情境，但不適用於我們不對稱的情境——在我們的設定中，一條通道 (LightGCN) 已知是強預設，另一條 (KG) 已知有時並不具資訊量。

另有一條工作線是對比式雙視角推薦器，例如 SGL [3] 與 DCCF [8]，這類方法以擾動單一圖（邊 dropout、節點 dropout、隨機漫步）來建構多個視角。此類方法中兩個視角位於相同訊號空間，對比對齊已足以整合二者。RA-GARK 的兩個視角則在結構上異質：區域視角為使用者—物品二部圖，全域視角為物品—aspect 的 KG。僅靠對比學習進行隱式對齊，無法調整兩個異質訊號空間的相對權重；明確的閘是必要的。

2.6 缺口：KG-Aware 推薦中沒有融合閘

儘管閘控在深度學習中已相當成熟，我們所調研的 KG-aware 推薦文獻中，未見任何方法將融合閘作為協同訊號與 KG 訊號之間的整合機制。表 2 摘要了四個被基準測試的基線與另外三個知名 KG-aware 方法 (CKAN [13]、MKR [14]、KGIN [15]) 所採用的整合機制。在這個集合中，KG 訊號是透過直接實體傳播、對比對齊、邊層級 dropout、

注意力、跨特徵單元或意圖解耦模組來整合。沒有任何機制允許 KG 通道在訊號不可靠時被結構性地脫接。

Table 2: 代表性 KG-aware 推薦器所採用的整合機制。皆未提供在不可靠 KG 下的架構優雅退化能力。

方法	KG 整合機制	可脫接？
KGAT [4]	直接實體訊息傳播	否
KGCL [5]	擾動 KG 對比學習	否
MCCLK [6]	多視角對比對齊	否
KGRec [7]	邊層級 dropout + KGAT 聚合器	否
CKAN [13]	協同—知識注意力	否
MKR [14]	跨特徵轉移單元	否
KGIN [15]	KG 上的意圖解耦	否
RA-GARK (本研究)	偏置初始化的融合閘	是

我們刻意作出一個範圍狹義的主張。我們不主張 RA-GARK 是 KG-aware 推薦中首個使用「任何閘」的方法，因 KG-aware 文獻浩繁，無法窮舉列舉。可辯護的主張為：在我們所檢視的方法中，沒有任何一個以偏置初始化的融合閘於稀疏或不可靠 KG 下提供架構優雅退化。我們在第 ?? 章的消融將 5.3% NDCG@20 的貢獻明確歸因於此閘的偏置初始化，支持上述主張在此情境中並非微不足道。

2.7 注意力正規化

一個橫跨多領域的相關問題是：在選擇合理化依據時，應對注意力權重套用 sigmoid 或 softmax？文獻並未匯聚於單一答案。DIN [16] 對使用者行為歷史套用 sigmoid 注意力，所基於的假設是每筆歷史行為與候選物品的相關性彼此獨立。NAIS [17] 對歷史互動套用 softmax 注意力以衡量物品相似度，AFM [18] 則對特徵交互套用 softmax。各工作中的選擇皆以其注意力所依附的語意假設為依據。

我們在第 ?? 章報告一項單一資料集的觀察：對於我們的 aspect-saliency 合理化，將 softmax 替換為 sigmoid 會損失 7.0% NDCG@20——這是我們所量測到單一元件影響最大者。我們將其解讀為支持「正規化應與合理化的語意假設相符」此一設計啟發，但明確將此觀察定位為待多資料集複製驗證的假設（第 ?? 章）。

2.8 總結與 RA-GARK 的定位

表 3 從四個設計面向匯整比較。在我們稀疏基準上所評估的方法中，RA-GARK 是唯一同時將純 LightGCN 區域聚合器與閘控後期融合的 KG 訊號相結合者，也是唯一將合理化作用於物品—aspect 粒度而非 KG 邊粒度者。

Table 3: 從四個面向所作的設計比較。NDCG@20 於我們的稀疏評論型 KG 基準上報告。

方法	區域聚合器	KG 整合	合理化	NDCG@20
KGAT	雙交互	直接傳播	—	0.1079
KGCL	KGAT 式	傳播 + CL	—	0.1073
MCCLK	多視角	多視角 CL	—	0.1067
KGRec	KGAT 式	傳播 + 邊 dropout	邊 Bernoulli	0.1095
RA-GARK	純 LightGCN	閘控後期融合	Aspect softmax	0.1238

我們並不將 RA-GARK 定位為相對於四個基線的嚴格改進。RA-GARK 在設計空間中佔據一個不同的位置——其特徵在於將 KG 視為可被明確閘控的旁路通道，而非必要的管線組件。此選擇在我們的稀疏 KG 情境中產出強勁結果，而基於閘控的優雅退化性質，在 KG 品質不均或模型部署於 KG 密度差異各異的多個領域時，或許亦能派上用場。然而，當 KG 稠密且品質一致地可靠時，KGAT 或 KGRec 這類深度融合方法可能仍較佳，因為後期融合的設計犧牲了深度融合架構所具有的部分表徵表達力。

Chapter 3

方法

本章從架構層次呈現 RA-GARK 的整體設計。第 3.1 節說明使 RA-GARK 有別於第 ?? 章所回顧之深度融合基線的核心設計原則。第 3.2 節以泳道圖 (swim-lane) 呈現推論時的整體資料流。第 3.3 節固定後續章節所使用的符號。第 3.4 節形式化推薦任務與訓練目標。第 3.5 節以模組摘要作結，並前向引用第 ?? 章——各模組之完整數學細節於該章呈現。

3.1 設計原則：KG 作為可被閘控的旁路通道

第 ?? 章的經驗觀察是：在本研究稀疏的評論衍生知識圖譜 (KG) 上，四種具代表性的 KG-aware 方法 (KGAT、KGCL、MCCLK、KGRec) 皆被純 LightGCN 一致地超越。這些基線所共有的結構性失因在於：KG 被當作評分管線的必要組件串接進來——KG 實體嵌入直接參與訊息傳遞，且無任何架構性的開關能在 KG 被證實不可靠時將其脫接。因此 KG 雜訊與協同表示共享同一條梯度流。

RA-GARK 圍繞一個直接面對此失效模式的核心設計原則：

KG 不應為評分管線的必要組件，而應為一條旁路通道；其對最終分數的貢獻由一個學習得到的閘決定，閘在初始化時偏置至一個安全預設（純協同過濾），僅在訓練訊號顯示 KG 通道能降低損失時才被打開。

此原則衍生三項架構層級的後果，並共同定義 RA-GARK：

1. **雙條平行視角。**區域視角透過在使用者—物品互動圖上運行 LightGCN 產生純協同表示 (u_{loc}, i_{loc}) ，過程中完全不涉及 KG。全域視角則由獨立的使用者嵌入表與

物品端的潛在面向槽產生 KG 表示 $(u_{\text{glo}}, i_{\text{glo}})$ ，過程中亦不涉及協同訊號。直至融合階段之前，兩條視角在結構上完全分離。

2. **後期、開控的融合。**兩條視角僅在最終評分階段被融合開合併；該開針對每組（使用者，物品）配對輸出一個混合權重 $\alpha \in (0, 1)$ 。開以偏置初始化使 $\alpha^{(0)} \approx 0.993$ ，模型訓練起點實質等同於純 LightGCN，KG 通道僅在梯度將 α 推低時逐步開啟。
3. **合理化感知的物品端聚合。**每件物品的 KG 語意儲存於 $A = 4$ 個潛在面向槽中，槽位內容由 IDF 加權商品一面向矩陣之截斷 SVD 產生；softmax aspect-saliency 注意力依（使用者，物品）配對選取代表該物品的潛在槽。

每項後果均於第 ?? 章中數學化。本章其餘部分將符號與問題陳述定位至足以使第 ?? 章自洽所需之細節層級。

3.2 架構概覽

圖 1 勾勒了推論時的資料流。模型被布置為對應區域與全域視角的兩條水平泳道，於右側由融合階段匯合。




Figure 1: RA-GARK 架構。區域視角（上方泳道）對使用者—物品互動圖套用 LightGCN，得到 $(u_{\text{loc}}, i_{\text{loc}})$ 。全域視角（下方泳道）直接以查表得到使用者的全域嵌入 u_{glo} ，並對物品的 $A = 4$ 個潛在面向槽（以虛線標註的 KG-SVD 初始化）施加 softmax 合理化遮罩以得 i_{glo} 。兩條視角由獨立的使用者側與物品側融合開混合，每個開的偏置初始化為 $+5$ 。最終分數為內積 $\langle u_{\text{final}}, i_{\text{final}} \rangle$ 。為求清晰，跨視角對比學習路徑於圖中省略，詳見第 ?? 節。

兩項結構性質值得在形式化呈現之前先點明。其一， u_{glo} 並不經過合理化遮罩模組，而是由直接查表得到，並逕送至使用者側融合閘；合理化遮罩僅作用於物品側，符合「合理化回答的是『此物品的哪個面向對此使用者重要』」這一語意。其二，KG-SVD 步驟為初始化而非前向運算：SVD 於訓練前計算一次以設定面向槽參數的初值，其後槽位即如其他參數般以梯度下降更新。

3.3 符號

本論文後續使用之符號列於表 4。

Table 4: 本章與後續章節所使用之符號。

符號	意義
$\mathcal{U}, \mathcal{I}$	使用者集合與物品集合
$\mathcal{R} \subseteq \mathcal{U} \times \mathcal{I}$	已觀察到的使用者—物品互動
$\mathcal{G}_{\text{KG}}$	物品—面向知識圖譜（評論衍生）
$\mathcal{A}$	$\mathcal{G}_{\text{KG}}$ 中出現之 unique 面向標籤集合
A	每件物品的潛在面向槽數（ $A = 4$ ）
d	嵌入維度（除另行指定， $d = 64$ ）
K	LightGCN 傳播層數（ $K = 2$ ）
$u_{\text{loc}}, i_{\text{loc}} \in \mathbb{R}^d$	區域視角（LightGCN）嵌入
$u_{\text{glo}} \in \mathbb{R}^d$	全域視角使用者嵌入（直接查表）
$\mathbf{a}_i \in \mathbb{R}^{A \times d}$	物品 i 之潛在面向槽（SVD 初始化）
$i_{\text{glo}} \in \mathbb{R}^d$	全域視角物品嵌入（合理化遮罩後）
$\alpha_u, \alpha_i \in (0, 1)$	使用者側與物品側融合閘輸出
$\hat{y}(u, i) \in \mathbb{R}$	對配對 (u, i) 之預測偏好分數

3.4 問題定式

任務。 本文處理隱式回饋設定下的 top- K 推薦。給定 $\mathcal{U}$ 、 $\mathcal{I}$ 、已觀察到的互動 $\mathcal{R}$ ，以及物品—面向 KG $\mathcal{G}_{\text{KG}}$ ，目標是為每位使用者 $u \in \mathcal{U}$ 從 $\mathcal{I} \setminus \{i : (u, i) \in \mathcal{R}\}$ 中產生一個排序清單，並以排序指標（NDCG@ K 、Recall@ K 、Hit@ K ）對保留之測試互動集進行評估。

評分函數。 RA-GARK 對每組 (u, i) 配對指派內積分數

$$\hat{y}(u, i) = \langle u_{\text{final}}, i_{\text{final}} \rangle, \quad (3.1)$$

其中 u_{final} 與 i_{final} 由區域與全域表示的閘控融合產生：

$$u_{\text{final}} = \alpha_u u_{\text{loc}} + (1 - \alpha_u) u_{\text{glo}}, \quad i_{\text{final}} = \alpha_i i_{\text{loc}} + (1 - \alpha_i) i_{\text{glo}}. \quad (3.2)$$

閘輸出 α_u, α_i 分別由獨立的 MLP 計算（第 ?? 節）。在本論文採用的偏置初始化下， $\alpha_u^{(0)}, \alpha_i^{(0)} \approx 0.993$ ，因此 $\hat{y}^{(0)}(u, i) \approx \langle u_{\text{loc}}, i_{\text{loc}} \rangle$ ，即訓練起點之分數實質為純 LightGCN 之分數，直至閘藉學習而調整。

訓練目標。 我們以 Bayesian Personalized Ranking (BPR) [19] 損失為主體，並輔以兩條跨視角對比正則化：

$$\mathcal{L} = \mathcal{L}_{\text{BPR}} + \lambda_{\text{CL}} (\mathcal{L}_{\text{aCL}} + \mathcal{L}_{\text{uCL}}), \quad (3.3)$$

其中對每組已觀察配對 $(u, i^+) \in \mathcal{R}$ 與一個取樣的負例物品 $i^- \notin \mathcal{R}_u$ ，

$$\mathcal{L}_{\text{BPR}} = -\log \sigma(\hat{y}(u, i^+) - \hat{y}(u, i^-)), \quad (3.4)$$

而 $\mathcal{L}_{\text{aCL}}, \mathcal{L}_{\text{uCL}}$ 分別為 $(i_{\text{loc}}, i_{\text{glo}})$ 與 $(u_{\text{loc}}, u_{\text{glo}})$ 之間的 InfoNCE 式對齊損失；全域側施加 stop-gradient 以避免對比梯度擾動 SVD 初始化之面向槽（第 ?? 節）。對比權重 λ_{CL} 固定為 0.005，使對比的角色為輔助而非主要。

3.5 模組摘要

模型其餘細節於第 ?? 章詳述。為方便交叉引用，此處列出各模組及其形式化所在之節：

- **區域視角（第 ?? 節）。**於 $\mathcal{U} \cup \mathcal{I}$ 上之兩層 LightGCN，不涉及 KG；產生 $u_{\text{loc}}, i_{\text{loc}}$ 。
- **面向槽與 KG-SVD 初始化（第 ?? 節）。**每件物品之參數張量 $\mathbf{a}_i \in \mathbb{R}^{A \times d}$ ，由 IDF 加權商品一面向共現矩陣之截斷 SVD 初始化。
- **Softmax 合理化遮罩（第 ?? 節）。**於物品 i 之 A 個槽上施加使用者條件 softmax 注意力，以加權求和得 i_{glo} 。
- **區域偏置融合閘（第 ?? 節）。**獨立之使用者側與物品側 MLP 閘，各輸出一純量 $\alpha \in (0, 1)$ ；最後一層線性層之偏置初始化為 +5。

- 跨視角對比正則化（第 ?? 節）。InfoNCE 式對齊配合全域側 stop-gradient；小固定權重 $\lambda_{\text{CL}} = 0.005$ 。

在設計原則、架構勾勒、符號與問題陳述就位後，第 ?? 章將呈現各模組之完整內容。

Bibliography

- [1] X. He, K. Deng, X. Wang, Y. Li, Y. Zhang, and M. Wang, “LightGCN: Simplifying and powering graph convolution network for recommendation,” in *Proc. ACM SIGIR*, 2020, pp. 639–648.
- [2] X. Wang, X. He, M. Wang, F. Feng, and T.-S. Chua, “Neural graph collaborative filtering,” in *Proc. ACM SIGIR*, 2019, pp. 165–174.
- [3] J. Wu, X. Wang, F. Feng, X. He, L. Chen, J. Lian, and X. Xie, “Self-supervised graph learning for recommendation,” in *Proc. ACM SIGIR*, 2021, pp. 726–735.
- [4] X. Wang, X. He, Y. Cao, M. Liu, and T.-S. Chua, “KGAT: Knowledge graph attention network for recommendation,” in *Proc. ACM SIGKDD*, 2019, pp. 950–958.
- [5] Y. Yang, C. Huang, L. Xia, and C. Li, “Knowledge graph contrastive learning for recommendation,” in *Proc. ACM SIGIR*, 2022, pp. 1434–1443.
- [6] D. Zou, W. Wei, X.-L. Mao, Z. Wang, M. Qiu, F. Zhu, and X. Cao, “Multi-level cross-view contrastive learning for knowledge-aware recommender system,” in *Proc. ACM SIGIR*, 2022, pp. 1358–1368.
- [7] Y. Yang, C. Huang, L. Xia, and C. Huang, “Knowledge graph self-supervised rationalization for recommendation,” in *Proc. ACM SIGKDD*, 2023, pp. 3046–3056.
- [8] X. Ren, L. Xia, J. Zhao, D. Yin, and C. Huang, “Disentangled contrastive collaborative filtering,” in *Proc. ACM SIGIR*, 2023, pp. 1137–1146.
- [9] A. van den Oord, Y. Li, and O. Vinyals, “Representation learning with contrastive predictive coding,” *arXiv preprint arXiv:1807.03748*, 2018.
- [10] R. K. Srivastava, K. Greff, and J. Schmidhuber, “Highway networks,” *arXiv preprint arXiv:1505.00387*, 2015.

- [11] J. Ma, Z. Zhao, X. Yi, J. Chen, L. Hong, and E. H. Chi, “Modeling task relationships in multi-task learning with multi-gate mixture-of-experts,” in *Proc. ACM SIGKDD*, 2018, pp. 1930–1939.
- [12] H. Tang, J. Liu, M. Zhao, and X. Gong, “Progressive layered extraction (PLE): A novel multi-task learning model for personalized recommendations,” in *Proc. ACM RecSys*, 2020, pp. 269–278.
- [13] Z. Wang, G. Lin, H. Tan, Q. Chen, and X. Liu, “CKAN: Collaborative knowledge-aware attentive network for recommender systems,” in *Proc. ACM SIGIR*, 2020, pp. 219–228.
- [14] H. Wang, F. Zhang, M. Zhao, W. Li, X. Xie, and M. Guo, “Multi-task feature learning for knowledge graph enhanced recommendation,” in *Proc. The Web Conference (WWW)*, 2019, pp. 2000–2010.
- [15] X. Wang, T. Huang, D. Wang, Y. Yuan, Z. Liu, X. He, and T.-S. Chua, “Learning intents behind interactions with knowledge graph for recommendation,” in *Proc. The Web Conference (WWW)*, 2021, pp. 878–887.
- [16] G. Zhou, X. Zhu, C. Song, Y. Fan, H. Zhu, X. Ma, Y. Yan, J. Jin, H. Li, and K. Gai, “Deep interest network for click-through rate prediction,” in *Proc. ACM SIGKDD*, 2018, pp. 1059–1068.
- [17] X. He, Z. He, J. Song, Z. Liu, Y.-G. Jiang, and T.-S. Chua, “NAIS: Neural attentive item similarity model for recommendation,” *IEEE Transactions on Knowledge and Data Engineering*, vol. 30, no. 12, pp. 2354–2366, 2018.
- [18] J. Xiao, H. Ye, X. He, H. Zhang, F. Wu, and T.-S. Chua, “Attentional factorization machines: Learning the weight of feature interactions via attention networks,” in *Proc. International Joint Conference on Artificial Intelligence (IJCAI)*, 2017, pp. 3119–3125.
- [19] S. Rendle, C. Freudenthaler, Z. Gantner, and L. Schmidt-Thieme, “BPR: Bayesian personalized ranking from implicit feedback,” in *Proc. Conference on Uncertainty in Artificial Intelligence (UAI)*, 2009, pp. 452–461.