

# 稀疏知識圖譜下基於理由感知閘控的雙視角推薦架構

學生：預覽用

指導教授：預覽用 博士

國立陽明交通大學  
資訊學院碩士在職專班

## 摘要

知識圖譜感知 (KG-aware) 推薦系統將商品語意引入圖式協同過濾，當知識圖譜 (KG) 稠密且品質良好時，普遍能有效提升推薦準確性，相關方法已蓬勃發展。然而當 KG 本身稀疏或品質不佳時——此即評論衍生、冷啟動、隱私受限等現實場景下的常態——既有研究的探討相當有限。本文以書評衍生 KG 為例（過濾後每件商品平均僅 2.4 條邊），觀察到四個代表性 KG-aware 方法 (KGAT、KGCL、MCCLK、KGRec) 皆不及完全不使用 KG 的純 LightGCN。共同結構原因在於：這些方法皆將 KG 訊號作為計分管線之必經成分，缺乏在 KG 不可信時將其切斷或弱化的機制，因此 KG 雜訊一併被融入產生協同表示的梯度流。

為解決此一問題，本文提出 RA-GARK (Rationale-Aware Gating over Review-Aspect Knowledge graphs)，一個雙視角推薦架構，將 KG 視為可被閘控之側通道而非必經元件。核心設計為一個本地偏置融合閘 (local-biased fusion gate)：當使用者—商品互動圖與 KG 進行合併考量時，閘根據每組 (使用者, 商品) 配對動態調整兩條訊號的相對權重，使模型能依情況彈性適應——KG 對該配對具資訊量時加大其貢獻，反之則退回以協同訊號為主，藉此提升預測分數與推薦效果。融合閘之偏置初始化為 +5，使訓練起點實質等同於純 LightGCN，僅在梯度顯示 KG 有益時才逐步開啟，提供結構性的優雅退化保證。除此之外，本文以四個潛在面向槽 (latent aspect slots) 儲存每件商品之 KG 語意——槽位數  $A = 4$  為模型設計參數，與每件商品所擁有之原始面向標籤數無關；其內容由 IDF 加權商品—面向共現矩陣之截斷 SVD 投影而得，跨全體商品共同學習語意子空間，並透過 softmax 注意力依 (使用者, 商品) 配對挑選最具顯著性的潛在面向。

在稀疏書評衍生 KG 之實驗設定下，RA-GARK 於 NDCG@20 達到 0.1238，較最強 KG-aware 基準 KGRec 提升 13.1%，並較純 LightGCN 提升 5.0%。後者顯示：所提之動態權重調整機制能在 KG 本身不變的情況下，將其貢獻自「無益」翻轉為「有益」。元件式消融顯示，softmax 注意力若被替換為 sigmoid 將造成 7.0% 之 NDCG 下降；偏置初始化融合閘與 KG-SVD 初始化則各貢獻 5.3%。本文另提出關於注意力歸一化之方法論

觀察作為待驗證假說，並明確指出該觀察目前僅有單一資料集支持，需多資料集複現方能升格為通用結論。

**關鍵字：**知識圖譜推薦；可退化機制；理由感知學習；融合閘；稀疏知識圖譜；注意力歸一化；協同過濾

# Contents

|          |                                |           |
|----------|--------------------------------|-----------|
| <b>1</b> | <b>緒論</b>                      | <b>1</b>  |
| 1.1      | 研究背景 . . . . .                 | 1         |
| 1.2      | 稀疏 KG 下的經驗異常現象 . . . . .       | 1         |
| 1.3      | 稀疏 KG 作為現實世界的常態 . . . . .      | 2         |
| 1.4      | 研究問題 . . . . .                 | 2         |
| 1.5      | 研究貢獻 . . . . .                 | 3         |
| 1.6      | 論文組織 . . . . .                 | 4         |
| <b>2</b> | <b>相關研究</b>                    | <b>5</b>  |
| 2.1      | 基礎：LightGCN 與 KGAT . . . . .   | 5         |
| 2.2      | 對比式知識圖譜方法 . . . . .            | 6         |
| 2.3      | 合理化感知推薦：KGRec . . . . .        | 6         |
| 2.4      | 合理化典範：共同前提與分歧的可信度假設 . . . . .  | 7         |
| 2.5      | 深度學習中的閘控機制 . . . . .           | 8         |
| 2.6      | 缺口：KG-Aware 推薦中沒有融合閘 . . . . . | 8         |
| 2.7      | 注意力正規化 . . . . .               | 9         |
| 2.8      | 總結與 RA-GARK 的定位 . . . . .      | 10        |
| <b>3</b> | <b>方法</b>                      | <b>11</b> |
| 3.1      | 設計原則：KG 作為可被閘控的旁路通道 . . . . .  | 11        |
| 3.2      | 架構概覽 . . . . .                 | 12        |
| 3.3      | 符號 . . . . .                   | 13        |
| 3.4      | 問題定式 . . . . .                 | 13        |
| 3.5      | 區域視角：LightGCN . . . . .        | 14        |
| 3.5.1    | 動機 . . . . .                   | 14        |

|        |                                   |    |
|--------|-----------------------------------|----|
| 3.5.2  | 圖的建構 . . . . .                    | 15 |
| 3.5.3  | 傳播 . . . . .                      | 15 |
| 3.5.4  | 層平均與輸出 . . . . .                  | 15 |
| 3.6    | 全域視角：KG-SVD 初始化 . . . . .         | 16 |
| 3.6.1  | 面向槽作為物品側 KG 表示 . . . . .          | 16 |
| 3.6.2  | 共現矩陣 . . . . .                    | 16 |
| 3.6.3  | IDF 加權 . . . . .                  | 16 |
| 3.6.4  | 截斷 SVD . . . . .                  | 17 |
| 3.6.5  | 重塑為槽位與量值縮放 . . . . .              | 17 |
| 3.6.6  | 演算法 . . . . .                     | 18 |
| 3.6.7  | 此初始化所帶來的效益 . . . . .              | 18 |
| 3.7    | 全域視角：Softmax 合理化遮罩 . . . . .      | 18 |
| 3.7.1  | 動機 . . . . .                      | 19 |
| 3.7.2  | 使用者條件之注意力 logits . . . . .        | 19 |
| 3.7.3  | Softmax 歸一化 . . . . .             | 19 |
| 3.7.4  | 加權聚合 . . . . .                    | 20 |
| 3.7.5  | 為何使用 Softmax 而非 Sigmoid . . . . . | 20 |
| 3.8    | 區域偏置融合閘 . . . . .                 | 20 |
| 3.8.1  | 雙側獨立閘 . . . . .                   | 21 |
| 3.8.2  | 閘的結構 . . . . .                    | 21 |
| 3.8.3  | 區域偏置初始化 . . . . .                 | 21 |
| 3.8.4  | 優雅退化 . . . . .                    | 22 |
| 3.8.5  | 為何選 +5 而非 $+\infty$ . . . . .     | 22 |
| 3.9    | 跨視角對比正則化 . . . . .                | 23 |
| 3.9.1  | 在架構中的角色 . . . . .                 | 23 |
| 3.9.2  | 面向層級對比損失 . . . . .                | 23 |
| 3.9.3  | 使用者層級對比損失 . . . . .               | 23 |
| 3.9.4  | 全域側 Stop-Gradient . . . . .       | 24 |
| 3.9.5  | 損失權重 . . . . .                    | 24 |
| 3.10   | 訓練與計算複雜度 . . . . .                | 24 |
| 3.10.1 | 總目標 . . . . .                     | 24 |
| 3.10.2 | 最佳化 . . . . .                     | 24 |

|                                     |           |
|-------------------------------------|-----------|
| 3.10.3 推論 . . . . .                 | 24        |
| 3.10.4 計算複雜度 . . . . .              | 25        |
| <b>4 實驗</b>                         | <b>26</b> |
| 4.1 資料集與 KG 建構 . . . . .            | 26        |
| 4.2 實驗設定 . . . . .                  | 27        |
| 4.3 主要結果 . . . . .                  | 27        |
| 4.4 消融研究 . . . . .                  | 27        |
| 4.4.1 KG-SVD 初始化 . . . . .          | 27        |
| 4.4.2 Softmax 合理化遮罩 . . . . .       | 27        |
| 4.4.3 區域偏置融合閘 . . . . .             | 27        |
| 4.5 敏感性分析 . . . . .                 | 27        |
| 4.5.1 Softmax 溫度 $\tau$ . . . . .   | 27        |
| 4.5.2 面向槽數 $A$ . . . . .            | 27        |
| 4.5.3 融合閘偏置 . . . . .               | 27        |
| 4.5.4 對比權重 $\lambda_{CL}$ . . . . . | 27        |
| 4.6 種子穩定性 . . . . .                 | 27        |
| 4.7 個案研究 . . . . .                  | 27        |
| 4.8 計算成本 . . . . .                  | 27        |
| <b>5 結論與未來工作</b>                    | <b>28</b> |
| 5.1 結論 . . . . .                    | 28        |
| 5.2 方法論啟示：注意力正規化 . . . . .          | 28        |
| 5.3 限制 . . . . .                    | 28        |
| 5.4 未來工作 . . . . .                  | 28        |

# Chapter 1

## 緒論

### 1.1 研究背景

圖神經網路 (GNN) 已成為協同過濾的主流架構選擇。其中，LightGCN [1] 證明了只要移除 GCN 中的非線性激活與特徵變換、僅保留線性鄰居聚合，便足以在標準推薦基準上超越如 NGCF [2] 等更深層的方法。LightGCN 的簡潔與穩定使其成為一個強大且參數高效的骨幹，而後續方法如 SGL [3] 則在其上疊加額外的自監督目標。

另一條互補的研究路線——知識圖譜感知推薦 (KG-aware recommendation) ——以知識圖譜 (KG) 所編碼的物品端語意來擴充協同訊號。具代表性的方法包括：KGAT [4]，在統一的使用者—物品—實體圖上傳播訊息；KGCL [5] 與 MCCLK [6]，透過對比學習對齊 KG 視角與協同視角；以及 KGRec [7]，引入邊層級的合理化 (rationalization) 機制以辨識哪些 KG 三元組對推薦負責。當 KG 稠密且品質良好時，這類方法皆能穩定地超越純協同基線。

### 1.2 稀疏 KG 下的經驗異常現象

本研究的起點是一個促使整篇論文展開的經驗觀察。在本研究所使用的、由評論衍生而來的 KG 資料集 (Amazon Books 子集，經篩選後每件物品平均僅有 2.4 條 aspect 邊) 上，前述四種具代表性的 KG-aware 方法全部都被完全不參考 KG 的純 LightGCN 所超越。表 1 摘要呈現此一差距。

我們並非主張上述四種基線本身有缺陷——它們在其原始論文所報告的稠密 KG 資料集上表現皆十分強勁。此觀察反映的，是深度 KG-CF 耦合所共同具有的一種失效模式：當 KG 過於稀疏或雜訊過多以致無法提供可靠的物品語意時，將其直接融入評分路

Table 1: 在我們的稀疏評論型 KG 上，代表性 KG-aware 方法之 NDCG@20 表現，並與純 LightGCN 對照。四種 KG-aware 方法皆不及不使用 KG 的基線。

| 方法                      | NDCG@20       |
|-------------------------|---------------|
| MCCLK [6]               | 0.1067        |
| KGCL [5]                | 0.1073        |
| KGAT [4]                | 0.1079        |
| KGRec [7]               | 0.1095        |
| 純 LightGCN [1] (未使用 KG) | <b>0.1179</b> |

徑會使 KG 雜訊污染本可產生純淨協同訊號的梯度流。

### 1.3 稀疏 KG 作為現實世界的常態

一個自然的反駁是：將此一經驗異常視為資料集的特殊性，並透過更精緻地策劃稠密 KG 或進行 KG 補全 (completion) 來填補缺失邊即可。然而，我們主張，稀疏 KG 才是實務推薦系統中更常見的情境，因此「在 KG 訊號不可靠時依然穩健」這項性質本身就值得專門研究，而非以工程繞道方式迴避。

實務上有三個常見的稀疏來源。其一，評論衍生型 KG——如本研究所使用者——其密度繼承自使用者實際提及的主題；覆蓋本質上即不均勻。其二，冷啟動與新興領域——新品類、低資源語言、利基垂直市場——通常無法取得如 Freebase 或 Wikidata 等等級的人工策劃資源，KG 必須從有限訊號中自舉而來。其三，隱私受限領域，如醫療或金融推薦，刻意限制可暴露給模型的關聯訊號。在以上三種情境中，激進的 KG 補全本身亦非易事：補全會引入新的雜訊，且通常需要足夠的種子訊號才能訓練——而這恰恰是稀疏情境中所欠缺的。

由此推論，推薦器在 KG 不可靠時的穩健性，至少和它在 KG 稠密時的峰值效能同等重要。本論文以此穩健性作為主要設計目標。

### 1.4 研究問題

上述經驗異常與稀疏 KG 情境的實務重要性，引出兩個研究問題：

- (RQ1, 診斷) 為何既有 KG-aware 方法在稀疏 KG 下不及純 LightGCN？它們所共同具備的結構性失效模式為何？

- (RQ2, 處方) 何種設計原則能讓模型在 KG 訊號有效時加以利用，而在訊號無效時避免 KG 雜訊污染協同過濾？

本論文的主張是：KG 不應如 KGAT 式深度融合那般，成為評分管線中的必要組件，而應作為一條可依其訊號是否有效而被明確開控的旁路通道。具體而言，此原則由三項設計選擇實現：以 softmax 為基礎的 aspect-saliency 注意力，用於對每組使用者—物品配對選取 KG 合理化依據；以 KG 驅動的 SVD 初始化，用以保留語意幾何；以及具有局部偏置的融合閘（local-biased fusion gate），其初始化內建了當 KG 訊號終究不具資訊量時優雅退化回純 LightGCN 的能力。

## 1.5 研究貢獻

本論文之主要貢獻如下：

1. **經驗性研究**：證明在稀疏評論型 KG 下，四種具代表性的 KG-aware 方法（KGAT、KGCL、MCCLK、KGRec）皆一致地被純 LightGCN 超越。我們將此歸因於這些方法缺乏一個能於 KG 不可靠時將其脫接的架構機制。
2. **RA-GARK，一個雙視角架構**：以旁路通道而非深度融合的方式整合協同訊號與 KG 衍生訊號。RA-GARK 由三項核心要素組成，且彼此皆獨立必要：
  - **Softmax aspect-saliency 注意力**（第 3.7 節）。每件物品的 KG 語意儲存於  $A = 4$  個潛在面向槽中——此槽位數為模型設計參數，與每件物品所擁有的原始面向標籤數無關——槽位內容由 IDF 加權商品—面向共現矩陣之截斷 SVD 投影而得；softmax 正規化的注意力為給定的使用者—物品配對選取最足以代表該物品的潛在槽位。將 softmax 改為 sigmoid 會使 NDCG@20 下降 7.0%，是我們所觀察到單一元件影響最大者。
  - **具局部偏置的融合閘**（第 3.8 節）。融合閘以 +5 的正偏置初始化，使  $\alpha^{(0)} \approx 0.993$ 。因此模型在訓練之初幾乎等同於純 LightGCN，僅當梯度顯示 KG 通道有幫助時，閘門才會被打開。此設計提供了四種基線所缺乏的、結構性的優雅退化保證。若移除此偏置初始化，NDCG@20 會損失 5.3%。
  - **KG-SVD 初始化**（第 3.6 節）。aspect 槽位的嵌入由 IDF 加權的物品—aspect 矩陣之截斷 SVD 初始化而來，將 KG 的語意幾何保留為最佳化的起點。將其換為隨機初始化會損失 5.3% NDCG@20。



3. **經驗驗證：**在稀疏評論型 KG 基準上，RA-GARK 達到  $NDCG@20 = 0.1238$ ，較最強的 KG-aware 基線 (KGRec) 高出 +13.1%，更重要的是，較純 LightGCN 也高出 +5.0%。後者的差距顯示，所提出的設計原則能在 KG 本身不變的情況下，把 KG 訊號的貢獻由淨負（四種基線之情況）翻轉為淨正。
4. **關於合理化感知設計中注意力正規化的方法論觀察。**在我們的情境中，softmax 與 sigmoid 之間異常顯著的差距，暗示正規化的選擇應與合理化的語意假設相一致。我們將此視為單一資料集上的假設而非通用主張，留待後續多資料集複製驗證（第 5 章）。

## 1.6 論文組織

本論文後續組織如下。第 2 章從四個面向回顧相關文獻：圖協同過濾、KG-aware 推薦、深度學習中的閘控機制，以及注意力正規化。第 3 章呈現 RA-GARK 的整體架構並形式化推薦問題。第 3 章詳述各模組，包括區域視角、含兩項創新（KG-SVD 初始化與 softmax aspect-saliency 注意力）的全域 KG 視角、具局部偏置的融合閘，以及跨視角對比正規化。第 4 章報告實驗結果、消融研究、敏感性分析與個案研究。第 5 章討論關於注意力正規化的方法論啟示，承認單一資料集驗證與種子敏感性的限制，並作結。

# Chapter 2

## 相關研究

本章從四個面向回顧先前研究，這些面向共同促成 RA-GARK 的設計。第 2.1 節介紹我們區域與全域視角所立足的兩項基礎：作為協同過濾骨幹的 LightGCN，與作為深度 KG-CF 融合典範的 KGAT。第 2.2 節回顧那些在不明確閘控下對齊協同與 KG 視角的對比式 KG 方法。第 2.3 節討論與本工作最為相關的合理化感知方法 KGRc，第 2.4 節則以「KG 可信度」為視角，對比我們與 KGRc 的合理化典範。第 2.5 與 2.6 節廣泛回顧深度學習中的閘控機制，並觀察到既有 KG-aware 方法皆未採用融合閘以提供架構層級的優雅退化。第 2.8 節總結 RA-GARK 相對於上述工作的定位。

### 2.1 基礎：LightGCN 與 KGAT

LightGCN [1] 是本研究區域視角的直接前身。建立於「NGCF [2] 中的非線性特徵變換對推薦準確率貢獻甚微」這項觀察上，LightGCN 將圖卷積網路精簡至最小骨幹：在使用者—物品二部圖上進行正規化的鄰居聚合  $\mathbf{E}^{(\ell+1)} = \tilde{\mathbf{A}}\mathbf{E}^{(\ell)}$ ，最終嵌入則取各層平均  $\bar{\mathbf{E}} = \frac{1}{K+1} \sum_{\ell=0}^K \mathbf{E}^{(\ell)}$ 。此一簡化在標準推薦基準上一致地優於 NGCF，且訓練更快、更穩定。其後諸多自監督方法，如 SGL [3] 與 DCCF [8]，皆在 LightGCN 式骨幹之上疊加額外的對比目標。

在 RA-GARK 中，我們原封不動採用 LightGCN ( $K = 2$ ) 作為區域視角：此分支內不施加任何 KG 相關運算。動機有二。其一，在我們的稀疏評論型 KG 上，純 LightGCN 已達  $\text{NDCG}@20 = 0.1179$ ，超越所有我們所評估的 KG-aware 基線。任何偏離此強預設的設計，皆須可被證實能改善而非劣化結果——這是本論文反覆訴諸的硬性設計約束。其二，將 KG 訊號隔離至獨立的全域視角（第 3 章），可避免 KG 雜訊污染協同表示的梯度流。

**KGAT** [4] 代表 KG-aware 推薦中的典範深度融合做法。KGAT 將使用者—物品互動圖與知識圖譜合併為一個協同知識圖 (Collaborative Knowledge Graph, CKG)，並以雙交互聚合器於此統一結構上傳播訊息。KG 實體嵌入因而直接參與使用者與物品表示的形成。當 KG 稠密且品質良好時，此設計相對於 CF 基線可取得顯著提升。

此處的隱含假設是 KG 可被信任，能在傳播路徑所及之處皆注入有用訊號。在我們的稀疏情境下此假設崩解：KGAT 僅達  $\text{NDCG}@20 = 0.1079$ ，低於純 LightGCN。其後續工作 [5, 6, 7] 沿用 KGAT 式聚合器，因此也繼承相同的脆弱性。RA-GARK 反轉此一設計選擇：我們完全不將 KG 與使用者—物品圖合併，而是將 KG 訊號導入一條專用旁路通道，當 KG 被證實不可靠時模型可衰減甚至全然脫接之。

## 2.2 對比式知識圖譜方法

**KGCL** [5] 對 KG 引入關係層級的結構擾動，並以 InfoNCE [9] 對比目標對齊擾動版本與原始版本。直覺是：具資訊量的 KG 結構應對隨機擾動具有不變性，而雜訊邊則不應。KGCL 在稠密 KG 情境下顯著優於 KGAT。然而在我們的稀疏情境中，擾動後的 KG 保留的邊過少，對比目標無法提供可靠監督： $\text{NDCG}@20$  降至 0.1073。

**MCCLK** [6] 將對比對齊擴展至三個視角——協同、語意與結構——並對三者兩兩施加對比損失。雖然此多視角設計在稠密 KG 基準上取得 SOTA，但同樣繼承稠密 KG 的假設：在稀疏 KG 下，三個視角中有兩個（語意與結構）訊號不足，對比對齊淪為由雜訊主導而非由結構主導的正則化 ( $0.1067 \text{NDCG}@20$ )。

RA-GARK 同樣納入跨視角對比學習，但其角色刻意受限。我們的對比損失 ( $\mathcal{L}_{\text{aCL}}$  與  $\mathcal{L}_{\text{uCL}}$ ，第 3.9 節) 僅作為小權重 ( $\lambda = 0.005$ ) 的輔助幾何正則化項，並關鍵地在 KG 側施加 stop-gradient，使對比梯度從不反向傳遞至 SVD 初始化的 aspect 嵌入。相較於 KGCL/MCCLK，此處的對比學習是表層的對齊層，而非主要的融合機制；協同與 KG 訊號的實際整合，是由一個明確的閘所執掌 (第 2.5 節)。

## 2.3 合理化感知推薦：KGRec

**KGRec** [7] 是與本工作最直接相關的研究。它是第一個將合理化選擇明確化的 KG-aware 推薦器：KGRec 不將每條 KG 三元組視為同等具資訊量，而是對每條 KG 邊計算一個基於注意力的重要性分數，並以 Bernoulli dropout 隨機移除高注意力邊，迫使模型不依賴少數主導邊；其穩健性接著由原始圖與被丟邊版本之間的對比目標來強化。整套合理化機制建立於 KGAT 式聚合器之上，因此合理化作用於使用者—物品—實體統

一圖的訊息傳遞路徑之內。在我們的稀疏基準上，KGRec 取得  $\text{NDCG}@20 = 0.1095$ ，為四個 KG-aware 基線中最強者，但仍低於純 LightGCN。

RA-GARK 在精神上採納合理化感知典範，但在結構上多處與 KGRec 有別，下節詳述之。

## 2.4 合理化典範：共同前提與分歧的可信度假設

KGRec [7] 與 RA-GARK 都認同「並非所有 KG 邊都對推薦同等貢獻、需要明確的選擇機制」這項觀察。然而二者對 KG 整體可信度所作的假設有所不同，此一假設並蔓延至各自分歧的設計選擇。

KGRec 的隱含假設是：具資訊量的邊存在於 KG 中，因此合理化任務簡化為將其找出；隨機 dropout 配合對比學習已足以辨識並放大有用子集。KG 整體作為證據體系被假定為可靠的，僅是個別邊的權重需被調整。

RA-GARK 的前提較弱。我們不假設 KG 整體是可靠的。aspect-saliency softmax (第 3.7 節) 在 KG 具資訊量時選取合理化依據，但具局部偏置的融合閘 (第 3.8 節) 可在閘的梯度顯示無益時，另外地脫接整條 KG 通道。此可信度差異展現於四項設計分歧上：

- **合理化粒度。** KGRec 在邊 (KG 三元組) 層級進行選擇。RA-GARK 將每件物品的 KG 語意聚合為  $A = 4$  個潛在面向槽——槽位內容由 IDF 加權商品—面向共現矩陣之截斷 SVD 投影得到——並在槽位層級進行選擇。此槽位數為模型設計參數，與每件物品所擁有的原始面向標籤數無關；粒度雖較邊層級選擇為粗，但直接產生可解讀的每物品 aspect 偏好。
- **選擇機制。** KGRec 採用離散 Bernoulli dropout 配合對比學習。RA-GARK 採用可微分的 softmax 注意力，能端到端訓練，並將推論期的權重作為可解釋性產物外露。
- **作用位置。** KGRec 在 KGAT 訊息傳遞路徑之內施加合理化；合理化與聚合糾纏在一起。RA-GARK 將合理化置於與 LightGCN 區域視角分離的旁路通道，僅於後期由閘將兩者結合。
- **對 KG 可信度的處理。** KGRec 沒有任何架構機制可脫接 KG。RA-GARK 的偏置初始化融合閘正提供此一機制：訓練起始時  $\alpha^{(0)} \approx 0.993$ ，模型實質上即為純 LightGCN；唯當學習顯示 KG 通道能降低損失時，閘才會被打開。

因此我們不將 RA-GARK 定位為對 KGRec 的工程性改良，而是基於對 KG 可信度不同前提之另一種設計。此一區別在經驗上是否重要，則於第 4 章中作答。

## 2.5 深度學習中的閘控機制

RA-GARK 的融合閘有兩個 KG-aware 推薦之外的近親，二者皆啟發本研究設計。

**Highway Networks** [10] 引入可學習的閘  $T(\mathbf{x})$ ，於變換訊號  $H(\mathbf{x})$  與恆等跳接間進行插值： $\mathbf{y} = T(\mathbf{x}) \cdot H(\mathbf{x}) + (1 - T(\mathbf{x})) \cdot \mathbf{x}$ 。其關鍵設計選擇為對  $T$  的負偏置初始化：訓練之初  $T \approx 0$ ，網路表現為恆等映射。其後訓練僅在變換有益處之處才打開閘門。此設計原本是為了應對極深網路訓練的困難，但「將閘偏置至已知安全的預設，僅在學習認為合理時才覆寫」此結構性樣式，遠遠超出深度的脈絡而具有普適性。RA-GARK 將此樣式由網路內跳接移植至雙視角融合：融合閘上的 +5 偏置扮演與 Highway 之負偏置相同的角色，對 KG 通道提供優雅退化保證。

**專家混合 (Mixture-of-Experts) 閘控**，以多任務推薦中的 MMoE [11] 與 PLE [12] 為代表，以閘控網路對多個專家塔加權。雖然概念上類似多管線選擇，但兩項重要性質與 RA-GARK 不同。其一，MMoE/PLE 中的專家為同質候選者——皆為相同架構、僅以任務特定目標訓練的實例——因此並無「某專家本質上比另一者較不可靠」的概念。其二，這些架構中的閘採對稱初始化（訓練起始不偏向任何特定專家），適用於對稱專家情境，但不適用於我們不對稱的情境——在我們的設定中，一條通道 (LightGCN) 已知是強預設，另一條 (KG) 已知有時並不具資訊量。

另有一條工作線是對比式雙視角推薦器，例如 SGL [3] 與 DCCF [8]，這類方法以擾動單一圖（邊 dropout、節點 dropout、隨機漫步）來建構多個視角。此類方法中兩個視角位於相同訊號空間，對比對齊已足以整合二者。RA-GARK 的兩個視角則在結構上異質：區域視角為使用者—物品二部圖，全域視角為物品—aspect 的 KG。僅靠對比學習進行隱式對齊，無法調整兩個異質訊號空間的相對權重；明確的閘是必要的。

## 2.6 缺口：KG-Aware 推薦中沒有融合閘

儘管閘控在深度學習中已相當成熟，我們所調研的 KG-aware 推薦文獻中，未見任何方法將融合閘作為協同訊號與 KG 訊號之間的整合機制。表 2 摘要了四個被基準測試的基線與另外三個知名 KG-aware 方法 (CKAN [13]、MKR [14]、KGIN [15]) 所採用的整合機制。在這個集合中，KG 訊號是透過直接實體傳播、對比對齊、邊層級 dropout、

注意力、跨特徵單元或意圖解耦模組來整合。沒有任何機制允許 KG 通道在訊號不可靠時被結構性地脫接。

Table 2: 代表性 KG-aware 推薦器所採用的整合機制。皆未提供在不可靠 KG 下的架構優雅退化能力。

| 方法                   | KG 整合機制                | 可脫接？     |
|----------------------|------------------------|----------|
| KGAT [4]             | 直接實體訊息傳播               | 否        |
| KGCL [5]             | 擾動 KG 對比學習             | 否        |
| MCCLK [6]            | 多視角對比對齊                | 否        |
| KGRec [7]            | 邊層級 dropout + KGAT 聚合器 | 否        |
| CKAN [13]            | 協同—知識注意力               | 否        |
| MKR [14]             | 跨特徵轉移單元                | 否        |
| KGIN [15]            | KG 上的意圖解耦              | 否        |
| <b>RA-GARK (本研究)</b> | <b>偏置初始化的融合閘</b>       | <b>是</b> |

我們刻意作出一個範圍狹義的主張。我們不主張 RA-GARK 是 KG-aware 推薦中首個使用「任何閘」的方法，因 KG-aware 文獻浩繁，無法窮舉列舉。可辯護的主張為：在我們所檢視的方法中，沒有任何一個以偏置初始化的融合閘於稀疏或不可靠 KG 下提供架構優雅退化。我們在第 4 章的消融將 5.3% NDCG@20 的貢獻明確歸因於此閘的偏置初始化，支持上述主張在此情境中並非微不足道。

## 2.7 注意力正規化

一個橫跨多領域的相關問題是：在選擇合理化依據時，應對注意力權重套用 sigmoid 或 softmax？文獻並未匯聚於單一答案。DIN [16] 對使用者行為歷史套用 sigmoid 注意力，所基於的假設是每筆歷史行為與候選物品的相關性彼此獨立。NAIS [17] 對歷史互動套用 softmax 注意力以衡量物品相似度，AFM [18] 則對特徵交互套用 softmax。各工作中的選擇皆以其注意力所依附的語意假設為依據。

我們在第 4 章報告一項單一資料集的觀察：對於我們的 aspect-saliency 合理化，將 softmax 替換為 sigmoid 會損失 7.0% NDCG@20——這是我們所量測到單一元件影響最大者。我們將其解讀為支持「正規化應與合理化的語意假設相符」此一設計啟發，但明確將此觀察定位為待多資料集複製驗證的假設（第 5 章）。

## 2.8 總結與 RA-GARK 的定位

表 3 從四個設計面向匯整比較。在我們稀疏基準上所評估的方法中，RA-GARK 是唯一同時將純 LightGCN 區域聚合器與閘控後期融合的 KG 訊號相結合者，也是唯一將合理化作用於物品—aspect 粒度而非 KG 邊粒度者。

Table 3: 從四個面向所作的設計比較。NDCG@20 於我們的稀疏評論型 KG 基準上報告。

| 方法             | 區域聚合器             | KG 整合          | 合理化                   | NDCG@20       |
|----------------|-------------------|----------------|-----------------------|---------------|
| KGAT           | 雙交互               | 直接傳播           | —                     | 0.1079        |
| KGCL           | KGAT 式            | 傳播 + CL        | —                     | 0.1073        |
| MCCLK          | 多視角               | 多視角 CL         | —                     | 0.1067        |
| KGRec          | KGAT 式            | 傳播 + 邊 dropout | 邊 Bernoulli           | 0.1095        |
| <b>RA-GARK</b> | <b>純 LightGCN</b> | <b>閘控後期融合</b>  | <b>Aspect softmax</b> | <b>0.1238</b> |

我們並不將 RA-GARK 定位為相對於四個基線的嚴格改進。RA-GARK 在設計空間中佔據一個不同的位置——其特徵在於將 KG 視為可被明確閘控的旁路通道，而非必要的管線組件。此選擇在我們的稀疏 KG 情境中產出強勁結果，而基於閘控的優雅退化性質，在 KG 品質不均或模型部署於 KG 密度差異各異的多個領域時，或許亦能派上用場。然而，當 KG 稠密且品質一致地可靠時，KGAT 或 KGRec 這類深度融合方法可能仍較佳，因為後期融合的設計犧牲了深度融合架構所具有的部分表徵表達力。

# Chapter 3

## 方法

本章呈現 RA-GARK 之完整方法。第 3.1 節說明使 RA-GARK 有別於第 2 章所回顧之深度融合基線的核心設計原則。第 3.2 節以泳道圖 (swim-lane) 呈現推論時的整體資料流。第 3.3 節固定符號。第 3.4 節形式化推薦任務與訓練目標。第 3.5 至 3.9 節依模組於前向傳遞中的順序逐一詳述各模組；第 3.10 節說明訓練程序與計算複雜度。

### 3.1 設計原則：KG 作為可被開控的旁路通道

第 1 章的經驗觀察是：在本研究稀疏的評論衍生知識圖譜 (KG) 上，四種具代表性的 KG-aware 方法 (KGAT、KGCL、MCCLK、KGRec) 皆被純 LightGCN 一致地超越。這些基線所共有的結構性失因在於：KG 被當作評分管線的必要組件串接進來——KG 實體嵌入直接參與訊息傳遞，且無任何架構性的開關能在 KG 被證實不可靠時將其脫接。因此 KG 雜訊與協同表示共享同一條梯度流。

RA-GARK 圍繞一個直接面對此失效模式的核心設計原則：

*KG 不應為評分管線的必要組件，而應為一條旁路通道；其對最終分數的貢獻由一個學習得到的開決定，開在初始化時偏置至一個安全預設（純協同過濾），僅在訓練訊號顯示 KG 通道能降低損失時才被打開。*

此原則衍生三項架構層級的後果，並共同定義 RA-GARK：

1. **雙條平行視角。**區域視角透過在使用者—物品互動圖上運行 LightGCN 產生純協同表示  $(u_{loc}, i_{loc})$ ，過程中完全不涉及 KG。全域視角則由獨立的使用者嵌入表與物品端的潛在面向槽產生 KG 表示  $(u_{glo}, i_{glo})$ ，過程中亦不涉及協同訊號。直至融合階段之前，兩條視角在結構上完全分離。



2. **後期、開控的融合**。兩條視角僅在最終評分階段被融合開合併；該開針對每組（使用者，物品）配對輸出一個混合權重  $\alpha \in (0, 1)$ 。開以偏置初始化使  $\alpha^{(0)} \approx 0.993$ ，模型訓練起點實質等同於純 LightGCN，KG 通道僅在梯度將  $\alpha$  推低時逐步開啟。
3. **合理化感知的物品端聚合**。每件物品的 KG 語意儲存於  $A = 4$  個潛在面向槽中，槽位內容由 IDF 加權商品一面向矩陣之截斷 SVD 產生；softmax aspect-saliency 注意力依（使用者，物品）配對選取代表該物品的潛在槽。

每項後果均於第 3 章中數學化。本章其餘部分將符號與問題陳述定位至足以使第 3 章自洽所需之細節層級。

## 3.2 架構概覽

圖 1 勾勒了推論時的資料流。模型被布置為對應區域與全域視角的兩條水平泳道，於右側由融合階段匯合。區域視角（上方泳道）對使用者—物品互動圖套用 LightGCN，得到  $(u_{loc}, i_{loc})$ 。全域視角（下方泳道）直接以查表得到使用者的全域嵌入  $u_{glo}$ ，並對物品的  $A = 4$  個潛在面向槽施加 softmax 合理化遮罩以得  $i_{glo}$ ；面向槽本身為 SVD 初始化（圖中以虛線標註）。兩條視角由獨立的使用者側與物品側融合開混合，每個開的偏置初始化為 +5；最終分數為內積  $\langle u_{final}, i_{final} \rangle$ 。為求清晰，跨視角對比學習路徑於圖中省略，詳見第 3.9 節。




Figure 1: RA-GARK 架構。

兩項結構性質值得在形式化呈現之前先點明。其一， $u_{glo}$  並不經過合理化遮罩模組，而是由直接查表得到，並逕送至使用者側融合開；合理化遮罩僅作用於物品側，符合

「合理化回答的是『此物品的哪個面向對此使用者重要』」這一語意。其二，KG-SVD 步驟為初始化而非前向運算：SVD 於訓練前計算一次以設定面向槽參數的初值，其後槽位即如其他參數般以梯度下降更新。

### 3.3 符號

本論文後續使用之符號列於表 4。

Table 4: 本章與後續章節所使用之符號。

| 符號                                                     | 意義                                           |
|--------------------------------------------------------|----------------------------------------------|
| $\mathcal{U}, \mathcal{I}$                             | 使用者集合與物品集合                                   |
| $\mathcal{R} \subseteq \mathcal{U} \times \mathcal{I}$ | 已觀察到的使用者—物品互動                                |
| $\mathcal{G}_{\text{KG}}$                              | 物品—面向知識圖譜（評論衍生）                              |
| $\mathcal{A}$                                          | $\mathcal{G}_{\text{KG}}$ 中出現之 unique 面向標籤集合 |
| $A$                                                    | 每件物品的潛在面向槽數（ $A = 4$ ）                       |
| $d$                                                    | 嵌入維度（除另行指定， $d = 64$ ）                       |
| $K$                                                    | LightGCN 傳播層數（ $K = 2$ ）                     |
| $u_{\text{loc}}, i_{\text{loc}} \in \mathbb{R}^d$      | 區域視角（LightGCN）嵌入                             |
| $u_{\text{glo}} \in \mathbb{R}^d$                      | 全域視角使用者嵌入（直接查表）                              |
| $\mathbf{a}_i \in \mathbb{R}^{A \times d}$             | 物品 $i$ 之潛在面向槽（SVD 初始化）                       |
| $i_{\text{glo}} \in \mathbb{R}^d$                      | 全域視角物品嵌入（合理化遮罩後）                             |
| $\alpha_u, \alpha_i \in (0, 1)$                        | 使用者側與物品側融合閘輸出                                |
| $\hat{y}(u, i) \in \mathbb{R}$                         | 對配對 $(u, i)$ 之預測偏好分數                         |

### 3.4 問題定式

**任務。** 本文處理隱式回饋設定下的 top- $K$  推薦。給定  $\mathcal{U}$ 、 $\mathcal{I}$ 、已觀察到的互動  $\mathcal{R}$ ，以及物品—面向 KG  $\mathcal{G}_{\text{KG}}$ ，目標是為每位使用者  $u \in \mathcal{U}$  從  $\mathcal{I} \setminus \{i : (u, i) \in \mathcal{R}\}$  中產生一個排序清單，並以排序指標（NDCG@ $K$ 、Recall@ $K$ 、Hit@ $K$ ）對保留之測試互動集進行評估。

**評分函數。** RA-GARK 對每組  $(u, i)$  配對指派內積分數

$$\hat{y}(u, i) = \langle u_{\text{final}}, i_{\text{final}} \rangle, \quad (3.1)$$

其中  $u_{\text{final}}$  與  $i_{\text{final}}$  由區域與全域表示的閘控融合產生：

$$u_{\text{final}} = \alpha_u u_{\text{loc}} + (1 - \alpha_u) u_{\text{glo}}, \quad i_{\text{final}} = \alpha_i i_{\text{loc}} + (1 - \alpha_i) i_{\text{glo}}. \quad (3.2)$$

閘輸出  $\alpha_u, \alpha_i$  分別由獨立的 MLP 計算（第 3.8 節）。在本論文採用的偏置初始化下， $\alpha_u^{(0)}, \alpha_i^{(0)} \approx 0.993$ ，因此  $\hat{y}^{(0)}(u, i) \approx \langle u_{\text{loc}}, i_{\text{loc}} \rangle$ ，即訓練起點之分數實質為純 LightGCN 之分數，直至閘藉學習而調整。

**訓練目標。** 我們以 Bayesian Personalized Ranking (BPR) [19] 損失為主體，並輔以兩條跨視角對比正則化：

$$\mathcal{L} = \mathcal{L}_{\text{BPR}} + \lambda_{\text{CL}} (\mathcal{L}_{\text{aCL}} + \mathcal{L}_{\text{uCL}}), \quad (3.3)$$

其中對每組已觀察配對  $(u, i^+) \in \mathcal{R}$  與一個取樣的負例物品  $i^- \notin \mathcal{R}_u$ ，

$$\mathcal{L}_{\text{BPR}} = -\log \sigma(\hat{y}(u, i^+) - \hat{y}(u, i^-)), \quad (3.4)$$

而  $\mathcal{L}_{\text{aCL}}, \mathcal{L}_{\text{uCL}}$  分別為  $(i_{\text{loc}}, i_{\text{glo}})$  與  $(u_{\text{loc}}, u_{\text{glo}})$  之間的 InfoNCE 式對齊損失；全域側施加 stop-gradient 以避免對比梯度擾動 SVD 初始化之面向槽（第 3.9 節）。對比權重  $\lambda_{\text{CL}}$  固定為 0.005，使對比的角色為輔助而非主要。

## 3.5 區域視角：LightGCN

區域視角僅由使用者—物品互動圖產生純協同表示  $(u_{\text{loc}}, i_{\text{loc}})$ ；此分支內部完全不施加任何 KG 運算。其架構與 LightGCN [1] 完全相同。

### 3.5.1 動機

選擇 LightGCN 作為區域視角骨幹的理由有三。其一，在本論文所使用之稀疏評論衍生 KG 上，純 LightGCN 已超越我們所評估的全部四個 KG-aware 基線（第 1 章），故為任何後續設計必須可被證實能改善的最強無 KG 起點。其二，其參數化極為精簡——僅有使用者與物品的嵌入表，傳播過程中無任何學習權重——這限制了兩條視角後續耦合時 KG 雜訊得以滲入協同梯度流的接觸面。其三，傳播為純線性，故每層對最終表示的貢獻可由閉式之層平均直接讀出，從而能在不受非線性干擾的前提下，理性化關於閘的放置（第 3.8 節）與對比對齊（第 3.9 節）的設計決策。

### 3.5.2 圖的建構

令  $\mathbf{R} \in \{0, 1\}^{|\mathcal{U}| \times |\mathcal{I}|}$  為由  $\mathcal{R}$  衍生的使用者—物品互動矩陣，其中  $\mathbf{R}_{u,i} = 1$  當且僅當  $(u, i) \in \mathcal{R}$ 。據此建構二部圖鄰接矩陣

$$\mathbf{A} = \begin{bmatrix} \mathbf{0} & \mathbf{R} \\ \mathbf{R}^\top & \mathbf{0} \end{bmatrix} \in \mathbb{R}^{(|\mathcal{U}|+|\mathcal{I}|) \times (|\mathcal{U}|+|\mathcal{I}|)}, \quad (3.5)$$

並施加對稱歸一化

$$\tilde{\mathbf{A}} = \mathbf{D}^{-1/2} \mathbf{A} \mathbf{D}^{-1/2}, \quad \mathbf{D} = \text{diag}(\mathbf{A} \mathbf{1}). \quad (3.6)$$

此歸一化降低了與高度使用者或熱門物品相鄰之邊的權重，於實務上有助於穩定長尾互動分布下的訓練。

### 3.5.3 傳播

令  $\mathbf{E}^{(0)} \in \mathbb{R}^{(|\mathcal{U}|+|\mathcal{I}|) \times d}$  為初始嵌入表，前  $|\mathcal{U}|$  列為使用者嵌入，其餘  $|\mathcal{I}|$  列為物品嵌入；兩區塊皆以 Xavier-normal 初始化。第  $\ell$  層由單次歸一化鄰居聚合得到：

$$\mathbf{E}^{(\ell+1)} = \tilde{\mathbf{A}} \mathbf{E}^{(\ell)}, \quad \ell = 0, 1, \dots, K-1. \quad (3.7)$$

過程中無任何可學習權重矩陣、無非線性、無自迴圈偏置——整個區域視角所有可學習參數即為  $\mathbf{E}^{(0)}$  的  $|\mathcal{U}|d + |\mathcal{I}|d$  個元素。

### 3.5.4 層平均與輸出

採用 LightGCN 標準的層平均

$$\bar{\mathbf{E}} = \frac{1}{K+1} \sum_{\ell=0}^K \mathbf{E}^{(\ell)}, \quad (3.8)$$

並由  $\bar{\mathbf{E}}$  對應列讀出  $u_{\text{loc}}$  與  $i_{\text{loc}}$ 。本論文使用  $K = 2$ ，與原始 LightGCN 論文一致，亦為我們純區域驗證損失趨於平台的深度。

如此得到的嵌入對僅由使用者—物品互動圖提供資訊；區域視角僅透過第 3.8 節之融合階段參與最終分數  $\hat{y}(u, i)$ ，訓練過程中不容許任何 KG 訊號改變  $u_{\text{loc}}$  或  $i_{\text{loc}}$ 。

### 3.6 全域視角：KG-SVD 初始化

全域視角引入一獨立的使用者側嵌入  $u_{\text{glo}}$ （直接查表，見下文）與一物品側參數張量以儲存各物品之 KG 語意。此物品側張量為 RA-GARK 中唯一容許 KG 內容進入模型之處。本節說明該張量之參數化方式及其值如何初始化。

#### 3.6.1 面向槽作為物品側 KG 表示

每件物品  $i$  在全域視角中由面向槽張量

$$\mathbf{a}_i \in \mathbb{R}^{A \times d}, \quad A = 4 \quad (3.9)$$

表示，將所有物品的張量集合為一可學習參數  $\mathbf{A}_{\text{KG}} \in \mathbb{R}^{|I| \times A \times d}$ 。初始化（下節說明）之後， $\mathbf{A}_{\text{KG}}$  即如其他參數般以梯度下降更新。

此處有一關鍵釐清：槽位數  $A = 4$  為模型超參數，不對應於每件物品的固定原始面向標籤數。在本論文使用的評論衍生 KG 中，每件物品平均僅持有 2.4 條面向邊，全域面向標籤詞彙遠大於  $A$  ( $|A| \gg A$ )。此四個槽位為面向誘導語意子空間中的潛在方向，跨全體物品共同學習，而非綁定於特定標籤。

#### 3.6.2 共現矩陣

從二值物品一面向共現矩陣  $\mathbf{M} \in \{0, 1\}^{|I| \times |A|}$  出發：

$$\mathbf{M}_{i,a} = \begin{cases} 1, & (i, a) \in \mathcal{G}_{\text{KG}}, \\ 0, & \text{否則} \end{cases} \quad (3.10)$$

$\mathbf{M}$  的每一列因此是一個稀疏指示向量：每件物品至多只有少數幾個非零項；經剪枝後（第 4.1 節）全域密度對應於每列平均 2.4 個 1。

#### 3.6.3 IDF 加權

部分面向標籤橫跨許多物品（如「文筆優美」、「引人入勝」），其他則高度特定（如某個利基類型或主題）。若不修正，後續 SVD 將由高頻標籤主導，所產生的潛在方向

實質上只是熱門度先驗。我們以標準的逆文件頻率（IDF）重新加權緩解此問題：

$$\text{idf}(a) = \log \left( \frac{|\mathcal{I}|}{|\{i : \mathbf{M}_{i,a} = 1\}| + 1} \right) + 1, \quad (3.11)$$

並依 IDF 重新縮放  $\mathbf{M}$  各行：

$$\tilde{\mathbf{M}}_{i,a} = \text{idf}(a) \cdot \mathbf{M}_{i,a}. \quad (3.12)$$

分母中之  $+1$  避免對所有物品支持已被剪除之面向除以零；對數外之  $+1$  防止最大頻率面向的 IDF 退化為零。兩項調整皆為標準作法。

### 3.6.4 截斷 SVD

對  $\tilde{\mathbf{M}}$  計算秩  $k$  之截斷 SVD：

$$\tilde{\mathbf{M}} \approx \mathbf{U}_k \Sigma_k \mathbf{V}_k^\top, \quad \mathbf{U}_k \in \mathbb{R}^{|\mathcal{I}| \times k}, \quad (3.13)$$

其中  $k = A \cdot d$ 。左奇異矩陣  $\mathbf{U}_k$  每件物品一列；各列位於一  $k$  維潛在子空間，於其中 IDF 加權的面向共現於秩  $k$  下被最佳解釋。

接著形成每件物品的潛在嵌入，將每個分量以對應奇異值之平方根縮放：

$$\mathbf{E}_{\text{KG}} = \mathbf{U}_k \Sigma_k^{1/2} \in \mathbb{R}^{|\mathcal{I}| \times k}. \quad (3.14)$$

此平方根縮放使譜能量均勻分布於左右因子，為標準選擇，所得嵌入之兩兩內積近似 IDF 加權共現內容。

### 3.6.5 重塑為槽位與量值縮放

寬度為  $k = Ad$  的展平嵌入  $\mathbf{E}_{\text{KG}}$  被重塑為每件物品  $A$  個寬度  $d$  的槽：

$$\mathbf{A}_{\text{KG}}^{(0)}[i, k, :] = \mathbf{E}_{\text{KG}}[i, kd : (k+1)d], \quad k = 0, \dots, A-1. \quad (3.15)$$

槽因此是 SVD 輸出中互不相交的連續區塊；它們不對應於可獨立解讀的面向標籤。

由於  $\mathbf{E}_{\text{KG}}$  之量值依賴於  $|\mathcal{I}|$ 、 $|A|$  與  $\tilde{\mathbf{M}}$  的譜，未經縮放的 SVD 輸出與模型他處 Xavier 初始化參數不在同一量級。我們因此將整個  $\mathbf{A}_{\text{KG}}^{(0)}$  重新縮放，使其經驗標準差匹配 Xavier-normal 目標  $\sigma = \sqrt{2/(A+d)}$ 。此縮放保留 SVD 輸出的角度幾何——也正是我們想注入的——同時使槽位量值與其餘最佳化過程相容。

### 3.6.6 演算法

完整初始化可總結為五步：

1. 由  $\mathcal{G}_{\text{KG}}$  建構二值共現矩陣  $\mathbf{M}$  (式 (3.10))。
2. 套用 IDF 列加權得  $\tilde{\mathbf{M}}$  (式 (3.12))。
3. 計算秩  $k = Ad$  之截斷 SVD： $\tilde{\mathbf{M}} \approx \mathbf{U}_k \Sigma_k \mathbf{V}_k^\top$  (式 (3.13))。
4. 形成  $\mathbf{E}_{\text{KG}} = \mathbf{U}_k \Sigma_k^{1/2}$  並重塑為  $\mathbf{A}_{\text{KG}}^{(0)} \in \mathbb{R}^{|\mathcal{I}| \times A \times d}$  (式 (3.15))。
5. 整體重新縮放使標準差匹配 Xavier-normal 目標。

若  $|\mathcal{A}| < Ad$ ，SVD 秩被限制為  $|\mathcal{A}| - 1$ ，剩餘槽維度於縮放前以小量高斯雜訊（標準差 0.01）填補；在我們的實驗中  $|\mathcal{A}| \gg Ad$ ，故此降階路徑不被觸發。

### 3.6.7 此初始化所帶來的效益

KG-SVD 初始化的貢獻於第 4.4.1 節以消融衡量：將其替換為相同張量形狀之 Xavier-normal 隨機初始化會損失 5.3% NDCG@20。其解釋是：SVD 初始化在訓練起點即保留了面向誘導語意子空間的角度幾何；其後梯度下降可微調此幾何，但在我們的稀疏 KG 條件下，難以由隨機初始化恢復——能恢復此幾何的梯度訊號需流經對比損失（ $\lambda_{\text{CL}} = 0.005$ ），訊號微弱。

佔位：KG-SVD 初始化流程  
 (物品—面向矩陣  $\rightarrow$  IDF 加權  $\rightarrow$  截斷 SVD  $\rightarrow$  reshape 至  $[|\mathcal{I}|, A, d]$ )。

Figure 2: KG-SVD 初始化流程。

## 3.7 全域視角：Softmax 合理化遮罩

給定物品的面向槽張量  $\mathbf{a}_i \in \mathbb{R}^{A \times d}$  與使用者側全域嵌入  $u_{\text{glo}} \in \mathbb{R}^d$ ，合理化遮罩模組選取  $A$  個潛在槽中最能在該使用者下代表該物品者，得到全域視角物品嵌入  $i_{\text{glo}}$ 。使用

者側全域嵌入本身為直接查表

$$u_{\text{glo}} = \mathbf{E}_u^{\text{glo}}, \quad \mathbf{E}^{\text{glo}} \in \mathbb{R}^{|\mathcal{U}| \times d}, \quad (3.16)$$

其中  $\mathbf{E}^{\text{glo}}$  為與區域視角使用者表分離的可學習參數；使用者側不施加任何合理化運算。

### 3.7.1 動機

每件物品的 KG 語意分散儲存於  $\mathbf{a}_i$  的  $A$  個潛在槽中；不同槽位編碼 SVD 可見之不同語意面向。然而給定使用者並非「同時透過物品之全部語意面向」與物品互動——其偏好通常由一或兩個面向主導。合理化模組的職責即在每組（使用者, 物品）配對中，挑出與該使用者表示  $u_{\text{glo}}$  最一致的槽。

### 3.7.2 使用者條件之注意力 logits

對每個槽  $k \in \{1, \dots, A\}$ ，計算一純量 logit

$$\ell_{u,i,k} = \text{MLP}([u_{\text{glo}} \parallel \mathbf{a}_{i,k}]) \in \mathbb{R}, \quad (3.17)$$

其中  $\parallel$  表沿嵌入維度串接，MLP 參數於所有槽與物品間共享。MLP 為兩層前饋區塊：

$$\text{MLP}(\mathbf{z}) = \mathbf{w}^\top \cdot \text{LeakyReLU}(\mathbf{W} \mathbf{z}), \quad (3.18)$$

其中  $\mathbf{W} \in \mathbb{R}^{d \times 2d}$ 、 $\mathbf{w} \in \mathbb{R}^d$ 。跨槽共享參數至關重要：它迫使 MLP 學到一個與槽無關的「此槽與此使用者契合程度」概念，而非為每個槽記憶各自的評分函數。

### 3.7.3 Softmax 歸一化

$A$  個 logit 透過溫度  $\tau$  之 softmax 歸一化為槽位之機率分布：

$$w_{u,i,k} = \frac{\exp(\ell_{u,i,k}/\tau)}{\sum_{k'=1}^A \exp(\ell_{u,i,k'}/\tau)}. \quad (3.19)$$

依建構  $\sum_k w_{u,i,k} = 1$ ， $A$  個槽位權重彼此競爭：增加某槽相對權重必使其餘槽位下降。我們使用  $\tau = 0.5$ ，相對於無資訊先驗（ $\tau = 1$  在  $\text{logit} = 0$  時得完全均勻）銳化分布，將質量集中於對使用者最相關之槽。溫度掃描見第 4.5.1 節。



### 3.7.4 加權聚合

全域視角物品嵌入為槽加權平均

$$i_{\text{glo}} = \sum_{k=1}^A w_{u,i,k} \cdot \mathbf{a}_{i,k} \in \mathbb{R}^d. \quad (3.20)$$

實作上即為「合理化遮罩」步驟：softmax 權重作為槽維度上的軟遮罩，被遮罩之槽位再加總回單一  $d$  維向量。雖然式 (3.19) 與 (3.20) 概念上為兩步，但在程式中於單一模組 (KGRationaleMasking) 內以一次前向呼叫完成。

### 3.7.5 為何使用 Softmax 而非 Sigmoid

一個自然的替代是對每個槽獨立以 sigmoid 評分： $w_{u,i,k} = \sigma(\ell_{u,i,k})$ ，不施加跨槽歸一化。這表達了不同的語意假設：每個槽對使用者獨立地相關或不相關；多個槽可同時「開啟」而不相互競爭。

實證上 sigmoid 變體會使本基準 NDCG@20 下降 7.0% (第 4.4.2 節)——是我們所觀察到單一元件影響最大者。我們解讀為：對於面向顯著性合理化而言，正確的語意假設是競爭而非獨立——在  $A$  個潛在槽中，合理化回答的是「哪一個」最具代表性，而答案近似為 one-hot。Softmax 直接編碼此假設，sigmoid 則否。我們在第 5 章對此發現作更謹慎之討論，並明確將其定位為單一資料集觀察，需多資料集複製驗證。




Figure 3: Softmax 合理化遮罩。

## 3.8 區域偏置融合開

融合開是將 RA-GARK 設計原則 (KG 為可被開控之旁路通道) 落實為具體運算的架構機制。它將區域與全域表示結合為最終嵌入，並由其產生分數。

### 3.8.1 雙側獨立閘

RA-GARK 使用兩個獨立融合閘，使用者側與物品側各一。兩者皆為純量閘，以該側區域與全域嵌入之串接為條件：

$$\alpha_u = \text{Gate}_u([u_{\text{loc}} \parallel u_{\text{glo}}]) \in (0, 1), \quad (3.21)$$

$$\alpha_i = \text{Gate}_i([i_{\text{loc}} \parallel i_{\text{glo}}]) \in (0, 1). \quad (3.22)$$

兩閘參數獨立；經驗上共享參數會劣化結果，因為在稀疏 KG 下 KG 訊號對使用者側與物品側嵌入的邊際資訊量不同。

最終各側嵌入為凸組合

$$u_{\text{final}} = \alpha_u u_{\text{loc}} + (1 - \alpha_u) u_{\text{glo}}, \quad i_{\text{final}} = \alpha_i i_{\text{loc}} + (1 - \alpha_i) i_{\text{glo}}, \quad (3.23)$$

最終分數為內積  $\hat{y}(u, i) = \langle u_{\text{final}}, i_{\text{final}} \rangle$ ，如式 (3.1) 已述。

### 3.8.2 閘的結構

每個 Gate 為一帶 sigmoid 頭之小型 MLP：

$$\text{Gate}(\mathbf{z}) = \sigma(\mathbf{w}^\top \tanh(\mathbf{W}\mathbf{z}) + b), \quad (3.24)$$

其中  $\mathbf{W} \in \mathbb{R}^{d \times 2d}$ 、 $\mathbf{w} \in \mathbb{R}^d$ 、 $b$  為純量偏置、 $\sigma$  為邏輯函數。隱藏層寬度與嵌入維度一致。第一層權重  $\mathbf{W}$  以 Xavier-uniform 初始化、偏置為零；第二層權重  $\mathbf{w}$  同樣以 Xavier-uniform 初始化；第二層偏置  $b$  即下節要特別初始化者。

### 3.8.3 區域偏置初始化

關鍵設計選擇為式 (3.24) 中純量偏置  $b$  的初始化。當  $b = 0$ ，訓練起點之閘輸出約為  $\sigma(0) = 0.5$ ，即區域與全域 50/50 混合。由於全域視角部分由帶雜訊之 KG 初始化，50/50 起點將使區域表示整個訓練過程中皆暴露於 KG 雜訊；而第 1 章已觀察到此正是深度融合基線的失效模式。

我們改將兩個閘的偏置皆初始化為  $b = +5$ 。訓練起點之閘輸出因此為

$$\alpha^{(0)} \approx \sigma(b) = \sigma(5) \approx 0.993, \quad (3.25)$$

初始混合約為

$$u_{\text{final}}^{(0)} \approx 0.993 u_{\text{loc}}^{(0)} + 0.007 u_{\text{glo}}^{(0)}, \quad (3.26)$$

物品側類似。換言之，RA-GARK 訓練起點實質為純 LightGCN。KG 通道起初僅開啟 0.7%；唯當 BPR 損失對  $b$  之梯度將  $b$  向下推動時——亦即拓寬 KG 通道能降低損失時——通道才會被擴大。偏置作為一個學習得到的、傾向安全預設之先驗。

### 3.8.4 優雅退化

區域偏置初始化提供結構性保證：若 KG 結果為完全無資訊，閘將維持於  $\alpha \approx 1$  附近，KG 項對分數的貢獻被上界約為  $0.007 \cdot \|\mathbf{a}\| \cdot \|\mathbf{u}\|$ ，模型於經驗上與純 LightGCN 無從區分。第 1 章所列之四個基線皆無此性質：每個都強制 KG 實體嵌入無論其是否具資訊量皆參與傳播路徑。

此即 Highway Networks [10] 嚴格架構意義下的優雅退化性質，自網路內部跳接移植至視角間融合。據我們所知，尚無 KG-aware 推薦器採此設計。

### 3.8.5 為何選 $+5$ 而非 $+\infty$

偏置量值之選擇依單一原則：大到使初始閘輸出絕對偏向區域、小到使  $b$  之梯度非零而能於訓練中調整閘。於  $b = +5$ ， $\sigma'(5) = \sigma(5)(1 - \sigma(5)) \approx 0.007$ ——雖小但未消失。 $b = +10$  之後  $b$  上之梯度於數值上可忽略，閘無法學會開啟。 $b = +5$  為使  $\alpha^{(0)} > 0.99$  同時保持  $\sigma'(b) > 10^{-3}$  之最小整數，並通過敏感性掃描不需進一步調整（第 4.5.3 節）。完全移除偏置初始化（設  $b = 0$ ）會損失 5.3% NDCG@20（第 4.4.3 節）。




Figure 4: 區域偏置融合閘。

## 3.9 跨視角對比正則化

區域與全域視角於結構上異質：一者為來自互動的協同表示，另一者為 KG 衍生表示，二者位於不同歸納子空間。若無任何明確對齊，兩表示在訓練過程中可能漂移至  $\mathbb{R}^d$  中彼此不相容之區域，此時融合閘所合併的向量並非直接可比。跨視角對比正則化即在處理此幾何錯位。

### 3.9.1 在架構中的角色

於 RA-GARK 中，對比損失扮演刻意受限之角色。它們並非主要整合機制——此角色由融合閘擔任（第 3.8 節）——而是將兩視角推向共享角度幾何的正則化項。具體而言，我們刻意不使用對比學習讓 KG 通道「掙得」其進入模型之資格，如 KGCL [5] 與 MCCLK [6] 所為；那將重新引入「將 KG 訊號視為必經主融合路徑」的失效模式。

### 3.9.2 面向層級對比損失

對訓練批次中每件物品  $i$ ，將其投影後的區域嵌入與其  $A$  個面向槽分別對比：

$$\mathcal{L}_{\text{aCL}} = \frac{1}{A} \sum_{k=1}^A \text{InfoNCE}(g(i_{\text{loc}}), \text{sg}[\mathbf{a}_{i,k}]), \quad (3.27)$$

其中  $g: \mathbb{R}^d \rightarrow \mathbb{R}^d$  為可學習投影頭（兩層 MLP 加 ReLU），僅施加於區域側輸入； $\text{sg}[\cdot]$  表示 stop-gradient；InfoNCE 為標準對比目標

$$\text{InfoNCE}(\mathbf{x}, \mathbf{y}) = -\log \frac{\exp(\langle \mathbf{x}, \mathbf{y} \rangle / \tau_{\text{CL}})}{\sum_{j=1}^B \exp(\langle \mathbf{x}, \mathbf{y}_j \rangle / \tau_{\text{CL}})}, \quad (3.28)$$

$\tau_{\text{CL}} = 0.2$ 、 $B$  為批次大小（負例為批次內其餘物品）。向量於內積之前皆作  $\ell_2$  歸一化。

### 3.9.3 使用者層級對比損失

對稱之使用者層級損失對齊區域與全域使用者嵌入：

$$\mathcal{L}_{\text{uCL}} = \text{InfoNCE}(g(u_{\text{loc}}), \text{sg}[u_{\text{glo}}]). \quad (3.29)$$

投影頭  $g$  與  $\mathcal{L}_{\text{aCL}}$  共享，因兩損失皆作用於區域側輸入，且我們希望投影編碼單一之「區域視角如何映射至全域視角角度幾何」變換。

### 3.9.4 全域側 Stop-Gradient

式 (3.27) 與 (3.29) 中 KG 側之 stop-gradient 在結構上至關重要。若無，對比梯度會反向傳遞至 SVD 初始化的面向槽與全域使用者表，逐漸破壞 KG-SVD 初始化所安裝之角度幾何（第 3.6 節）。配合 stop-gradient 後，對比損失作用不對稱：能將區域視角拉向全域視角已有之幾何，但無法把全域視角向任何方向推動。KG 衍生語意子空間被保留為外部參照，由區域視角承擔對齊代價。

### 3.9.5 損失權重

式 (3.3) 中對比權重  $\lambda_{\text{CL}}$  固定為 0.005。此值小到使對比損失於總梯度中貢獻一非主導比例（BPR 仍為主要訊號），亦與第 3.9.1 節所賦予對比正則化之角色一致：幾何先驗，非主要學習目標。我們不對  $\lambda_{\text{CL}}$  作資料集相關調參。

## 3.10 訓練與計算複雜度

### 3.10.1 總目標

完整訓練損失已於式 (3.3) 給出，此處為完整性重述：

$$\mathcal{L} = \mathcal{L}_{\text{BPR}} + \lambda_{\text{CL}}(\mathcal{L}_{\text{aCL}} + \mathcal{L}_{\text{uCL}}). \quad (3.30)$$

BPR 損失提供主要排序訊號；對比項提供跨視角幾何對齊。

### 3.10.2 最佳化

以 Adam（預設  $\beta_1 = 0.9, \beta_2 = 0.999, \epsilon = 10^{-8}$ ）最佳化式 (3.30)，學習率  $10^{-3}$ 、批次大小 128，最多訓練 30 epochs。以驗證集 NDCG@20 之耐心 10 早停。每批次包含 128 組三元組  $(u, i^+, i^-)$ ，其中  $i^-$  自  $\mathcal{R}_u$  之外的物品均勻取樣。式 (3.7)–(3.8) 之 LightGCN 傳播於每批次重新計算一次，並於該批次內正負例評分時共用。

### 3.10.3 推論

推論時，於評估開始時計算 LightGCN 傳播一次並快取  $\bar{\mathbf{E}}$ 。對每個查詢使用者  $u$ ，以單次批次矩陣乘法計算全部物品集合之分數：面向槽、合理化權重、 $i_{\text{glo}}$ 、物品閘以及

與  $u_{\text{final}}$  之內積，皆於整個物品集合上以向量化形式同時評估。

### 3.10.4 計算複雜度

令  $B$  為批次大小、 $|\mathcal{E}_{\mathcal{UI}}|$  為已觀察使用者—物品互動數、 $|\mathcal{I}|$  為物品數、 $A$  為槽位數、 $d$  為嵌入維度、 $K$  為 LightGCN 層數。每批次訓練成本分解如下：

Table 5: 各模組每批次訓練成本。

| 模組                  | 成本                                    |
|---------------------|---------------------------------------|
| LightGCN 傳播         | $O( \mathcal{E}_{\mathcal{UI}}  d K)$ |
| $u_{\text{glo}}$ 查表 | $O(B d)$                              |
| 面向槽讀取               | $O(B A d)$                            |
| 合理化遮罩               | $O(B A d)$                            |
| 使用者與物品融合閘           | $O(B d^2)$                            |
| BPR 與對比損失           | $O(B d)$                              |

LightGCN 傳播項主導訓練成本，與純 LightGCN 基線完全一致。KG 側之新增（面向讀取、合理化遮罩、融合閘）貢獻為  $A$  與  $d$  之線性項，皆相對於傳播為小。RA-GARK 之每 epoch 牆鐘時間因此於純 LightGCN 之小常數倍以內，並於同一硬體與相同嵌入維度下與 KGRec 大致相等（精確牆鐘數字見第 4.8 節）。

全集合推論由使用者條件之物品側合理化遮罩步驟  $O(B \cdot |\mathcal{I}| \cdot A \cdot d)$  主導，於本論文使用之資料集規模下可行。

# Chapter 4

## 實驗

### 4.1 資料集與 KG 建構




Figure 5: 評論衍生 KG 建構 pipeline。

## 4.2 實驗設定

## 4.3 主要結果

## 4.4 消融研究

### 4.4.1 KG-SVD 初始化

### 4.4.2 Softmax 合理化遮罩

### 4.4.3 區域偏置融合閘

## 4.5 敏感性分析

### 4.5.1 Softmax 溫度 $\tau$

### 4.5.2 面向槽數 $A$

### 4.5.3 融合閘偏置

### 4.5.4 對比權重 $\lambda_{\text{CL}}$

## 4.6 種子穩定性

## 4.7 個案研究

## 4.8 計算成本



## Chapter 5

### 結論與未來工作

#### 5.1 結論

#### 5.2 方法論啟示：注意力正規化

#### 5.3 限制

#### 5.4 未來工作

# Bibliography

- [1] X. He, K. Deng, X. Wang, Y. Li, Y. Zhang, and M. Wang, “LightGCN: Simplifying and powering graph convolution network for recommendation,” in *Proc. ACM SIGIR*, 2020, pp. 639–648.
- [2] X. Wang, X. He, M. Wang, F. Feng, and T.-S. Chua, “Neural graph collaborative filtering,” in *Proc. ACM SIGIR*, 2019, pp. 165–174.
- [3] J. Wu, X. Wang, F. Feng, X. He, L. Chen, J. Lian, and X. Xie, “Self-supervised graph learning for recommendation,” in *Proc. ACM SIGIR*, 2021, pp. 726–735.
- [4] X. Wang, X. He, Y. Cao, M. Liu, and T.-S. Chua, “KGAT: Knowledge graph attention network for recommendation,” in *Proc. ACM SIGKDD*, 2019, pp. 950–958.
- [5] Y. Yang, C. Huang, L. Xia, and C. Li, “Knowledge graph contrastive learning for recommendation,” in *Proc. ACM SIGIR*, 2022, pp. 1434–1443.
- [6] D. Zou, W. Wei, X.-L. Mao, Z. Wang, M. Qiu, F. Zhu, and X. Cao, “Multi-level cross-view contrastive learning for knowledge-aware recommender system,” in *Proc. ACM SIGIR*, 2022, pp. 1358–1368.
- [7] Y. Yang, C. Huang, L. Xia, and C. Huang, “Knowledge graph self-supervised rationalization for recommendation,” in *Proc. ACM SIGKDD*, 2023, pp. 3046–3056.
- [8] X. Ren, L. Xia, J. Zhao, D. Yin, and C. Huang, “Disentangled contrastive collaborative filtering,” in *Proc. ACM SIGIR*, 2023, pp. 1137–1146.
- [9] A. van den Oord, Y. Li, and O. Vinyals, “Representation learning with contrastive predictive coding,” *arXiv preprint arXiv:1807.03748*, 2018.
- [10] R. K. Srivastava, K. Greff, and J. Schmidhuber, “Highway networks,” *arXiv preprint arXiv:1505.00387*, 2015.

- [11] J. Ma, Z. Zhao, X. Yi, J. Chen, L. Hong, and E. H. Chi, “Modeling task relationships in multi-task learning with multi-gate mixture-of-experts,” in *Proc. ACM SIGKDD*, 2018, pp. 1930–1939.
- [12] H. Tang, J. Liu, M. Zhao, and X. Gong, “Progressive layered extraction (PLE): A novel multi-task learning model for personalized recommendations,” in *Proc. ACM RecSys*, 2020, pp. 269–278.
- [13] Z. Wang, G. Lin, H. Tan, Q. Chen, and X. Liu, “CKAN: Collaborative knowledge-aware attentive network for recommender systems,” in *Proc. ACM SIGIR*, 2020, pp. 219–228.
- [14] H. Wang, F. Zhang, M. Zhao, W. Li, X. Xie, and M. Guo, “Multi-task feature learning for knowledge graph enhanced recommendation,” in *Proc. The Web Conference (WWW)*, 2019, pp. 2000–2010.
- [15] X. Wang, T. Huang, D. Wang, Y. Yuan, Z. Liu, X. He, and T.-S. Chua, “Learning intents behind interactions with knowledge graph for recommendation,” in *Proc. The Web Conference (WWW)*, 2021, pp. 878–887.
- [16] G. Zhou, X. Zhu, C. Song, Y. Fan, H. Zhu, X. Ma, Y. Yan, J. Jin, H. Li, and K. Gai, “Deep interest network for click-through rate prediction,” in *Proc. ACM SIGKDD*, 2018, pp. 1059–1068.
- [17] X. He, Z. He, J. Song, Z. Liu, Y.-G. Jiang, and T.-S. Chua, “NAIS: Neural attentive item similarity model for recommendation,” *IEEE Transactions on Knowledge and Data Engineering*, vol. 30, no. 12, pp. 2354–2366, 2018.
- [18] J. Xiao, H. Ye, X. He, H. Zhang, F. Wu, and T.-S. Chua, “Attentional factorization machines: Learning the weight of feature interactions via attention networks,” in *Proc. International Joint Conference on Artificial Intelligence (IJCAI)*, 2017, pp. 3119–3125.
- [19] S. Rendle, C. Freudenthaler, Z. Gantner, and L. Schmidt-Thieme, “BPR: Bayesian personalized ranking from implicit feedback,” in *Proc. Conference on Uncertainty in Artificial Intelligence (UAI)*, 2009, pp. 452–461.