

基於理由感知閘控的稀疏評論面向知識圖譜推薦架構

學生：預覽用

指導教授：預覽用 博士

國立陽明交通大學資訊學院碩士在職專班

摘要

知識圖譜感知 (KG-aware) 推薦系統在 KG 稠密且品質良好時普遍能提升準確度，但當 KG 稀疏或品質不佳時——即評論衍生、冷啟動、隱私受限等常見場景——既有研究探討有限。本文以書評衍生 KG 為例（過濾後每件商品平均 2.4 條邊），觀察到四個代表性方法 (KGAT、KGCL、MCCLK、KGRec) 皆不及完全不使用 KG 的純 LightGCN，原因在於這些方法將 KG 訊號作為計分管線之必經成分，缺乏在 KG 不可信時切斷或弱化的機制，KG 雜訊因此污染協同表示之梯度流。

本文提出 RA-GARK (Rationale-Aware Gating over Review-Aspect Knowledge graphs)，將 KG 視為可閘控之側通道。核心為本地偏置融合閘，依每組（使用者, 商品）動態調整協同與 KG 兩訊號之相對權重；偏置初始化為 +5，使訓練起點等同於純 LightGCN，僅在梯度顯示 KG 有益時才逐步開啟，提供結構性優雅退化。每件商品之 KG 語意以 $A = 4$ 個潛在面向槽儲存，由 IDF 加權商品—面向共現矩陣之截斷 SVD 初始化，並以 softmax 注意力挑選最具顯著性之槽位。實驗中 RA-GARK 於 NDCG@20 達 0.1238，較最強 KG-aware 基準 KGRec 提升 13.1%、較純 LightGCN 提升 5.0%，在 KG 不變的條件下將其貢獻自「無益」翻轉為「有益」。消融顯示：softmax 替換為 sigmoid 損失 7.0% NDCG，移除偏置融合閘或 KG-SVD 初始化各損失 5.3%。注意力歸一化之觀察定位為單一資料集之待驗證假說。

關鍵字：知識圖譜推薦；可退化機制；融合閘；稀疏知識圖譜；協同過濾

Contents

1	緒論	1
1.1	研究背景	1
1.2	稀疏 KG 下的經驗異常現象	1
1.3	稀疏 KG 作為現實世界的常態	2
1.4	研究問題	2
1.5	研究貢獻	3
1.6	論文組織	4
2	相關研究	5
2.1	基礎：LightGCN 與 KGAT	5
2.2	對比式知識圖譜方法	6
2.3	合理化感知推薦：KGRec	6
2.4	合理化典範：共同前提與分歧的可信度假設	7
2.5	深度學習中的閘控機制	8
2.6	缺口：KG-Aware 推薦中沒有融合閘	8
2.7	注意力正規化	9
2.8	總結與 RA-GARK 的定位	10
3	方法	11
3.1	設計原則：KG 作為可被閘控的旁路通道	11
3.2	架構概覽	12
3.3	符號	13
3.4	問題定式	13
3.5	區域視角：LightGCN	14
3.5.1	動機	14

3.5.2	圖的建構	15
3.5.3	傳播	15
3.5.4	層平均與輸出	15
3.6	全域視角：KG-SVD 初始化	16
3.6.1	面向槽作為物品側 KG 表示	16
3.6.2	共現矩陣	17
3.6.3	IDF 加權	17
3.6.4	截斷 SVD	17
3.6.5	重塑為槽位與量值縮放	18
3.6.6	演算法	18
3.6.7	此初始化所帶來的效益	18
3.7	全域視角：Softmax 合理化遮罩	19
3.7.1	動機	19
3.7.2	使用者條件之注意力 logits	19
3.7.3	Softmax 歸一化	19
3.7.4	加權聚合	20
3.7.5	為何使用 Softmax 而非 Sigmoid	20
3.8	區域偏置融合閘	21
3.8.1	雙側獨立閘	21
3.8.2	閘的結構	21
3.8.3	區域偏置初始化	21
3.8.4	優雅退化	22
3.8.5	為何選 +5 而非 $+\infty$	22
3.9	跨視角對比正則化	23
3.9.1	在架構中的角色	23
3.9.2	面向層級對比損失	23
3.9.3	使用者層級對比損失	23
3.9.4	全域側 Stop-Gradient	24
3.9.5	損失權重	24
3.10	訓練與計算複雜度	24
3.10.1	總目標	24
3.10.2	最佳化	24

3.10.3 推論	24
3.10.4 計算複雜度	25
4 實驗	26
4.1 資料集與 KG 建構	26
4.2 實驗設定	27
4.3 主要結果	27
4.4 消融研究	27
4.4.1 KG-SVD 初始化	27
4.4.2 Softmax 合理化遮罩	27
4.4.3 區域偏置融合閘	27
4.5 敏感性分析	27
4.5.1 Softmax 溫度 τ	27
4.5.2 面向槽數 A	27
4.5.3 融合閘偏置	27
4.5.4 對比權重 λ_{CL}	27
4.6 種子穩定性	27
4.7 個案研究	27
4.8 計算成本	27
5 結論與未來工作	28
5.1 結論	28
5.2 方法論啟示：注意力正規化	28
5.3 限制	28
5.4 未來工作	28

Chapter 1

緒論

1.1 研究背景

圖神經網路 (GNN) 已成為協同過濾的主流架構選擇。其中，LightGCN [1] 證明了只要移除 GCN 中的非線性激活與特徵變換、僅保留線性鄰居聚合，便足以在標準推薦基準上超越如 NGCF [2] 等更深層的方法。LightGCN 的簡潔與穩定使其成為一個強大且參數高效的骨幹，而後續方法如 SGL [3] 則在其上疊加額外的自監督目標。

另一條互補的研究路線——知識圖譜感知推薦 (KG-aware recommendation) ——以知識圖譜 (KG) 所編碼的物品端語意來擴充協同訊號。具代表性的方法包括：KGAT [4]，在統一的使用者—物品—實體圖上傳播訊息；KGCL [5] 與 MCCLK [6]，透過對比學習對齊 KG 視角與協同視角；以及 KGRec [7]，引入邊層級的合理化 (rationalization) 機制以辨識哪些 KG 三元組對推薦負責。當 KG 稠密且品質良好時，這類方法皆能穩定地超越純協同基線。

1.2 稀疏 KG 下的經驗異常現象

本研究的起點是一個促使整篇論文展開的經驗觀察。在本研究所使用的、由評論衍生而來的 KG 資料集 (Amazon Books 子集，經篩選後每件物品平均僅有 2.4 條 aspect 邊) 上，前述四種具代表性的 KG-aware 方法全部都被完全不參考 KG 的純 LightGCN 所超越。表 1 摘要呈現此一差距。

我們並非主張上述四種基線本身有缺陷——它們在其原始論文所報告的稠密 KG 資料集上表現皆十分強勁。此觀察反映的，是深度 KG-CF 耦合所共同具有的一種失效模式：當 KG 過於稀疏或雜訊過多以致無法提供可靠的物品語意時，將其直接融入評分路

Table 1: 在我們的稀疏評論型 KG 上，代表性 KG-aware 方法之 NDCG@20 表現，並與純 LightGCN 對照。四種 KG-aware 方法皆不及不使用 KG 的基線。

方法	NDCG@20
MCCLK [6]	0.1067
KGCL [5]	0.1073
KGAT [4]	0.1079
KGRec [7]	0.1095
純 LightGCN [1] (未使用 KG)	0.1179

徑會使 KG 雜訊污染本可產生純淨協同訊號的梯度流。

1.3 稀疏 KG 作為現實世界的常態

一個自然的反駁是：將此一經驗異常視為資料集的特殊性，並透過更精緻地策劃稠密 KG 或進行 KG 補全 (completion) 來填補缺失邊即可。然而，我們主張，稀疏 KG 才是實務推薦系統中更常見的情境，因此「在 KG 訊號不可靠時依然穩健」這項性質本身就值得專門研究，而非以工程繞道方式迴避。

實務上有三個常見的稀疏來源。其一，評論衍生型 KG——如本研究所使用者——其密度繼承自使用者實際提及的主題；覆蓋本質上即不均勻。其二，冷啟動與新興領域——新品類、低資源語言、利基垂直市場——通常無法取得如 Freebase 或 Wikidata 等等級的人工策劃資源，KG 必須從有限訊號中自舉而來。其三，隱私受限領域，如醫療或金融推薦，刻意限制可暴露給模型的關聯訊號。在以上三種情境中，激進的 KG 補全本身亦非易事：補全會引入新的雜訊，且通常需要足夠的種子訊號才能訓練——而這恰恰是稀疏情境中所欠缺的。

由此推論，推薦器在 KG 不可靠時的穩健性，至少和它在 KG 稠密時的峰值效能同等重要。本論文以此穩健性作為主要設計目標。

1.4 研究問題

上述經驗異常與稀疏 KG 情境的實務重要性，引出兩個研究問題：

- (RQ1, 診斷) 為何既有 KG-aware 方法在稀疏 KG 下不及純 LightGCN？它們所共同具備的結構性失效模式為何？

- **(RQ2, 處方)** 何種設計原則能讓模型在 KG 訊號有效時加以利用，而在訊號無效時避免 KG 雜訊污染協同過濾？

本論文的主張是：KG 不應如 KGAT 式深度融合那般，成為評分管線中的必要組件，而應作為一條可依其訊號是否有效而被明確開控的旁路通道。具體而言，此原則由三項設計選擇實現：以 softmax 為基礎的 aspect-saliency 注意力，用於對每組使用者—物品配對選取 KG 合理化依據；以 KG 驅動的 SVD 初始化，用以保留語意幾何；以及具有局部偏置的融合閘（local-biased fusion gate），其初始化內建了當 KG 訊號終究不具資訊量時優雅退化回純 LightGCN 的能力。

1.5 研究貢獻

本論文之主要貢獻如下：

1. **經驗性研究**：證明在稀疏評論型 KG 下，四種具代表性的 KG-aware 方法（KGAT、KGCL、MCCLK、KGRec）皆一致地被純 LightGCN 超越。我們將此歸因於這些方法缺乏一個能於 KG 不可靠時將其脫接的架構機制。
2. **RA-GARK，一個雙視角架構**：以旁路通道而非深度融合的方式整合協同訊號與 KG 衍生訊號。RA-GARK 由三項核心要素組成，且彼此皆獨立必要：
 - **Softmax aspect-saliency 注意力**（第 3.7 節）。每件物品的 KG 語意儲存於 $A = 4$ 個潛在面向槽中——此槽位數為模型設計參數，與每件物品所擁有的原始面向標籤數無關——槽位內容由 IDF 加權商品—面向共現矩陣之截斷 SVD 投影而得；softmax 正規化的注意力為給定的使用者—物品配對選取最足以代表該物品的潛在槽位。將 softmax 改為 sigmoid 會使 NDCG@20 下降 7.0%，是我們所觀察到單一元件影響最大者。
 - **具局部偏置的融合閘**（第 3.8 節）。融合閘以 +5 的正偏置初始化，使 $\alpha^{(0)} \approx 0.993$ 。因此模型在訓練之初幾乎等同於純 LightGCN，僅當梯度顯示 KG 通道有幫助時，閘門才會被打開。此設計提供了四種基線所缺乏的、結構性的優雅退化保證。若移除此偏置初始化，NDCG@20 會損失 5.3%。
 - **KG-SVD 初始化**（第 3.6 節）。aspect 槽位的嵌入由 IDF 加權的物品—aspect 矩陣之截斷 SVD 初始化而來，將 KG 的語意幾何保留為最佳化的起點。將其換為隨機初始化會損失 5.3% NDCG@20。

3. **經驗驗證：**在稀疏評論型 KG 基準上，RA-GARK 達到 $NDCG@20 = 0.1238$ ，較最強的 KG-aware 基線 (KGRec) 高出 +13.1%，更重要的是，較純 LightGCN 也高出 +5.0%。後者的差距顯示，所提出的設計原則能在 KG 本身不變的情況下，把 KG 訊號的貢獻由淨負（四種基線之情況）翻轉為淨正。
4. **關於合理化感知設計中注意力正規化的方法論觀察。**在我們的情境中，softmax 與 sigmoid 之間異常顯著的差距，暗示正規化的選擇應與合理化的語意假設相一致。我們將此視為單一資料集上的假設而非通用主張，留待後續多資料集複製驗證（第 5 章）。

1.6 論文組織

本論文後續組織如下。第 2 章從四個面向回顧相關文獻：圖協同過濾、KG-aware 推薦、深度學習中的閘控機制，以及注意力正規化。第 3 章呈現 RA-GARK 的整體架構並形式化推薦問題。第 3 章詳述各模組，包括區域視角、含兩項創新（KG-SVD 初始化與 softmax aspect-saliency 注意力）的全域 KG 視角、具局部偏置的融合閘，以及跨視角對比正規化。第 4 章報告實驗結果、消融研究、敏感性分析與個案研究。第 5 章討論關於注意力正規化的方法論啟示，承認單一資料集驗證與種子敏感性的限制，並作結。

Chapter 2

相關研究

本章從四個面向回顧先前研究，這些面向共同促成 RA-GARK 的設計。第 2.1 節介紹我們區域與全域視角所立足的兩項基礎：作為協同過濾骨幹的 LightGCN，與作為深度 KG-CF 融合典範的 KGAT。第 2.2 節回顧那些在不明確閘控下對齊協同與 KG 視角的對比式 KG 方法。第 2.3 節討論與本工作最為相關的合理化感知方法 KGRc，第 2.4 節則以「KG 可信度」為視角，對比我們與 KGRc 的合理化典範。第 2.5 與 2.6 節廣泛回顧深度學習中的閘控機制，並觀察到既有 KG-aware 方法皆未採用融合閘以提供架構層級的優雅退化。第 2.8 節總結 RA-GARK 相對於上述工作的定位。

2.1 基礎：LightGCN 與 KGAT

LightGCN [1] 是本研究區域視角的直接前身。建立於「NGCF [2] 中的非線性特徵變換對推薦準確率貢獻甚微」這項觀察上，LightGCN 將圖卷積網路精簡至最小骨幹：在使用者—物品二部圖上進行正規化的鄰居聚合 $\mathbf{E}^{(\ell+1)} = \tilde{\mathbf{A}}\mathbf{E}^{(\ell)}$ ，最終嵌入則取各層平均 $\bar{\mathbf{E}} = \frac{1}{K+1} \sum_{\ell=0}^K \mathbf{E}^{(\ell)}$ 。此一簡化在標準推薦基準上一致地優於 NGCF，且訓練更快、更穩定。其後諸多自監督方法，如 SGL [3] 與 DCCF [8]，皆在 LightGCN 式骨幹之上疊加額外的對比目標。

在 RA-GARK 中，我們原封不動採用 LightGCN ($K = 2$) 作為區域視角：此分支內不施加任何 KG 相關運算。動機有二。其一，在我們的稀疏評論型 KG 上，純 LightGCN 已達 $\text{NDCG@20} = 0.1179$ ，超越所有我們所評估的 KG-aware 基線。任何偏離此強預設的設計，皆須可被證實能改善而非劣化結果——這是本論文反覆訴諸的硬性設計約束。其二，將 KG 訊號隔離至獨立的全域視角（第 3 章），可避免 KG 雜訊污染協同表示的梯度流。

KGAT [4] 代表 KG-aware 推薦中的典範深度融合做法。KGAT 將使用者—物品互動圖與知識圖譜合併為一個協同知識圖 (Collaborative Knowledge Graph, CKG)，並以雙交互聚合器於此統一結構上傳播訊息。KG 實體嵌入因而直接參與使用者與物品表示的形成。當 KG 稠密且品質良好時，此設計相對於 CF 基線可取得顯著提升。

此處的隱含假設是 KG 可被信任，能在傳播路徑所及之處皆注入有用訊號。在我們的稀疏情境下此假設崩解：KGAT 僅達 $\text{NDCG}@20 = 0.1079$ ，低於純 LightGCN。其後續工作 [5, 6, 7] 沿用 KGAT 式聚合器，因此也繼承相同的脆弱性。RA-GARK 反轉此一設計選擇：我們完全不將 KG 與使用者—物品圖合併，而是將 KG 訊號導入一條專用旁路通道，當 KG 被證實不可靠時模型可衰減甚至全然脫接之。

2.2 對比式知識圖譜方法

KGCL [5] 對 KG 引入關係層級的結構擾動，並以 InfoNCE [9] 對比目標對齊擾動版本與原始版本。直覺是：具資訊量的 KG 結構應對隨機擾動具有不變性，而雜訊邊則不應。KGCL 在稠密 KG 情境下顯著優於 KGAT。然而在我們的稀疏情境中，擾動後的 KG 保留的邊過少，對比目標無法提供可靠監督： $\text{NDCG}@20$ 降至 0.1073。

MCCLK [6] 將對比對齊擴展至三個視角——協同、語意與結構——並對三者兩兩施加對比損失。雖然此多視角設計在稠密 KG 基準上取得 SOTA，但同樣繼承稠密 KG 的假設：在稀疏 KG 下，三個視角中有兩個（語意與結構）訊號不足，對比對齊淪為由雜訊主導而非由結構主導的正則化 ($0.1067 \text{NDCG}@20$)。

RA-GARK 同樣納入跨視角對比學習，但其角色刻意受限。我們的對比損失 ($\mathcal{L}_{\text{aCL}}$ 與 $\mathcal{L}_{\text{uCL}}$ ，第 3.9 節) 僅作為小權重 ($\lambda = 0.005$) 的輔助幾何正則化項，並關鍵地在 KG 側施加 stop-gradient，使對比梯度從不反向傳遞至 SVD 初始化的 aspect 嵌入。相較於 KGCL/MCCLK，此處的對比學習是表層的對齊層，而非主要的融合機制；協同與 KG 訊號的實際整合，是由一個明確的閘所執掌 (第 2.5 節)。

2.3 合理化感知推薦：KGRec

KGRec [7] 是與本工作最直接相關的研究。它是第一個將合理化選擇明確化的 KG-aware 推薦器：KGRec 不將每條 KG 三元組視為同等具資訊量，而是對每條 KG 邊計算一個基於注意力的重要性分數，並以 Bernoulli dropout 隨機移除高注意力邊，迫使模型不依賴少數主導邊；其穩健性接著由原始圖與被丟邊版本之間的對比目標來強化。整套合理化機制建立於 KGAT 式聚合器之上，因此合理化作用於使用者—物品—實體統

一圖的訊息傳遞路徑之內。在我們的稀疏基準上，KGRec 取得 $\text{NDCG}@20 = 0.1095$ ，為四個 KG-aware 基線中最強者，但仍低於純 LightGCN。

RA-GARK 在精神上採納合理化感知典範，但在結構上多處與 KGRec 有別，下節詳述之。

2.4 合理化典範：共同前提與分歧的可信度假設

KGRec [7] 與 RA-GARK 都認同「並非所有 KG 邊都對推薦同等貢獻、需要明確的選擇機制」這項觀察。然而二者對 KG 整體可信度所作的假設有所不同，此一假設並蔓延至各自分歧的設計選擇。

KGRec 的隱含假設是：具資訊量的邊存在於 KG 中，因此合理化任務簡化為將其找出；隨機 dropout 配合對比學習已足以辨識並放大有用子集。KG 整體作為證據體系被假定為可靠的，僅是個別邊的權重需被調整。

RA-GARK 的前提較弱。我們不假設 KG 整體是可靠的。aspect-saliency softmax（第 3.7 節）在 KG 具資訊量時選取合理化依據，但具局部偏置的融合閘（第 3.8 節）可在閘的梯度顯示無益時，另外地脫接整條 KG 通道。此可信度差異展現於四項設計分歧上：

- **合理化粒度。** KGRec 在邊（KG 三元組）層級進行選擇。RA-GARK 將每件物品的 KG 語意聚合為 $A = 4$ 個潛在面向槽——槽位內容由 IDF 加權商品—面向共現矩陣之截斷 SVD 投影得到——並在槽位層級進行選擇。此槽位數為模型設計參數，與每件物品所擁有的原始面向標籤數無關；粒度雖較邊層級選擇為粗，但直接產生可解讀的每物品 aspect 偏好。
- **選擇機制。** KGRec 採用離散 Bernoulli dropout 配合對比學習。RA-GARK 採用可微分的 softmax 注意力，能端到端訓練，並將推論期的權重作為可解釋性產物外露。
- **作用位置。** KGRec 在 KGAT 訊息傳遞路徑之內施加合理化；合理化與聚合糾纏在一起。RA-GARK 將合理化置於與 LightGCN 區域視角分離的旁路通道，僅於後期由閘將兩者結合。
- **對 KG 可信度的處理。** KGRec 沒有任何架構機制可脫接 KG。RA-GARK 的偏置初始化融合閘正提供此一機制：訓練起始時 $\alpha^{(0)} \approx 0.993$ ，模型實質上即為純 LightGCN；唯當學習顯示 KG 通道能降低損失時，閘才會被打開。

因此我們不將 RA-GARK 定位為對 KGRec 的工程性改良，而是基於對 KG 可信度不同前提之另一種設計。此一區別在經驗上是否重要，則於第 4 章中作答。

2.5 深度學習中的閘控機制

RA-GARK 的融合閘有兩個 KG-aware 推薦之外的近親，二者皆啟發本研究設計。

Highway Networks [10] 引入可學習的閘 $T(\mathbf{x})$ ，於變換訊號 $H(\mathbf{x})$ 與恆等跳接間進行插值： $\mathbf{y} = T(\mathbf{x}) \cdot H(\mathbf{x}) + (1 - T(\mathbf{x})) \cdot \mathbf{x}$ 。其關鍵設計選擇為對 T 的負偏置初始化：訓練之初 $T \approx 0$ ，網路表現為恆等映射。其後訓練僅在變換有益處之處才打開閘門。此設計原本是為應對極深網路訓練的困難，但「將閘偏置至已知安全的預設，僅在學習認為合理時才覆寫」此結構性樣式，遠遠超出深度的脈絡而具有普適性。RA-GARK 將此樣式由網路內跳接移植至雙視角融合：融合閘上的 +5 偏置扮演與 Highway 之負偏置相同的角色，對 KG 通道提供優雅退化保證。

專家混合 (Mixture-of-Experts) 閘控，以多任務推薦中的 MMoE [11] 與 PLE [12] 為代表，以閘控網路對多個專家塔加權。雖然概念上類似多管線選擇，但兩項重要性質與 RA-GARK 不同。其一，MMoE/PLE 中的專家為同質候選者——皆為相同架構、僅以任務特定目標訓練的實例——因此並無「某專家本質上比另一者較不可靠」的概念。其二，這些架構中的閘採對稱初始化（訓練起始不偏向任何特定專家），適用於對稱專家情境，但不適用於我們不對稱的情境——在我們的設定中，一條通道 (LightGCN) 已知是強預設，另一條 (KG) 已知有時並不具資訊量。

另有一條工作線是對比式雙視角推薦器，例如 SGL [3] 與 DCCF [8]，這類方法以擾動單一圖（邊 dropout、節點 dropout、隨機漫步）來建構多個視角。此類方法中兩個視角位於相同訊號空間，對比對齊已足以整合二者。RA-GARK 的兩個視角則在結構上異質：區域視角為使用者—物品二部圖，全域視角為物品—aspect 的 KG。僅靠對比學習進行隱式對齊，無法調整兩個異質訊號空間的相對權重；明確的閘是必要的。

2.6 缺口：KG-Aware 推薦中沒有融合閘

儘管閘控在深度學習中已相當成熟，我們所調研的 KG-aware 推薦文獻中，未見任何方法將融合閘作為協同訊號與 KG 訊號之間的整合機制。表 2 摘要了四個被基準測試的基線與另外三個知名 KG-aware 方法 (CKAN [13]、MKR [14]、KGIN [15]) 所採用的整合機制。在這個集合中，KG 訊號是透過直接實體傳播、對比對齊、邊層級 dropout、

注意力、跨特徵單元或意圖解耦模組來整合。沒有任何機制允許 KG 通道在訊號不可靠時被結構性地脫接。

Table 2: 代表性 KG-aware 推薦器所採用的整合機制。皆未提供在不可靠 KG 下的架構優雅退化能力。

方法	KG 整合機制	可脫接？
KGAT [4]	直接實體訊息傳播	否
KGCL [5]	擾動 KG 對比學習	否
MCCLK [6]	多視角對比對齊	否
KGRec [7]	邊層級 dropout + KGAT 聚合器	否
CKAN [13]	協同—知識注意力	否
MKR [14]	跨特徵轉移單元	否
KGIN [15]	KG 上的意圖解耦	否
RA-GARK (本研究)	偏置初始化的融合閘	是

我們刻意作出一個範圍狹義的主張。我們不主張 RA-GARK 是 KG-aware 推薦中首個使用「任何閘」的方法，因 KG-aware 文獻浩繁，無法窮舉列舉。可辯護的主張為：在我們所檢視的方法中，沒有任何一個以偏置初始化的融合閘於稀疏或不可靠 KG 下提供架構優雅退化。我們在第 4 章的消融將 5.3% NDCG@20 的貢獻明確歸因於此閘的偏置初始化，支持上述主張在此情境中並非微不足道。

2.7 注意力正規化

一個橫跨多領域的相關問題是：在選擇合理化依據時，應對注意力權重套用 sigmoid 或 softmax？文獻並未匯聚於單一答案。DIN [16] 對使用者行為歷史套用 sigmoid 注意力，所基於的假設是每筆歷史行為與候選物品的相關性彼此獨立。NAIS [17] 對歷史互動套用 softmax 注意力以衡量物品相似度，AFM [18] 則對特徵交互套用 softmax。各工作中的選擇皆以其注意力所依附的語意假設為依據。

我們在第 4 章報告一項單一資料集的觀察：對於我們的 aspect-saliency 合理化，將 softmax 替換為 sigmoid 會損失 7.0% NDCG@20——這是我們所量測到單一元件影響最大者。我們將其解讀為支持「正規化應與合理化的語意假設相符」此一設計啟發，但明確將此觀察定位為待多資料集複製驗證的假設（第 5 章）。

2.8 總結與 RA-GARK 的定位

表 3 從四個設計面向匯整比較。在我們稀疏基準上所評估的方法中，RA-GARK 是唯一同時將純 LightGCN 區域聚合器與閘控後期融合的 KG 訊號相結合者，也是唯一將合理化作用於物品—aspect 粒度而非 KG 邊粒度者。

Table 3: 從四個面向所作的設計比較。NDCG@20 於我們的稀疏評論型 KG 基準上報告。

方法	區域聚合器	KG 整合	合理化	NDCG@20
KGAT	雙交互	直接傳播	—	0.1079
KGCL	KGAT 式	傳播 + CL	—	0.1073
MCCLK	多視角	多視角 CL	—	0.1067
KGRec	KGAT 式	傳播 + 邊 dropout	邊 Bernoulli	0.1095
RA-GARK	純 LightGCN	閘控後期融合	Aspect softmax	0.1238

我們並不將 RA-GARK 定位為相對於四個基線的嚴格改進。RA-GARK 在設計空間中佔據一個不同的位置——其特徵在於將 KG 視為可被明確閘控的旁路通道，而非必要的管線組件。此選擇在我們的稀疏 KG 情境中產出強勁結果，而基於閘控的優雅退化性質，在 KG 品質不均或模型部署於 KG 密度差異各異的多個領域時，或許亦能派上用場。然而，當 KG 稠密且品質一致地可靠時，KGAT 或 KGRec 這類深度融合方法可能仍較佳，因為後期融合的設計犧牲了深度融合架構所具有的部分表徵表達力。

Chapter 3

方法

本章呈現 RA-GARK 之完整方法。第 3.1 節說明使 RA-GARK 有別於第 2 章所回顧之深度融合基線的核心設計原則。第 3.2 節以泳道圖 (swim-lane) 呈現推論時的整體資料流。第 3.3 節固定符號。第 3.4 節形式化推薦任務與訓練目標。第 3.5 至 3.9 節依模組於前向傳遞中的順序逐一詳述各模組；第 3.10 節說明訓練程序與計算複雜度。

3.1 設計原則：KG 作為可被開控的旁路通道

第 1 章的經驗觀察是：在本研究稀疏的評論衍生知識圖譜 (KG) 上，四種具代表性的 KG-aware 方法 (KGAT、KGCL、MCCLK、KGRec) 皆被純 LightGCN 一致地超越。這些基線所共有的結構性失因在於：KG 被當作評分管線的必要組件串接進來——KG 實體嵌入直接參與訊息傳遞，且無任何架構性的開關能在 KG 被證實不可靠時將其脫接。因此 KG 雜訊與協同表示共享同一條梯度流。

RA-GARK 圍繞一個直接面對此失效模式的核心設計原則：

KG 不應為評分管線的必要組件，而應為一條旁路通道；其對最終分數的貢獻由一個學習得到的開決定，開在初始化時偏置至一個安全預設（純協同過濾），僅在訓練訊號顯示 KG 通道能降低損失時才被打開。

此原則衍生三項架構層級的後果，並共同定義 RA-GARK：

1. **雙條平行視角。**區域視角透過在使用者—物品互動圖上運行 LightGCN 產生純協同表示 (u_{loc}, i_{loc}) ，過程中完全不涉及 KG。全域視角則由獨立的使用者嵌入表與物品端的潛在面向槽產生 KG 表示 (u_{glo}, i_{glo}) ，過程中亦不涉及協同訊號。直至融合階段之前，兩條視角在結構上完全分離。

2. **後期、開控的融合**。兩條視角僅在最終評分階段被融合開合併；該開針對每組（使用者，物品）配對輸出一個混合權重 $\alpha \in (0, 1)$ 。開以偏置初始化使 $\alpha^{(0)} \approx 0.993$ ，模型訓練起點實質等同於純 LightGCN，KG 通道僅在梯度將 α 推低時逐步開啟。
3. **合理化感知的物品端聚合**。每件物品的 KG 語意儲存於 $A = 4$ 個潛在面向槽中，槽位內容由 IDF 加權商品一面向矩陣之截斷 SVD 產生；softmax aspect-saliency 注意力依（使用者，物品）配對選取代表該物品的潛在槽。

每項後果均於第 3 章中數學化。本章其餘部分將符號與問題陳述定位至足以使第 3 章自洽所需之細節層級。

3.2 架構概覽

圖 1 勾勒了推論時的資料流。模型被布置為對應區域與全域視角的兩條水平泳道，於右側由融合階段匯合。區域視角（上方泳道）對使用者—物品互動圖套用 LightGCN，得到 (u_{loc}, i_{loc}) 。全域視角（下方泳道）直接以查表得到使用者的全域嵌入 u_{glo} ，並對物品的 $A = 4$ 個潛在面向槽施加 softmax 合理化遮罩以得 i_{glo} ；面向槽本身為 SVD 初始化（圖中以虛線標註）。兩條視角由獨立的使用者側與物品側融合開混合，每個開的偏置初始化為 +5；最終分數為內積 $\langle u_{final}, i_{final} \rangle$ 。為求清晰，跨視角對比學習路徑於圖中省略，詳見第 3.9 節。




Figure 1: RA-GARK 架構。

兩項結構性質值得在形式化呈現之前先點明。其一， u_{glo} 並不經過合理化遮罩模組，而是由直接查表得到，並逕送至使用者側融合開；合理化遮罩僅作用於物品側，符合

「合理化回答的是『此物品的哪個面向對此使用者重要』」這一語意。其二，KG-SVD 步驟為初始化而非前向運算：SVD 於訓練前計算一次以設定面向槽參數的初值，其後槽位即如其他參數般以梯度下降更新。

3.3 符號

本論文後續使用之符號列於表 4。

Table 4: 本章與後續章節所使用之符號。

符號	意義
$\mathcal{U}, \mathcal{I}$	使用者集合與物品集合
$\mathcal{R} \subseteq \mathcal{U} \times \mathcal{I}$	已觀察到的使用者—物品互動
$\mathcal{G}_{\text{KG}}$	物品—面向知識圖譜（評論衍生）
$\mathcal{A}$	$\mathcal{G}_{\text{KG}}$ 中出現之 unique 面向標籤集合
A	每件物品的潛在面向槽數（ $A = 4$ ）
d	嵌入維度（除另行指定， $d = 64$ ）
K	LightGCN 傳播層數（ $K = 2$ ）
$u_{\text{loc}}, i_{\text{loc}} \in \mathbb{R}^d$	區域視角（LightGCN）嵌入
$u_{\text{glo}} \in \mathbb{R}^d$	全域視角使用者嵌入（直接查表）
$\mathbf{a}_i \in \mathbb{R}^{A \times d}$	物品 i 之潛在面向槽（SVD 初始化）
$i_{\text{glo}} \in \mathbb{R}^d$	全域視角物品嵌入（合理化遮罩後）
$\alpha_u, \alpha_i \in (0, 1)$	使用者側與物品側融合閘輸出
$\hat{y}(u, i) \in \mathbb{R}$	對配對 (u, i) 之預測偏好分數

3.4 問題定式

任務。 本文處理隱式回饋設定下的 top- K 推薦。給定 $\mathcal{U}$ 、 $\mathcal{I}$ 、已觀察到的互動 $\mathcal{R}$ ，以及物品—面向 KG $\mathcal{G}_{\text{KG}}$ ，目標是為每位使用者 $u \in \mathcal{U}$ 從 $\mathcal{I} \setminus \{i : (u, i) \in \mathcal{R}\}$ 中產生一個排序清單，並以排序指標（NDCG@ K 、Recall@ K 、Hit@ K ）對保留之測試互動集進行評估。

評分函數。 RA-GARK 對每組 (u, i) 配對指派內積分數

$$\hat{y}(u, i) = \langle u_{\text{final}}, i_{\text{final}} \rangle, \quad (3.1)$$

其中 u_{final} 與 i_{final} 由區域與全域表示的閘控融合產生：

$$u_{\text{final}} = \alpha_u u_{\text{loc}} + (1 - \alpha_u) u_{\text{glo}}, \quad i_{\text{final}} = \alpha_i i_{\text{loc}} + (1 - \alpha_i) i_{\text{glo}}. \quad (3.2)$$

閘輸出 α_u, α_i 分別由獨立的 MLP 計算（第 3.8 節）。在本論文採用的偏置初始化下， $\alpha_u^{(0)}, \alpha_i^{(0)} \approx 0.993$ ，因此 $\hat{y}^{(0)}(u, i) \approx \langle u_{\text{loc}}, i_{\text{loc}} \rangle$ ，即訓練起點之分數實質為純 LightGCN 之分數，直至閘藉學習而調整。

訓練目標。 我們以 Bayesian Personalized Ranking (BPR) [19] 損失為主體，並輔以兩條跨視角對比正則化：

$$\mathcal{L} = \mathcal{L}_{\text{BPR}} + \lambda_{\text{CL}} (\mathcal{L}_{\text{aCL}} + \mathcal{L}_{\text{uCL}}), \quad (3.3)$$

其中對每組已觀察配對 $(u, i^+) \in \mathcal{R}$ 與一個取樣的負例物品 $i^- \notin \mathcal{R}_u$ ，

$$\mathcal{L}_{\text{BPR}} = -\log \sigma(\hat{y}(u, i^+) - \hat{y}(u, i^-)), \quad (3.4)$$

而 $\mathcal{L}_{\text{aCL}}, \mathcal{L}_{\text{uCL}}$ 分別為 $(i_{\text{loc}}, i_{\text{glo}})$ 與 $(u_{\text{loc}}, u_{\text{glo}})$ 之間的 InfoNCE 式對齊損失；全域側施加 stop-gradient 以避免對比梯度擾動 SVD 初始化之面向槽（第 3.9 節）。對比權重 λ_{CL} 固定為 0.005，使對比的角色為輔助而非主要。

3.5 區域視角：LightGCN

區域視角僅由使用者—物品互動圖產生純協同表示 $(u_{\text{loc}}, i_{\text{loc}})$ ；此分支內部完全不施加任何 KG 運算。其架構與 LightGCN [1] 完全相同。

3.5.1 動機

選擇 LightGCN 作為區域視角骨幹的理由有三。其一，在本論文所使用之稀疏評論衍生 KG 上，純 LightGCN 已超越我們所評估的全部四個 KG-aware 基線（第 1 章），故為任何後續設計必須可被證實能改善的最強無 KG 起點。其二，其參數化極為精簡——僅有使用者與物品的嵌入表，傳播過程中無任何學習權重——這限制了兩條視角後續耦合時 KG 雜訊得以滲入協同梯度流的接觸面。其三，傳播為純線性，故每層對最終表示的貢獻可由閉式之層平均直接讀出，從而能在不受非線性干擾的前提下，理性化關於閘的放置（第 3.8 節）與對比對齊（第 3.9 節）的設計決策。

3.5.2 圖的建構

令 $\mathbf{R} \in \{0, 1\}^{|\mathcal{U}| \times |\mathcal{I}|}$ 為由 $\mathcal{R}$ 衍生的使用者—物品互動矩陣，其中 $\mathbf{R}_{u,i} = 1$ 當且僅當 $(u, i) \in \mathcal{R}$ 。據此建構二部圖鄰接矩陣

$$\mathbf{A} = \begin{bmatrix} \mathbf{0} & \mathbf{R} \\ \mathbf{R}^\top & \mathbf{0} \end{bmatrix} \in \mathbb{R}^{(|\mathcal{U}|+|\mathcal{I}|) \times (|\mathcal{U}|+|\mathcal{I}|)}, \quad (3.5)$$

並施加對稱歸一化

$$\tilde{\mathbf{A}} = \mathbf{D}^{-1/2} \mathbf{A} \mathbf{D}^{-1/2}, \quad \mathbf{D} = \text{diag}(\mathbf{A} \mathbf{1}). \quad (3.6)$$

此歸一化降低了與高度使用者或熱門物品相鄰之邊的權重，於實務上有助於穩定長尾互動分布下的訓練。

3.5.3 傳播

令 $\mathbf{E}^{(0)} \in \mathbb{R}^{(|\mathcal{U}|+|\mathcal{I}|) \times d}$ 為初始嵌入表，前 $|\mathcal{U}|$ 列為使用者嵌入，其餘 $|\mathcal{I}|$ 列為物品嵌入；兩區塊皆以 Xavier-normal 初始化。第 ℓ 層由單次歸一化鄰居聚合得到：

$$\mathbf{E}^{(\ell+1)} = \tilde{\mathbf{A}} \mathbf{E}^{(\ell)}, \quad \ell = 0, 1, \dots, K-1. \quad (3.7)$$

過程中無任何可學習權重矩陣、無非線性、無自迴圈偏置——整個區域視角所有可學習參數即為 $\mathbf{E}^{(0)}$ 的 $|\mathcal{U}|d + |\mathcal{I}|d$ 個元素。

3.5.4 層平均與輸出

採用 LightGCN 標準的層平均

$$\bar{\mathbf{E}} = \frac{1}{K+1} \sum_{\ell=0}^K \mathbf{E}^{(\ell)}, \quad (3.8)$$

並由 $\bar{\mathbf{E}}$ 對應列讀出 u_{loc} 與 i_{loc} 。本論文使用 $K = 2$ ，與原始 LightGCN 論文一致，亦為我們純區域驗證損失趨於平台的深度。

如此得到的嵌入對僅由使用者—物品互動圖提供資訊；區域視角僅透過第 3.8 節之融合階段參與最終分數 $\hat{y}(u, i)$ ，訓練過程中不容許任何 KG 訊號改變 u_{loc} 或 i_{loc} 。




Figure 2: KG-SVD 初始化流程。

3.6 全域視角：KG-SVD 初始化

全域視角引入一獨立的使用者側嵌入 u_{glo} （直接查表，見下文）與一物品側參數張量以儲存各物品之 KG 語意。此物品側張量為 RA-GARK 中唯一容許 KG 內容進入模型之處。本節說明該張量之參數化方式及其值如何初始化。圖 2 提供四階段初始化流程之視覺概觀，其餘內容則將每階段形式化。

3.6.1 面向槽作為物品側 KG 表示

每件物品 i 在全域視角中由面向槽張量

$$\mathbf{a}_i \in \mathbb{R}^{A \times d}, \quad A = 4 \quad (3.9)$$

表示，將所有物品的張量集合為一可學習參數 $\mathbf{A}_{\text{KG}} \in \mathbb{R}^{|I| \times A \times d}$ 。初始化（下節說明）之後， $\mathbf{A}_{\text{KG}}$ 即如其他參數般以梯度下降更新。

此處有一關鍵釐清：槽位數 $A = 4$ 為模型超參數，不對應於每件物品的固定原始面向標籤數。在本論文使用的評論衍生 KG 中，每件物品平均僅持有 2.4 條面向邊，全域面向標籤詞彙遠大於 A ($|\mathcal{A}| \gg A$)。此四個槽位為面向誘導語意子空間中的潛在方向，跨全體物品共同學習，而非綁定於特定標籤。

3.6.2 共現矩陣

從二值物品一面向共現矩陣 $\mathbf{M} \in \{0, 1\}^{|I| \times |A|}$ 出發：

$$\mathbf{M}_{i,a} = \begin{cases} 1, & (i, a) \in \mathcal{G}_{\text{KG}}, \\ 0, & \text{否則} \end{cases} \quad (3.10)$$

$\mathbf{M}$ 的每一列因此是一個稀疏指示向量：每件物品至多只有少數幾個非零項；經剪枝後（第 4.1 節）全域密度對應於每列平均 2.4 個 1。

3.6.3 IDF 加權

部分面向標籤橫跨許多物品（如「文筆優美」、「引人入勝」），其他則高度特定（如某個利基類型或主題）。若不修正，後續 SVD 將由高頻標籤主導，所產生的潛在方向實質上只是熱門度先驗。我們以標準的逆文件頻率（IDF）重新加權緩解此問題：

$$\text{idf}(a) = \log \left(\frac{|I|}{|\{i : \mathbf{M}_{i,a} = 1\}| + 1} \right) + 1, \quad (3.11)$$

並依 IDF 重新縮放 $\mathbf{M}$ 各行：

$$\tilde{\mathbf{M}}_{i,a} = \text{idf}(a) \cdot \mathbf{M}_{i,a}. \quad (3.12)$$

分母中之 +1 避免對所有物品支持已被剪除之面向除以零；對數外之 +1 防止最大頻率面向的 IDF 退化為零。兩項調整皆為標準作法。

3.6.4 截斷 SVD

對 $\tilde{\mathbf{M}}$ 計算秩 k 之截斷 SVD：

$$\tilde{\mathbf{M}} \approx \mathbf{U}_k \mathbf{\Sigma}_k \mathbf{V}_k^\top, \quad \mathbf{U}_k \in \mathbb{R}^{|I| \times k}, \quad (3.13)$$

其中 $k = A \cdot d$ 。左奇異矩陣 $\mathbf{U}_k$ 每件物品一列；各列位於一 k 維潛在子空間，於其中 IDF 加權的面向共現於秩 k 下被最佳解釋。

接著形成每件物品的潛在嵌入，將每個分量以對應奇異值之平方根縮放：

$$\mathbf{E}_{\text{KG}} = \mathbf{U}_k \mathbf{\Sigma}_k^{1/2} \in \mathbb{R}^{|I| \times k}. \quad (3.14)$$

此平方根縮放使譜能量均勻分布於左右因子，為標準選擇，所得嵌入之兩兩內積近似 IDF 加權共現內容。

3.6.5 重塑為槽位與量值縮放

寬度為 $k = Ad$ 的展平嵌入 $\mathbf{E}_{\text{KG}}$ 被重塑為每件物品 A 個寬度 d 的槽：

$$\mathbf{A}_{\text{KG}}^{(0)}[i, k, :] = \mathbf{E}_{\text{KG}}[i, kd : (k+1)d], \quad k = 0, \dots, A-1. \quad (3.15)$$

槽因此是 SVD 輸出中互不相交的連續區塊；它們不對應於可獨立解讀的面向標籤。

由於 $\mathbf{E}_{\text{KG}}$ 之量值依賴於 $|I|$ 、 $|A|$ 與 $\tilde{\mathbf{M}}$ 的譜，未經縮放的 SVD 輸出與模型他處 Xavier 初始化參數不在同一量級。我們因此將整個 $\mathbf{A}_{\text{KG}}^{(0)}$ 重新縮放，使其經驗標準差匹配 Xavier-normal 目標 $\sigma = \sqrt{2/(A+d)}$ 。此縮放保留 SVD 輸出的角度幾何——也正是我們想注入的——同時使槽位量值與其餘最佳化過程相容。

3.6.6 演算法

完整初始化可總結為五步：

1. 由 $\mathcal{G}_{\text{KG}}$ 建構二值共現矩陣 $\mathbf{M}$ （式 (3.10)）。
2. 套用 IDF 列加權得 $\tilde{\mathbf{M}}$ （式 (3.12)）。
3. 計算秩 $k = Ad$ 之截斷 SVD： $\tilde{\mathbf{M}} \approx \mathbf{U}_k \Sigma_k \mathbf{V}_k^\top$ （式 (3.13)）。
4. 形成 $\mathbf{E}_{\text{KG}} = \mathbf{U}_k \Sigma_k^{1/2}$ 並重塑為 $\mathbf{A}_{\text{KG}}^{(0)} \in \mathbb{R}^{|I| \times A \times d}$ （式 (3.15)）。
5. 整體重新縮放使標準差匹配 Xavier-normal 目標。

若 $|A| < Ad$ ，SVD 秩被限制為 $|A| - 1$ ，剩餘槽維度於縮放前以小量高斯雜訊（標準差 0.01）填補；在我們的實驗中 $|A| \gg Ad$ ，故此降階路徑不被觸發。

3.6.7 此初始化所帶來的效益

KG-SVD 初始化的貢獻於第 4.4.1 節以消融衡量：將其替換為相同張量形狀之 Xavier-normal 隨機初始化會損失 5.3% NDCG@20。其解釋是：SVD 初始化在訓練起點即保留了面向誘導語意子空間的角度幾何；其後梯度下降可微調此幾何，但在我們的稀疏 KG 條件下，難以由隨機初始化恢復——能恢復此幾何的梯度訊號需流經對比損失（ $\lambda_{\text{CL}} = 0.005$ ），訊號微弱。

3.7 全域視角：Softmax 合理化遮罩

給定物品的面向槽張量 $\mathbf{a}_i \in \mathbb{R}^{A \times d}$ 與使用者側全域嵌入 $u_{\text{glo}} \in \mathbb{R}^d$ ，合理化遮罩模組選取 A 個潛在槽中最能在該使用者下代表該物品者，得到全域視角物品嵌入 i_{glo} 。使用者側全域嵌入本身為直接查表

$$u_{\text{glo}} = \mathbf{E}_u^{\text{glo}}, \quad \mathbf{E}^{\text{glo}} \in \mathbb{R}^{|\mathcal{U}| \times d}, \quad (3.16)$$

其中 $\mathbf{E}^{\text{glo}}$ 為與區域視角使用者表分離的可學習參數；使用者側不施加任何合理化運算。

3.7.1 動機

每件物品的 KG 語意分散儲存於 $\mathbf{a}_i$ 的 A 個潛在槽中；不同槽位編碼 SVD 可見之不同語意面向。然而給定使用者並非「同時透過物品之全部語意面向」與物品互動——其偏好通常由一或兩個面向主導。合理化模組的職責即在每組（使用者, 物品）配對中，挑出與該使用者表示 u_{glo} 最一致的槽。

3.7.2 使用者條件之注意力 logits

對每個槽 $k \in \{1, \dots, A\}$ ，計算一純量 logit

$$\ell_{u,i,k} = \text{MLP}([u_{\text{glo}} \parallel \mathbf{a}_{i,k}]) \in \mathbb{R}, \quad (3.17)$$

其中 $\parallel$ 表沿嵌入維度串接，MLP 參數於所有槽與物品間共享。MLP 為兩層前饋區塊：

$$\text{MLP}(\mathbf{z}) = \mathbf{w}^\top \cdot \text{LeakyReLU}(\mathbf{W} \mathbf{z}), \quad (3.18)$$

其中 $\mathbf{W} \in \mathbb{R}^{d \times 2d}$ 、 $\mathbf{w} \in \mathbb{R}^d$ 。跨槽共享參數至關重要：它迫使 MLP 學到一個與槽無關的「此槽與此使用者契合程度」概念，而非為每個槽記憶各自的評分函數。

3.7.3 Softmax 歸一化

A 個 logit 透過溫度 τ 之 softmax 歸一化為槽位之機率分布：

$$w_{u,i,k} = \frac{\exp(\ell_{u,i,k}/\tau)}{\sum_{k'=1}^A \exp(\ell_{u,i,k'}/\tau)}. \quad (3.19)$$

依建構 $\sum_k w_{u,i,k} = 1$ ， A 個槽位權重彼此競爭：增加某槽相對權重必使其餘槽位下降。我們使用 $\tau = 0.5$ ，相對於無資訊先驗（ $\tau = 1$ 在 $\text{logit} = 0$ 時得完全均勻）銳化分布，將質量集中於對使用者最相關之槽。溫度掃描見第 4.5.1 節。

3.7.4 加權聚合

全域視角物品嵌入為槽加權平均

$$i_{\text{glo}} = \sum_{k=1}^A w_{u,i,k} \cdot \mathbf{a}_{i,k} \in \mathbb{R}^d. \quad (3.20)$$

實作上即為「合理化遮罩」步驟：softmax 權重作為槽維度上的軟遮罩，被遮罩之槽位再加總回單一 d 維向量。雖然式 (3.19) 與 (3.20) 概念上為兩步，但在程式中於單一模組（KGRationaleMasking）內以一次前向呼叫完成。

3.7.5 為何使用 Softmax 而非 Sigmoid

一個自然的替代是對每個槽獨立以 sigmoid 評分： $w_{u,i,k} = \sigma(\ell_{u,i,k})$ ，不施加跨槽歸一化。這表達了不同的語意假設：每個槽對使用者獨立地相關或不相關；多個槽可同時「開啟」而不相互競爭。

實證上 sigmoid 變體會使本基準 NDCG@20 下降 7.0%（第 4.4.2 節）——是我們所觀察到單一元件影響最大者。我們解讀為：對於面向顯著性合理化而言，正確的語意假設是競爭而非獨立——在 A 個潛在槽中，合理化回答的是「哪一個」最具代表性，而答案近似為 one-hot。Softmax 直接編碼此假設，sigmoid 則否。我們在第 5 章對此發現作更謹慎之討論，並明確將其定位為單一資料集觀察，需多資料集複製驗證。

佔位：Softmax 合理化遮罩前向流程
 $(u_{\text{glo}}, \{\mathbf{a}_{i,k}\}_{k=1}^A \rightarrow \text{MLP logits} \rightarrow \text{softmax 權重 } w_{u,i,k} \rightarrow \text{加權求和} \rightarrow i_{\text{glo}})$ 。

Figure 3: Softmax 合理化遮罩。

3.8 區域偏置融合閘

融合閘是將 RA-GARK 設計原則（KG 為可被閘控之旁路通道）落實為具體運算的架構機制。它將區域與全域表示結合為最終嵌入，並由其產生分數。

3.8.1 雙側獨立閘

RA-GARK 使用兩個獨立融合閘，使用者側與物品側各一。兩者皆為純量閘，以該側區域與全域嵌入之串接為條件：

$$\alpha_u = \text{Gate}_u([u_{\text{loc}} \parallel u_{\text{glo}}]) \in (0, 1), \quad (3.21)$$

$$\alpha_i = \text{Gate}_i([i_{\text{loc}} \parallel i_{\text{glo}}]) \in (0, 1). \quad (3.22)$$

兩閘參數獨立；經驗上共享參數會劣化結果，因為在稀疏 KG 下 KG 訊號對使用者側與物品側嵌入的邊際資訊量不同。

最終各側嵌入為凸組合

$$u_{\text{final}} = \alpha_u u_{\text{loc}} + (1 - \alpha_u) u_{\text{glo}}, \quad i_{\text{final}} = \alpha_i i_{\text{loc}} + (1 - \alpha_i) i_{\text{glo}}, \quad (3.23)$$

最終分數為內積 $\hat{y}(u, i) = \langle u_{\text{final}}, i_{\text{final}} \rangle$ ，如式 (3.1) 已述。

3.8.2 閘的結構

每個 Gate 為一帶 sigmoid 頭之小型 MLP：

$$\text{Gate}(\mathbf{z}) = \sigma(\mathbf{w}^\top \tanh(\mathbf{W}\mathbf{z}) + b), \quad (3.24)$$

其中 $\mathbf{W} \in \mathbb{R}^{d \times 2d}$ 、 $\mathbf{w} \in \mathbb{R}^d$ 、 b 為純量偏置、 σ 為邏輯函數。隱藏層寬度與嵌入維度一致。第一層權重 $\mathbf{W}$ 以 Xavier-uniform 初始化、偏置為零；第二層權重 $\mathbf{w}$ 同樣以 Xavier-uniform 初始化；第二層偏置 b 即下節要特別初始化者。

3.8.3 區域偏置初始化

關鍵設計選擇為式 (3.24) 中純量偏置 b 的初始化。當 $b = 0$ ，訓練起點之閘輸出約為 $\sigma(0) = 0.5$ ，即區域與全域 50/50 混合。由於全域視角部分由帶雜訊之 KG 初始化，

50/50 起點將使區域表示整個訓練過程中皆暴露於 KG 雜訊；而第 1 章已觀察到此正是深度融合基線的失效模式。

我們改將兩個閘的偏置皆初始化為 $b = +5$ 。訓練起點之閘輸出因此為

$$\alpha^{(0)} \approx \sigma(b) = \sigma(5) \approx 0.993, \quad (3.25)$$

初始混合約為

$$u_{\text{final}}^{(0)} \approx 0.993 u_{\text{loc}}^{(0)} + 0.007 u_{\text{glo}}^{(0)}, \quad (3.26)$$

物品側類似。換言之，RA-GARK 訓練起點實質為純 LightGCN。KG 通道起初僅開啟 0.7%；唯當 BPR 損失對 b 之梯度將 b 向下推動時——亦即拓寬 KG 通道能降低損失時——通道才會被擴大。偏置作為一個學習得到的、傾向安全預設之先驗。

3.8.4 優雅退化

區域偏置初始化提供結構性保證：若 KG 結果為完全無資訊，閘將維持於 $\alpha \approx 1$ 附近，KG 項對分數的貢獻被上界約為 $0.007 \cdot \|\mathbf{a}\| \cdot \|\mathbf{u}\|$ ，模型於經驗上與純 LightGCN 無從區分。第 1 章所列之四個基線皆無此性質：每個都強制 KG 實體嵌入無論其是否具資訊量皆參與傳播路徑。

此即 Highway Networks [10] 嚴格架構意義下的優雅退化性質，自網路內部跳接移植至視角間融合。據我們所知，尚無 KG-aware 推薦器採此設計。

3.8.5 為何選 $+5$ 而非 $+\infty$

偏置量值之選擇依單一原則：大到使初始閘輸出絕對偏向區域、小到使 b 之梯度非零而能於訓練中調整閘。於 $b = +5$ ， $\sigma'(5) = \sigma(5)(1 - \sigma(5)) \approx 0.007$ ——雖小但未消失。 $b = +10$ 之後 b 上之梯度於數值上可忽略，閘無法學會開啟。 $b = +5$ 為使 $\alpha^{(0)} > 0.99$ 同時保持 $\sigma'(b) > 10^{-3}$ 之最小整數，並通過敏感性掃描不需進一步調整（第 4.5.3 節）。完全移除偏置初始化（設 $b = 0$ ）會損失 5.3% NDCG@20（第 4.4.3 節）。




Figure 4: 區域偏置融合閘（物品側同理）。

3.9 跨視角對比正則化

區域與全域視角於結構上異質：一者為來自互動的協同表示，另一者為 KG 衍生表示，二者位於不同歸納子空間。若無任何明確對齊，兩表示在訓練過程中可能漂移至 $\mathbb{R}^d$ 中彼此不相容之區域，此時融合閘所合併的向量並非直接可比。跨視角對比正則化即在處理此幾何錯位。

3.9.1 在架構中的角色

於 RA-GARK 中，對比損失扮演刻意受限之角色。它們並非主要整合機制——此角色由融合閘擔任（第 3.8 節）——而是將兩視角推向共享角度幾何的正則化項。具體而言，我們刻意不使用對比學習讓 KG 通道「掙得」其進入模型之資格，如 KGCL [5] 與 MCCLK [6] 所為；那將重新引入「將 KG 訊號視為必經主融合路徑」的失效模式。

3.9.2 面向層級對比損失

對訓練批次中每件物品 i ，將其投影後的區域嵌入與其 A 個面向槽分別對比：

$$\mathcal{L}_{\text{aCL}} = \frac{1}{A} \sum_{k=1}^A \text{InfoNCE}(g(i_{\text{loc}}), \text{sg}[\mathbf{a}_{i,k}]), \quad (3.27)$$

其中 $g: \mathbb{R}^d \rightarrow \mathbb{R}^d$ 為可學習投影頭（兩層 MLP 加 ReLU），僅施加於區域側輸入； $\text{sg}[\cdot]$ 表示 stop-gradient；InfoNCE 為標準對比目標

$$\text{InfoNCE}(\mathbf{x}, \mathbf{y}) = -\log \frac{\exp(\langle \mathbf{x}, \mathbf{y} \rangle / \tau_{\text{CL}})}{\sum_{j=1}^B \exp(\langle \mathbf{x}, \mathbf{y}_j \rangle / \tau_{\text{CL}})}, \quad (3.28)$$

$\tau_{\text{CL}} = 0.2$ 、 B 為批次大小（負例為批次內其餘物品）。向量於內積之前皆作 ℓ_2 歸一化。

3.9.3 使用者層級對比損失

對稱之使用者層級損失對齊區域與全域使用者嵌入：

$$\mathcal{L}_{\text{uCL}} = \text{InfoNCE}(g(u_{\text{loc}}), \text{sg}[u_{\text{glo}}]). \quad (3.29)$$

投影頭 g 與 $\mathcal{L}_{\text{aCL}}$ 共享，因兩損失皆作用於區域側輸入，且我們希望投影編碼單一之「區域視角如何映射至全域視角角度幾何」變換。

3.9.4 全域側 Stop-Gradient

式 (3.27) 與 (3.29) 中 KG 側之 stop-gradient 在結構上至關重要。若無，對比梯度會反向傳遞至 SVD 初始化的面向槽與全域使用者表，逐漸破壞 KG-SVD 初始化所安裝之角度幾何（第 3.6 節）。配合 stop-gradient 後，對比損失作用不對稱：能將區域視角拉向全域視角已有之幾何，但無法把全域視角向任何方向推動。KG 衍生語意子空間被保留為外部參照，由區域視角承擔對齊代價。

3.9.5 損失權重

式 (3.3) 中對比權重 λ_{CL} 固定為 0.005。此值小到使對比損失於總梯度中貢獻一非主導比例（BPR 仍為主要訊號），亦與第 3.9.1 節所賦予對比正則化之角色一致：幾何先驗，非主要學習目標。我們不對 λ_{CL} 作資料集相關調參。

3.10 訓練與計算複雜度

3.10.1 總目標

完整訓練損失已於式 (3.3) 給出，此處為完整性重述：

$$\mathcal{L} = \mathcal{L}_{\text{BPR}} + \lambda_{\text{CL}}(\mathcal{L}_{\text{aCL}} + \mathcal{L}_{\text{uCL}}). \quad (3.30)$$

BPR 損失提供主要排序訊號；對比項提供跨視角幾何對齊。

3.10.2 最佳化

以 Adam（預設 $\beta_1 = 0.9, \beta_2 = 0.999, \epsilon = 10^{-8}$ ）最佳化式 (3.30)，學習率 10^{-3} 、批次大小 128，最多訓練 30 epochs。以驗證集 NDCG@20 之耐心 10 早停。每批次包含 128 組三元組 (u, i^+, i^-) ，其中 i^- 自 $\mathcal{R}_u$ 之外的物品均勻取樣。式 (3.7)–(3.8) 之 LightGCN 傳播於每批次重新計算一次，並於該批次內正負例評分時共用。

3.10.3 推論

推論時，於評估開始時計算 LightGCN 傳播一次並快取 $\bar{\mathbf{E}}$ 。對每個查詢使用者 u ，以單次批次矩陣乘法計算全部物品集合之分數：面向槽、合理化權重、 i_{glo} 、物品閘以及

與 u_{final} 之內積，皆於整個物品集合上以向量化形式同時評估。

3.10.4 計算複雜度

令 B 為批次大小、 $|\mathcal{E}_{\mathcal{UI}}|$ 為已觀察使用者—物品互動數、 $|\mathcal{I}|$ 為物品數、 A 為槽位數、 d 為嵌入維度、 K 為 LightGCN 層數。每批次訓練成本分解如下：

Table 5: 各模組每批次訓練成本。

模組	成本
LightGCN 傳播	$O(\mathcal{E}_{\mathcal{UI}} d K)$
u_{glo} 查表	$O(B d)$
面向槽讀取	$O(B A d)$
合理化遮罩	$O(B A d)$
使用者與物品融合閘	$O(B d^2)$
BPR 與對比損失	$O(B d)$

LightGCN 傳播項主導訓練成本，與純 LightGCN 基線完全一致。KG 側之新增（面向讀取、合理化遮罩、融合閘）貢獻為 A 與 d 之線性項，皆相對於傳播為小。RA-GARK 之每 epoch 牆鐘時間因此於純 LightGCN 之小常數倍以內，並於同一硬體與相同嵌入維度下與 KGRec 大致相等（精確牆鐘數字見第 4.8 節）。

全集合推論由使用者條件之物品側合理化遮罩步驟 $O(B \cdot |\mathcal{I}| \cdot A \cdot d)$ 主導，於本論文使用之資料集規模下可行。

Chapter 4

實驗

4.1 資料集與 KG 建構




Figure 5: 評論衍生 KG 建構 pipeline。

4.2 實驗設定

4.3 主要結果

4.4 消融研究

4.4.1 KG-SVD 初始化

4.4.2 Softmax 合理化遮罩

4.4.3 區域偏置融合閘

4.5 敏感性分析

4.5.1 Softmax 溫度 τ

4.5.2 面向槽數 A

4.5.3 融合閘偏置

4.5.4 對比權重 λ_{CL}

4.6 種子穩定性

4.7 個案研究

4.8 計算成本

Chapter 5

結論與未來工作

5.1 結論

5.2 方法論啟示：注意力正規化

5.3 限制

5.4 未來工作

Bibliography

- [1] X. He, K. Deng, X. Wang, Y. Li, Y. Zhang, and M. Wang, “LightGCN: Simplifying and powering graph convolution network for recommendation,” in *Proc. ACM SIGIR*, 2020, pp. 639–648.
- [2] X. Wang, X. He, M. Wang, F. Feng, and T.-S. Chua, “Neural graph collaborative filtering,” in *Proc. ACM SIGIR*, 2019, pp. 165–174.
- [3] J. Wu, X. Wang, F. Feng, X. He, L. Chen, J. Lian, and X. Xie, “Self-supervised graph learning for recommendation,” in *Proc. ACM SIGIR*, 2021, pp. 726–735.
- [4] X. Wang, X. He, Y. Cao, M. Liu, and T.-S. Chua, “KGAT: Knowledge graph attention network for recommendation,” in *Proc. ACM SIGKDD*, 2019, pp. 950–958.
- [5] Y. Yang, C. Huang, L. Xia, and C. Li, “Knowledge graph contrastive learning for recommendation,” in *Proc. ACM SIGIR*, 2022, pp. 1434–1443.
- [6] D. Zou, W. Wei, X.-L. Mao, Z. Wang, M. Qiu, F. Zhu, and X. Cao, “Multi-level cross-view contrastive learning for knowledge-aware recommender system,” in *Proc. ACM SIGIR*, 2022, pp. 1358–1368.
- [7] Y. Yang, C. Huang, L. Xia, and C. Huang, “Knowledge graph self-supervised rationalization for recommendation,” in *Proc. ACM SIGKDD*, 2023, pp. 3046–3056.
- [8] X. Ren, L. Xia, J. Zhao, D. Yin, and C. Huang, “Disentangled contrastive collaborative filtering,” in *Proc. ACM SIGIR*, 2023, pp. 1137–1146.
- [9] A. van den Oord, Y. Li, and O. Vinyals, “Representation learning with contrastive predictive coding,” *arXiv preprint arXiv:1807.03748*, 2018.
- [10] R. K. Srivastava, K. Greff, and J. Schmidhuber, “Highway networks,” *arXiv preprint arXiv:1505.00387*, 2015.

- [11] J. Ma, Z. Zhao, X. Yi, J. Chen, L. Hong, and E. H. Chi, “Modeling task relationships in multi-task learning with multi-gate mixture-of-experts,” in *Proc. ACM SIGKDD*, 2018, pp. 1930–1939.
- [12] H. Tang, J. Liu, M. Zhao, and X. Gong, “Progressive layered extraction (PLE): A novel multi-task learning model for personalized recommendations,” in *Proc. ACM RecSys*, 2020, pp. 269–278.
- [13] Z. Wang, G. Lin, H. Tan, Q. Chen, and X. Liu, “CKAN: Collaborative knowledge-aware attentive network for recommender systems,” in *Proc. ACM SIGIR*, 2020, pp. 219–228.
- [14] H. Wang, F. Zhang, M. Zhao, W. Li, X. Xie, and M. Guo, “Multi-task feature learning for knowledge graph enhanced recommendation,” in *Proc. The Web Conference (WWW)*, 2019, pp. 2000–2010.
- [15] X. Wang, T. Huang, D. Wang, Y. Yuan, Z. Liu, X. He, and T.-S. Chua, “Learning intents behind interactions with knowledge graph for recommendation,” in *Proc. The Web Conference (WWW)*, 2021, pp. 878–887.
- [16] G. Zhou, X. Zhu, C. Song, Y. Fan, H. Zhu, X. Ma, Y. Yan, J. Jin, H. Li, and K. Gai, “Deep interest network for click-through rate prediction,” in *Proc. ACM SIGKDD*, 2018, pp. 1059–1068.
- [17] X. He, Z. He, J. Song, Z. Liu, Y.-G. Jiang, and T.-S. Chua, “NAIS: Neural attentive item similarity model for recommendation,” *IEEE Transactions on Knowledge and Data Engineering*, vol. 30, no. 12, pp. 2354–2366, 2018.
- [18] J. Xiao, H. Ye, X. He, H. Zhang, F. Wu, and T.-S. Chua, “Attentional factorization machines: Learning the weight of feature interactions via attention networks,” in *Proc. International Joint Conference on Artificial Intelligence (IJCAI)*, 2017, pp. 3119–3125.
- [19] S. Rendle, C. Freudenthaler, Z. Gantner, and L. Schmidt-Thieme, “BPR: Bayesian personalized ranking from implicit feedback,” in *Proc. Conference on Uncertainty in Artificial Intelligence (UAI)*, 2009, pp. 452–461.