

# 基於理由感知門控與稀疏評論面向知識圖譜之產品推薦

學生：預覽用

指導教授：預覽用 博士

國立陽明交通大學資訊學院碩士在職專班

## 摘 要

知識圖譜感知推薦在圖譜稠密且品質良好時普遍能提升準確度，但當圖譜稀疏或品質不佳時，例如評論衍生、冷啟動或隱私受限等常見情境，既有研究探討仍十分有限。本文以商品評論衍生的圖譜為例，過濾後每件商品平均僅 2.4 條邊，觀察到 KGAT、KGCL、MCCLK 與 KGRec 四個代表性方法的表現皆不如完全不使用圖譜的純 LightGCN。原因在於這些方法將圖譜硬性嵌入評分流程，缺乏可在其不可信時將之關閉的開關，雜訊因而干擾了協同訊號的學習。

本文提出 RA-GARK，將圖譜當作一條可開關的側通道，而非評分流程中非用不可的組件，並以三個步驟實現。其一，把每件商品的相關內容整理成少數幾個代表性面向，並讓這些面向從帶有語意的起始值出發，而非隨機初始化。其二，再依使用者與商品自動挑出最相關的面向。其三，由一個融合閘決定是否啟用這條側通道：它起初幾乎關閉，使訓練起點等同於純 LightGCN，只有當側通道確實有幫助時才逐步打開，讓模型在其無用時能平順退回。在不更動圖譜的前提下，RA-GARK 便將其貢獻由無益翻轉為有益。

本研究的價值在於指出：知識圖譜感知方法在稀疏圖譜上表現不佳，是架構問題而非資訊問題；同一個在強制融合下成為負擔的圖譜，一旦其使用被設計為可選，便能轉為助益。據此，優雅退化提供了一個可重用的設計原則，適用於任何事先無法保證可靠性的輔助訊號，例如評論衍生、冷啟動或隱私受限的知識圖譜。

**關鍵字：**知識圖譜推薦；可退化機制；融合閘；稀疏知識圖譜；協同過濾

# Contents

|          |                                |           |
|----------|--------------------------------|-----------|
| <b>1</b> | <b>緒論</b>                      | <b>1</b>  |
| 1.1      | 研究背景 . . . . .                 | 1         |
| 1.2      | 稀疏 KG 下的經驗異常現象 . . . . .       | 1         |
| 1.3      | 稀疏 KG 作為現實世界的常態 . . . . .      | 2         |
| 1.4      | 研究問題 . . . . .                 | 2         |
| 1.5      | 研究貢獻 . . . . .                 | 3         |
| 1.6      | 論文組織 . . . . .                 | 4         |
| <b>2</b> | <b>相關研究</b>                    | <b>5</b>  |
| 2.1      | 基礎：LightGCN 與 KGAT . . . . .   | 5         |
| 2.2      | 對比式知識圖譜方法 . . . . .            | 6         |
| 2.3      | 合理化感知推薦：KGRec . . . . .        | 6         |
| 2.4      | 合理化典範：共同前提與分歧的可信度假設 . . . . .  | 7         |
| 2.5      | 深度學習中的閘控機制 . . . . .           | 8         |
| 2.6      | 缺口：KG-Aware 推薦中沒有融合閘 . . . . . | 9         |
| 2.7      | 注意力正規化 . . . . .               | 9         |
| 2.8      | 總結與 RA-GARK 的定位 . . . . .      | 10        |
| <b>3</b> | <b>方法</b>                      | <b>11</b> |
| 3.1      | 設計原則：KG 作為可被閘控的旁路通道 . . . . .  | 11        |
| 3.2      | 架構概覽 . . . . .                 | 12        |
| 3.3      | 符號 . . . . .                   | 12        |
| 3.4      | 問題定式 . . . . .                 | 13        |
| 3.5      | 區域視角：LightGCN . . . . .        | 14        |
| 3.5.1    | 動機 . . . . .                   | 14        |

|        |                                   |    |
|--------|-----------------------------------|----|
| 3.5.2  | 圖的建構 . . . . .                    | 15 |
| 3.5.3  | 傳播 . . . . .                      | 15 |
| 3.5.4  | 層平均與輸出 . . . . .                  | 15 |
| 3.6    | 全域視角：KG-SVD 初始化 . . . . .         | 16 |
| 3.6.1  | 面向槽作為物品側 KG 表示 . . . . .          | 16 |
| 3.6.2  | 共現矩陣 . . . . .                    | 17 |
| 3.6.3  | IDF 加權 . . . . .                  | 17 |
| 3.6.4  | 截斷 SVD . . . . .                  | 17 |
| 3.6.5  | 重塑為槽位與量值縮放 . . . . .              | 18 |
| 3.6.6  | 演算法 . . . . .                     | 18 |
| 3.6.7  | 此初始化所帶來的效益 . . . . .              | 18 |
| 3.7    | 全域視角：Softmax 合理化遮罩 . . . . .      | 19 |
| 3.7.1  | 動機 . . . . .                      | 19 |
| 3.7.2  | 使用者條件之注意力 logits . . . . .        | 19 |
| 3.7.3  | Softmax 歸一化 . . . . .             | 20 |
| 3.7.4  | 加權聚合 . . . . .                    | 20 |
| 3.7.5  | 為何使用 Softmax 而非 Sigmoid . . . . . | 20 |
| 3.8    | 區域偏置融合閘 . . . . .                 | 21 |
| 3.8.1  | 雙側獨立閘 . . . . .                   | 21 |
| 3.8.2  | 閘的結構 . . . . .                    | 21 |
| 3.8.3  | 區域偏置初始化 . . . . .                 | 22 |
| 3.8.4  | 優雅退化 . . . . .                    | 22 |
| 3.8.5  | 為何選 +5 而非 $+\infty$ . . . . .     | 22 |
| 3.9    | 跨視角對比正則化 . . . . .                | 23 |
| 3.9.1  | 在架構中的角色 . . . . .                 | 23 |
| 3.9.2  | 面向層級對比損失 . . . . .                | 23 |
| 3.9.3  | 使用者層級對比損失 . . . . .               | 23 |
| 3.9.4  | 全域側 Stop-Gradient . . . . .       | 24 |
| 3.9.5  | 損失權重 . . . . .                    | 24 |
| 3.10   | 訓練與計算複雜度 . . . . .                | 24 |
| 3.10.1 | 總目標 . . . . .                     | 24 |
| 3.10.2 | 最佳化 . . . . .                     | 24 |

|          |                     |           |
|----------|---------------------|-----------|
| 3.10.3   | 推論                  | 25        |
| 3.10.4   | 計算複雜度               | 25        |
| <b>4</b> | <b>實驗</b>           | <b>26</b> |
| 4.1      | 資料集與 KG 建構          | 26        |
| 4.1.1    | 資料集                 | 26        |
| 4.1.2    | 知識圖譜建構              | 27        |
| 4.2      | 實驗設定                | 27        |
| 4.2.1    | Baseline            | 27        |
| 4.2.2    | 評估協議                | 28        |
| 4.2.3    | 超參數設定               | 28        |
| 4.2.4    | 硬體與軟體               | 29        |
| 4.3      | 主要結果                | 29        |
| 4.4      | 消融研究                | 29        |
| 4.5      | 敏感性分析               | 31        |
| 4.5.1    | Softmax 溫度 $\tau$   | 31        |
| 4.5.2    | 面向槽數 $A$            | 31        |
| 4.5.3    | 融合閾偏置 $b$           | 32        |
| 4.5.4    | 對比權重 $\lambda_{CL}$ | 32        |
| 4.6      | 結果穩定性               | 32        |
| 4.7      | 個案研究                | 33        |
| 4.8      | 計算成本                | 34        |
| <b>5</b> | <b>結論與未來工作</b>      | <b>35</b> |
| 5.1      | 結論                  | 35        |
| 5.2      | 方法論啟示：注意力歸一化        | 36        |
| 5.3      | 限制                  | 37        |
| 5.4      | 未來工作                | 37        |

# Chapter 1

## 緒論

### 1.1 研究背景

圖神經網路 (GNN) 已成為協同過濾的主流架構選擇。其中，LightGCN [1] 證明了只要移除 GCN 中的非線性激活與特徵變換、僅保留線性鄰居聚合，便足以在標準推薦基準上超越如 NGCF [2] 等更深層的方法。LightGCN 的簡潔與穩定使其成為一個強大且參數高效的骨幹，而後續方法如 SGL [3] 則在其上疊加額外的自監督目標。

另一條互補的研究路線，知識圖譜感知推薦 (KG-aware recommendation)，以知識圖譜 (KG) 所編碼的物品端語意來擴充協同訊號。具代表性的方法包括：KGAT [4]，在統一的使用者—物品—實體圖上傳播訊息；KGCL [5] 與 MCCLK [6]，透過對比學習對齊 KG 視角與協同視角；以及 KGRec [7]，引入邊層級的合理化 (rationalization) 機制以辨識哪些 KG 三元組對推薦負責。當 KG 稠密且品質良好時，這類方法皆能穩定地超越純協同基線。

### 1.2 稀疏 KG 下的經驗異常現象

本研究的起點是一個促使整篇論文展開的經驗觀察。在本研究所使用的、由評論衍生而來的 KG 資料集 (Amazon Books 子集，經篩選後每件物品平均僅有 2.4 條 aspect 邊) 上，前述四種具代表性的 KG-aware 方法全部都被完全不參考 KG 的純 LightGCN 所超越。表 1 摘要呈現此一差距。

我們並非主張上述四種基線本身有缺陷，它們在其原始論文所報告的稠密 KG 資料集上表現皆十分強勁。此觀察反映的，是深度 KG-CF 耦合所共同具有的一種失效模式：當 KG 過於稀疏或雜訊過多以致無法提供可靠的物品語意時，將其直接融入評分路

Table 1: 在我們的稀疏評論型 KG 上，代表性 KG-aware 方法之 NDCG@20 表現，並與純 LightGCN 對照。四種 KG-aware 方法皆不及不使用 KG 的基線。

| 方法                      | NDCG@20       |
|-------------------------|---------------|
| MCCLK [6]               | 0.1067        |
| KGCL [5]                | 0.1073        |
| KGAT [4]                | 0.1079        |
| KGRec [7]               | 0.1095        |
| 純 LightGCN [1] (未使用 KG) | <b>0.1179</b> |

徑會使 KG 雜訊污染本可產生純淨協同訊號的梯度流。

### 1.3 稀疏 KG 作為現實世界的常態

一個自然的反駁是：將此一經驗異常視為資料集的特殊性，並透過更精緻地策劃稠密 KG 或進行 KG 補全 (completion) 來填補缺失邊即可。然而，我們主張，稀疏 KG 才是實務推薦系統中更常見的情境，因此「在 KG 訊號不可靠時依然穩健」這項性質本身就值得專門研究，而非以工程繞道方式迴避。

實務上有三個常見的稀疏來源。其一，評論衍生型 KG (如本研究所使用者) 其密度繼承自使用者實際提及的主題；覆蓋本質上即不均勻。其二，冷啟動與新興領域 (新品類、低資源語言、利基垂直市場) 通常無法取得如 Freebase 或 Wikidata 等等級的人工策劃資源，KG 必須從有限訊號中自舉而來。其三，隱私受限領域，如醫療或金融推薦，刻意限制可暴露給模型的關聯訊號。在以上三種情境中，激進的 KG 補全本身亦非易事：補全會引入新的雜訊，且通常需要足夠的種子訊號才能訓練，而這恰恰是稀疏情境中所欠缺的。

由此推論，推薦器在 KG 不可靠時的穩健性，至少和它在 KG 稠密時的峰值效能同等重要。本論文以此穩健性作為主要設計目標。

### 1.4 研究問題

上述經驗異常與稀疏 KG 情境的實務重要性，引出兩個研究問題：

- (RQ1, 診斷) 為何既有 KG-aware 方法在稀疏 KG 下不及純 LightGCN？它們所共同具備的結構性失效模式為何？

- (RQ2, 處方) 何種設計原則能讓模型在 KG 訊號有效時加以利用，而在訊號無效時避免 KG 雜訊污染協同過濾？

本論文的主張是：KG 不應如 KGAT 式深度融合那般，成為評分管線中的必要組件，而應作為一條可依其訊號是否有效而被明確開控的旁路通道。具體而言，此原則由三項設計選擇實現：以 softmax 為基礎的 aspect-saliency 注意力，用於對每組使用者—物品配對選取 KG 合理化依據；以 KG 驅動的 SVD 初始化，用以保留語意幾何；以及具有局部偏置的融合閘（local-biased fusion gate），其初始化內建了當 KG 訊號終究不具資訊量時優雅退化回純 LightGCN 的能力。

## 1.5 研究貢獻

本論文之主要貢獻如下：

1. **經驗性研究**：證明在稀疏評論型 KG 下，四種具代表性的 KG-aware 方法（KGAT、KGCL、MCCLK、KGRec）皆一致地被純 LightGCN 超越。我們將此歸因於這些方法缺乏一個能於 KG 不可靠時將其脫接的架構機制。
2. **RA-GARK，一個雙視角架構**：以旁路通道而非深度融合的方式整合協同訊號與 KG 衍生訊號。RA-GARK 由三項核心要素組成，且彼此皆獨立必要：
  - **Softmax aspect-saliency 注意力**（第 3.7 節）。每件物品的 KG 語意儲存於  $A = 4$  個潛在面向槽中（此槽位數為模型設計參數，與每件物品所擁有的原始面向標籤數無關）槽位內容由 IDF 加權商品—面向共現矩陣之截斷 SVD 投影而得；softmax 正規化的注意力為給定的使用者—物品配對選取最足以代表該物品的潛在槽位。將 softmax 改為 sigmoid 會使 NDCG@20 下降 7.0%，是我們所觀察到單一元件影響最大者。
  - **具局部偏置的融合閘**（第 3.8 節）。融合閘以 +5 的正偏置初始化，使  $\alpha^{(0)} \approx 0.993$ 。因此模型在訓練之初幾乎等同於純 LightGCN，僅當梯度顯示 KG 通道有幫助時，閘門才會被打開。此設計提供了四種基線所缺乏的、結構性的優雅退化保證。若移除此偏置初始化，NDCG@20 會損失 5.3%。
  - **KG-SVD 初始化**（第 3.6 節）。aspect 槽位的嵌入由 IDF 加權的物品—aspect 矩陣之截斷 SVD 初始化而來，將 KG 的語意幾何保留為最佳化的起點。將其換為隨機初始化會損失 5.3% NDCG@20。

3. **經驗驗證：**在稀疏評論型 KG 基準上，RA-GARK 達到  $\text{NDCG}@20 = 0.1238$ ，較最強的 KG-aware 基線 (KGRec) 高出 +13.1%，更重要的是，較純 LightGCN 也高出 +5.0%。後者的差距顯示，所提出的設計原則能在 KG 本身不變的情況下，把 KG 訊號的貢獻由淨負（四種基線之情況）翻轉為淨正。
4. **關於合理化感知設計中注意力正規化的方法論觀察。**在我們的情境中，softmax 與 sigmoid 之間異常顯著的差距，暗示正規化的選擇應與合理化的語意假設相一致。我們將此視為單一資料集上的假設而非通用主張，留待後續多資料集複製驗證（第 5 章）。

## 1.6 論文組織

本論文後續組織如下。第 2 章從四個面向回顧相關文獻：圖協同過濾、KG-aware 推薦、深度學習中的閘控機制，以及注意力正規化。第 3 章完整呈現 RA-GARK 架構：陳述設計原則、固定符號與問題形式化，並依序展開各模組，LightGCN 區域視角、含兩項創新（KG-SVD 初始化與 softmax aspect-saliency 注意力）的全域 KG 視角、具局部偏置的融合閘、跨視角對比正則化，並附訓練流程與計算複雜度。第 4 章報告實驗結果、消融研究、敏感性分析、結果穩定性與個案研究。第 5 章討論關於注意力正規化的方法論啟示，承認單一資料集驗證的限制，並提出未來工作方向。

# Chapter 2

## 相關研究

本章從四個面向回顧先前研究，這些面向共同促成 RA-GARK 的設計。第 2.1 節介紹我們區域與全域視角所立足的兩項基礎：作為協同過濾骨幹的 LightGCN，與作為深度 KG-CF 融合典範的 KGAT。第 2.2 節回顧那些在不明確閘控下對齊協同與 KG 視角的對比式 KG 方法。第 2.3 節討論與本工作最為相關的合理化感知方法 KGRc，第 2.4 節則以「KG 可信度」為視角，對比我們與 KGRc 的合理化典範。第 2.5 與 2.6 節廣泛回顧深度學習中的閘控機制，並觀察到既有 KG-aware 方法皆未採用融合閘以提供架構層級的優雅退化。第 2.8 節總結 RA-GARK 相對於上述工作的定位。

### 2.1 基礎：LightGCN 與 KGAT

LightGCN [1] 是本研究區域視角的直接前身。建立於「NGCF [2] 中的非線性特徵變換對推薦準確率貢獻甚微」這項觀察上，LightGCN 將圖卷積網路精簡至最小骨幹：在使用者—物品二部圖上進行正規化的鄰居聚合  $\mathbf{E}^{(\ell+1)} = \tilde{\mathbf{A}}\mathbf{E}^{(\ell)}$ ，最終嵌入則取各層平均  $\bar{\mathbf{E}} = \frac{1}{K+1} \sum_{\ell=0}^K \mathbf{E}^{(\ell)}$ 。此一簡化在標準推薦基準上一致地優於 NGCF，且訓練更快、更穩定。其後諸多自監督方法，如 SGL [3] 與 DCCF [8]，皆在 LightGCN 式骨幹之上疊加額外的對比目標。

在 RA-GARK 中，我們原封不動採用 LightGCN ( $K = 2$ ) 作為區域視角：此分支內不施加任何 KG 相關運算。動機有二。其一，在我們的稀疏評論型 KG 上，純 LightGCN 已達  $\text{NDCG}@20 = 0.1179$ ，超越所有我們所評估的 KG-aware 基線。任何偏離此強預設的設計，皆須可被證實能改善而非劣化結果，這是本論文反覆訴諸的硬性設計約束。其二，將 KG 訊號隔離至獨立的全域視角（第 3 章），可避免 KG 雜訊污染協同表示的梯度流。

**KGAT** [4] 代表 KG-aware 推薦中的典範深度融合做法。KGAT 將使用者—物品互動圖與知識圖譜合併為一個協同知識圖 (Collaborative Knowledge Graph, CKG)，並以雙交互聚合器於此統一結構上傳播訊息。KG 實體嵌入因而直接參與使用者與物品表示的形成。當 KG 稠密且品質良好時，此設計相對於 CF 基線可取得顯著提升。

此處的隱含假設是 KG 可被信任，能在傳播路徑所及之處皆注入有用訊號。在我們的稀疏情境下此假設崩解：KGAT 僅達  $\text{NDCG}@20 = 0.1079$ ，低於純 LightGCN。其後續工作 [5, 6, 7] 沿用 KGAT 式聚合器，因此也繼承相同的脆弱性。RA-GARK 反轉此一設計選擇：我們完全不將 KG 與使用者—物品圖合併，而是將 KG 訊號導入一條專用旁路通道，當 KG 被證實不可靠時模型可衰減甚至全然脫接之。

## 2.2 對比式知識圖譜方法

**KGCL** [5] 對 KG 引入關係層級的結構擾動，並以 InfoNCE [9] 對比目標對齊擾動版本與原始版本。直覺是：具資訊量的 KG 結構應對隨機擾動具有不變性，而雜訊邊則不應。KGCL 在稠密 KG 情境下顯著優於 KGAT。然而在我們的稀疏情境中，擾動後的 KG 保留的邊過少，對比目標無法提供可靠監督： $\text{NDCG}@20$  降至 0.1073。

**MCCLK** [6] 將對比對齊擴展至三個視角（協同、語意與結構）並對三者兩兩施加對比損失。雖然此多視角設計在稠密 KG 基準上取得 SOTA，但同樣繼承稠密 KG 的假設：在稀疏 KG 下，三個視角中有兩個（語意與結構）訊號不足，對比對齊淪為由雜訊主導而非由結構主導的正則化（0.1067  $\text{NDCG}@20$ ）。

RA-GARK 同樣納入跨視角對比學習，但其角色刻意受限。我們的對比損失（ $\mathcal{L}_{\text{aCL}}$  與  $\mathcal{L}_{\text{uCL}}$ ，第 3.9 節）僅作為小權重（ $\lambda = 0.005$ ）的輔助幾何正則化項，並關鍵地在 KG 側施加 stop-gradient，使對比梯度從不反向傳遞至 SVD 初始化的 aspect 嵌入。相較於 KGCL/MCCLK，此處的對比學習是表層的對齊層，而非主要的融合機制；協同與 KG 訊號的實際整合，是由一個明確的閘所執掌（第 2.5 節）。

## 2.3 合理化感知推薦：KGRec

**KGRec** [7] 是與本工作最直接相關的研究。它是第一個將合理化選擇明確化的 KG-aware 推薦器：KGRec 不將每條 KG 三元組視為同等具資訊量，而是對每條 KG 邊計算一個基於注意力的重要性分數，並以 Bernoulli dropout 隨機移除高注意力邊，迫使模型不依賴少數主導邊；其穩健性接著由原始圖與被丟邊版本之間的對比目標來強化。整套合理化機制建立於 KGAT 式聚合器之上，因此合理化作用於使用者—物品—實體統

一圖的訊息傳遞路徑之內。在我們的稀疏基準上，KGRec 取得  $NDCG@20 = 0.1095$ ，為四個 KG-aware 基線中最強者，但仍低於純 LightGCN。

RA-GARK 在精神上採納合理化感知典範，但在結構上多處與 KGRec 有別，下節詳述之。

## 2.4 合理化典範：共同前提與分歧的可信度假設

KGRec [7] 與 RA-GARK 都認同「並非所有 KG 邊都對推薦同等貢獻、需要明確的選擇機制」這項觀察。然而二者對 KG 整體可信度所作的假設有所不同，此一假設並蔓延至各自分歧的設計選擇。

KGRec 的隱含假設是：具資訊量的邊存在於 KG 中，因此合理化任務簡化為將其找出；隨機 dropout 配合對比學習已足以辨識並放大有用子集。KG 整體作為證據體系被假定為可靠的，僅是個別邊的權重需被調整。

RA-GARK 的前提較弱。我們不假設 KG 整體是可靠的。aspect-saliency softmax (第 3.7 節) 在 KG 具資訊量時選取合理化依據，但具局部偏置的融合閘 (第 3.8 節) 可在閘的梯度顯示無益時，另外地脫接整條 KG 通道。此可信度差異展現於四項設計分歧上：

- **合理化粒度。** KGRec 在邊 (KG 三元組) 層級進行選擇。RA-GARK 將每件物品的 KG 語意聚合為  $A = 4$  個潛在面向槽 (槽位內容由 IDF 加權商品—面向共現矩陣之截斷 SVD 投影得到) 並在槽位層級進行選擇。此槽位數為模型設計參數，與每件物品所擁有的原始面向標籤數無關；粒度雖較邊層級選擇為粗，但直接產生可解讀的每物品 aspect 偏好。
- **選擇機制。** KGRec 採用離散 Bernoulli dropout 配合對比學習。RA-GARK 採用可微分的 softmax 注意力，能端到端訓練，並將推論期的權重作為可解釋性產物外露。
- **作用位置。** KGRec 在 KGAT 訊息傳遞路徑之內施加合理化；合理化與聚合糾纏在一起。RA-GARK 將合理化置於與 LightGCN 區域視角分離的旁路通道，僅於後期由閘將兩者結合。
- **對 KG 可信度的處理。** KGRec 沒有任何架構機制可脫接 KG。RA-GARK 的偏置初始化融合閘正提供此一機制：訓練起始時  $\alpha^{(0)} \approx 0.993$ ，模型實質上即為純 LightGCN；唯當學習顯示 KG 通道能降低損失時，閘才會被打開。

Table 2: 合理化典範對比：KGRc 與 RA-GARK 於四項設計軸線。

| 軸線       | KGRc                   | RA-GARK     |
|----------|------------------------|-------------|
| 合理化粒度    | KG 三元組 (邊)             | $A$ 個潛在面向槽  |
| 選擇機制     | Bernoulli dropout + CL | Softmax 注意力 |
| 作用位置     | KGAT 訊息傳遞之內            | 旁路通道，後期融合   |
| KG 可信度處理 | 無脫接機制                  | 偏置初始化融合閘    |

表 2 將上述四項軸線並列對照。

因此我們不將 RA-GARK 定位為對 KGRc 的工程性改良，而是基於對 KG 可信度不同前提之另一種設計。此一區別在經驗上是否重要，則於第 4 章中作答。

## 2.5 深度學習中的閘控機制

RA-GARK 的融合閘有兩個 KG-aware 推薦之外的近親，二者皆啟發本研究設計。

**Highway Networks** [10] 引入可學習的閘  $T(\mathbf{x})$ ，於變換訊號  $H(\mathbf{x})$  與恆等跳接間進行插值： $\mathbf{y} = T(\mathbf{x}) \cdot H(\mathbf{x}) + (1 - T(\mathbf{x})) \cdot \mathbf{x}$ 。其關鍵設計選擇為對  $T$  的負偏置初始化：訓練之初  $T \approx 0$ ，網路表現為恆等映射。其後訓練僅在變換有益處之處才打開閘門。此設計原本是為了應對極深網路訓練的困難，但「將閘偏置至已知安全的預設，僅在學習認為合理時才覆寫」此結構性樣式，遠遠超出深度的脈絡而具有普適性。RA-GARK 將此樣式由網路內跳接移植至雙視角融合：融合閘上的 +5 偏置扮演與 Highway 之負偏置相同的角色，對 KG 通道提供優雅退化保證。

**專家混合 (Mixture-of-Experts) 閘控**，以多任務推薦中的 MMoe [11] 與 PLE [12] 為代表，以閘控網路對多個專家塔加權。雖然概念上類似多管線選擇，但兩項重要性質與 RA-GARK 不同。其一，MMoe/PLE 中的專家為同質候選者（皆為相同架構、僅以任務特定目標訓練的實例）因此並無「某專家本質上比另一者較不可靠」的概念。其二，這些架構中的閘採對稱初始化（訓練起始不偏向任何特定專家），適用於對稱專家情境，但不適用於我們不對稱的情境，在我們的設定中，一條通道 (LightGCN) 已知是強預設，另一條 (KG) 已知有時並不具資訊量。

另有一條工作線是對比式雙視角推薦器，例如 SGL [3] 與 DCCF [8]，這類方法以擾動單一圖（邊 dropout、節點 dropout、隨機漫步）來建構多個視角。此類方法中兩個視角位於相同訊號空間，對比對齊已足以整合二者。RA-GARK 的兩個視角則在結構上異質：區域視角為使用者—物品二部圖，全域視角為物品—aspect 的 KG。僅靠對比學習進行隱式對齊，無法調整兩個異質訊號空間的相對權重；明確的閘是必要的。

## 2.6 缺口：KG-Aware 推薦中沒有融合閘

儘管閘控在深度學習中已相當成熟，我們所調研的 KG-aware 推薦文獻中，未見任何方法將融合閘作為協同訊號與 KG 訊號之間的整合機制。表 3 摘要了四個被基準測試的基線與另外三個知名 KG-aware 方法（CKAN [13]、MKR [14]、KGIN [15]）所採用的整合機制。在這個集合中，KG 訊號是透過直接實體傳播、對比對齊、邊層級 dropout、注意力、跨特徵單元或意圖解耦模組來整合。沒有任何機制允許 KG 通道在訊號不可靠時被結構性地脫接。

Table 3: 代表性 KG-aware 推薦器所採用的整合機制。皆未提供在不可靠 KG 下的架構優雅退化能力。

| 方法                   | KG 整合機制                | 可脫接？     |
|----------------------|------------------------|----------|
| KGAT [4]             | 直接實體訊息傳播               | 否        |
| KGCL [5]             | 擾動 KG 對比學習             | 否        |
| MCCLK [6]            | 多視角對比對齊                | 否        |
| KGRec [7]            | 邊層級 dropout + KGAT 聚合器 | 否        |
| CKAN [13]            | 協同—知識注意力               | 否        |
| MKR [14]             | 跨特徵轉移單元                | 否        |
| KGIN [15]            | KG 上的意圖解耦              | 否        |
| <b>RA-GARK (本研究)</b> | <b>偏置初始化的融合閘</b>       | <b>是</b> |

我們刻意作出一個範圍狹義的主張。我們不主張 RA-GARK 是 KG-aware 推薦中首個使用「任何閘」的方法，因 KG-aware 文獻浩繁，無法窮舉列舉。可辯護的主張為：在我們所檢視的方法中，沒有任何一個以偏置初始化的融合閘於稀疏或不可靠 KG 下提供架構優雅退化。我們在第 4 章的消融將 5.3% NDCG@20 的貢獻明確歸因於此閘的偏置初始化，支持上述主張在此情境中並非微不足道。

## 2.7 注意力正規化

一個橫跨多領域的相關問題是：在選擇合理化依據時，應對注意力權重套用 sigmoid 或 softmax？文獻並未匯聚於單一答案。DIN [16] 對使用者行為歷史套用 sigmoid 注意力，所基於的假設是每筆歷史行為與候選物品的相關性彼此獨立。NAIS [17] 對歷史互動套用 softmax 注意力以衡量物品相似度，AFM [18] 則對特徵交互套用 softmax。各工作中的選擇皆以其注意力所依附的語意假設為依據。

我們在第 4 章報告一項單一資料集的觀察：對於我們的 aspect-saliency 合理化，將 softmax 替換為 sigmoid 會損失 7.0% NDCG@20，這是我們所量測到單一元件影響最大

者。我們將其解讀為支持「正規化應與合理化的語意假設相符」此一設計啟發，但明確將此觀察定位為待多資料集複製驗證的假設（第 5 章）。

## 2.8 總結與 RA-GARK 的定位

表 4 從四個設計面向匯整比較。在我們稀疏基準上所評估的方法中，RA-GARK 是唯一同時將純 LightGCN 區域聚合器與閘控後期融合的 KG 訊號相結合者，也是唯一將合理化作用於物品—aspect 粒度而非 KG 邊粒度者。

Table 4: 從四個面向所作的設計比較。NDCG@20 於我們的稀疏評論型 KG 基準上報告。

| 方法             | 區域聚合器             | KG 整合          | 合理化                   | NDCG@20       |
|----------------|-------------------|----------------|-----------------------|---------------|
| KGAT           | 雙交互               | 直接傳播           | 無                     | 0.1079        |
| KGCL           | KGAT 式            | 傳播 + CL        | 無                     | 0.1073        |
| MCCLK          | 多視角               | 多視角 CL         | 無                     | 0.1067        |
| KGRec          | KGAT 式            | 傳播 + 邊 dropout | 邊 Bernoulli           | 0.1095        |
| <b>RA-GARK</b> | <b>純 LightGCN</b> | <b>閘控後期融合</b>  | <b>Aspect softmax</b> | <b>0.1238</b> |

我們並不將 RA-GARK 定位為相對於四個基線的嚴格改進。RA-GARK 在設計空間中佔據一個不同的位置，其特徵在於將 KG 視為可被明確閘控的旁路通道，而非必要的管線組件。此選擇在我們的稀疏 KG 情境中產出強勁結果，而基於閘控的優雅退化性質，在 KG 品質不均或模型部署於 KG 密度差異各異的多個領域時，或許亦能派上用場。然而，當 KG 稠密且品質一致地可靠時，KGAT 或 KGRec 這類深度融合方法可能仍較佳，因為後期融合的設計犧牲了深度融合架構所具有的部分表徵表達力。

# Chapter 3

## 方法

本章呈現 RA-GARK 之完整方法，編排如下：

- 第 3.1 節說明使 RA-GARK 有別於第 2 章所回顧之深度融合基線的核心設計原則。
- 第 3.2 節以泳道圖（swim-lane）呈現推論時的整體資料流。
- 第 3.3 至 3.4 節固定符號並形式化推薦任務與訓練目標。
- 第 3.5 至 3.9 節依模組於前向傳遞中的順序逐一詳述各模組。
- 第 3.10 節說明訓練程序與計算複雜度。

### 3.1 設計原則：KG 作為可被閘控的旁路通道

第 1 章的經驗觀察是：在本研究稀疏的評論衍生知識圖譜（KG）上，四種具代表性的 KG-aware 方法（KGAT、KGCL、MCCLK、KGRec）皆被純 LightGCN 一致地超越。

這些基線所共有的結構性失因在於：KG 被當作評分管線的必要組件串接進來，KG 實體嵌入直接參與訊息傳遞，且無任何架構性的開關能在 KG 被證實不可靠時將其脫接。因此 KG 雜訊與協同表示共享同一條梯度流。

RA-GARK 圍繞一個直接面對此失效模式的核心設計原則：

*KG 不應為評分管線的必要組件，而應為一條旁路通道；其對最終分數的貢獻由一個學習得到的閘決定，閘在初始化時偏置至一個安全預設（純協同過濾），僅在訓練訊號顯示 KG 通道能降低損失時才被打開。*

此原則衍生三項架構層級的後果，並共同定義 RA-GARK：

1. **雙條平行視角**。區域視角透過在使用者—物品互動圖上運行 LightGCN 產生純協同表示  $(u_{loc}, i_{loc})$ ，過程中完全不涉及 KG。全域視角則由獨立的使用者嵌入表與物品端的潛在面向槽產生 KG 表示  $(u_{glo}, i_{glo})$ ，過程中亦不涉及協同訊號。直至融合階段之前，兩條視角在結構上完全分離。
2. **後期、開控的融合**。兩條視角僅在最終評分階段被融合開合併；該開針對每組（使用者，物品）配對輸出一個混合權重  $\alpha \in (0, 1)$ 。開以偏置初始化使  $\alpha^{(0)} \approx 0.993$ ，模型訓練起點實質等同於純 LightGCN，KG 通道僅在梯度將  $\alpha$  推低時逐步開啟。
3. **合理化感知的物品端聚合**。每件物品的 KG 語意儲存於  $A = 4$  個潛在面向槽中，槽位內容由 IDF 加權商品—面向矩陣之截斷 SVD 產生；softmax aspect-saliency 注意力依（使用者，物品）配對選取代表該物品的潛在槽。

每項後果均於下方第 3.5 至 3.9 節中數學化。本章其餘部分先固定符號與問題陳述（第 3.3 至 3.4 節），再依各模組於前向傳遞中之參與順序逐一展開。

## 3.2 架構概覽

圖 1 勾勒了推論時的資料流。模型被布置為對應區域與全域視角的兩條水平泳道，於右側由融合階段匯合。區域視角（上方泳道）對使用者—物品互動圖套用 LightGCN，得到  $(u_{loc}, i_{loc})$ 。全域視角（下方泳道）直接以查表得到使用者的全域嵌入  $u_{glo}$ ，並對物品的  $A = 4$  個潛在面向槽施加 softmax 合理化遮罩以得  $i_{glo}$ ；面向槽本身為 SVD 初始化（圖中以虛線標註）。兩條視角由獨立的使用者側與物品側融合開混合，每個開的偏置初始化為 +5；最終分數為內積  $\langle u_{final}, i_{final} \rangle$ 。為求清晰，跨視角對比學習路徑於圖中省略，詳見第 3.9 節。

兩項結構性質值得在形式化呈現之前先點明。其一， $u_{glo}$  並不經過合理化遮罩模組，而是由直接查表得到，並逕送至使用者側融合開；合理化遮罩僅作用於物品側，符合「合理化回答的是『此物品的哪個面向對此使用者重要』」這一語意。其二，KG-SVD 步驟為初始化而非前向運算：SVD 於訓練前計算一次以設定面向槽參數的初值，其後槽位即如其他參數般以梯度下降更新。

## 3.3 符號

本論文後續使用之符號列於表 5。




Figure 1: RA-GARK 架構。

Table 5: 本章與後續章節所使用之符號。

| 符號                                                     | 意義                                           |
|--------------------------------------------------------|----------------------------------------------|
| $\mathcal{U}, \mathcal{I}$                             | 使用者集合與物品集合                                   |
| $\mathcal{R} \subseteq \mathcal{U} \times \mathcal{I}$ | 已觀察到的使用者—物品互動                                |
| $\mathcal{G}_{\text{KG}}$                              | 物品—面向知識圖譜（評論衍生）                              |
| $\mathcal{A}$                                          | $\mathcal{G}_{\text{KG}}$ 中出現之 unique 面向標籤集合 |
| $A$                                                    | 每件物品的潛在面向槽數（ $A = 4$ ）                       |
| $d$                                                    | 嵌入維度（除另行指定， $d = 128$ ）                      |
| $K$                                                    | LightGCN 傳播層數（ $K = 2$ ）                     |
| $u_{\text{loc}}, i_{\text{loc}} \in \mathbb{R}^d$      | 區域視角（LightGCN）嵌入                             |
| $u_{\text{glo}} \in \mathbb{R}^d$                      | 全域視角使用者嵌入（直接查表）                              |
| $\mathbf{a}_i \in \mathbb{R}^{A \times d}$             | 物品 $i$ 之潛在面向槽（SVD 初始化）                       |
| $i_{\text{glo}} \in \mathbb{R}^d$                      | 全域視角物品嵌入（合理化遮罩後）                             |
| $\alpha_u, \alpha_i \in (0, 1)$                        | 使用者側與物品側融合閘輸出                                |
| $\hat{y}(u, i) \in \mathbb{R}$                         | 對配對 $(u, i)$ 之預測偏好分數                         |

### 3.4 問題定式

**任務。** 本文處理隱式回饋設定下的 top- $K$  推薦。給定  $\mathcal{U}$ 、 $\mathcal{I}$ 、已觀察到的互動  $\mathcal{R}$ ，以及物品—面向 KG  $\mathcal{G}_{\text{KG}}$ ，目標是為每位使用者  $u \in \mathcal{U}$  從  $\mathcal{I} \setminus \{i : (u, i) \in \mathcal{R}\}$  中產生一個排序清單，並以排序指標（NDCG@ $K$ 、Recall@ $K$ 、Hit@ $K$ ）對保留之測試互動集進行評估。

**評分函數。** RA-GARK 對每組  $(u, i)$  配對指派內積分數

$$\hat{y}(u, i) = \langle u_{\text{final}}, i_{\text{final}} \rangle, \quad (3.1)$$

其中  $u_{\text{final}}$  與  $i_{\text{final}}$  由區域與全域表示的閘控融合產生：

$$u_{\text{final}} = \alpha_u u_{\text{loc}} + (1 - \alpha_u) u_{\text{glo}}, \quad i_{\text{final}} = \alpha_i i_{\text{loc}} + (1 - \alpha_i) i_{\text{glo}}. \quad (3.2)$$

閘輸出  $\alpha_u, \alpha_i$  分別由獨立的 MLP 計算（第 3.8 節）。在本論文採用的偏置初始化下， $\alpha_u^{(0)}, \alpha_i^{(0)} \approx 0.993$ ，因此  $\hat{y}^{(0)}(u, i) \approx \langle u_{\text{loc}}, i_{\text{loc}} \rangle$ ，即訓練起點之分數實質為純 LightGCN 之分數，直至閘藉學習而調整。

**訓練目標。** 我們以 Bayesian Personalized Ranking (BPR) [19] 損失為主體，並輔以兩條跨視角對比正則化：

$$\mathcal{L} = \mathcal{L}_{\text{BPR}} + \lambda_{\text{CL}} (\mathcal{L}_{\text{aCL}} + \mathcal{L}_{\text{uCL}}), \quad (3.3)$$

其中對每組已觀察配對  $(u, i^+) \in \mathcal{R}$  與一個取樣的負例物品  $i^- \notin \mathcal{R}_u$ ，

$$\mathcal{L}_{\text{BPR}} = -\log \sigma(\hat{y}(u, i^+) - \hat{y}(u, i^-)), \quad (3.4)$$

而  $\mathcal{L}_{\text{aCL}}, \mathcal{L}_{\text{uCL}}$  分別為  $(i_{\text{loc}}, i_{\text{glo}})$  與  $(u_{\text{loc}}, u_{\text{glo}})$  之間的 InfoNCE 式對齊損失；全域側施加 stop-gradient 以避免對比梯度擾動 SVD 初始化之面向槽（第 3.9 節）。對比權重  $\lambda_{\text{CL}}$  固定為 0.005，使對比的角色為輔助而非主要。

## 3.5 區域視角：LightGCN

區域視角僅由使用者—物品互動圖產生純協同表示  $(u_{\text{loc}}, i_{\text{loc}})$ ；此分支內部完全不施加任何 KG 運算。其架構與 LightGCN [1] 完全相同。

### 3.5.1 動機

選擇 LightGCN 作為區域視角骨幹的理由有三。其一，在本論文所使用之稀疏評論衍生 KG 上，純 LightGCN 已超越我們所評估的全部四個 KG-aware 基線（第 1 章），故為任何後續設計必須可被證實能改善的最強無 KG 起點。其二，其參數化極為精簡（僅有使用者與物品的嵌入表，傳播過程中無任何學習權重）這限制了兩條視角後續耦合時 KG 雜訊得以滲入協同梯度流的接觸面。其三，傳播為純線性，故每層對最終表示的貢獻可由閉式之層平均直接讀出，從而能在不受非線性干擾的前提下，理性化關於閘的放置（第 3.8 節）與對比對齊（第 3.9 節）的設計決策。

### 3.5.2 圖的建構

令  $\mathbf{R} \in \{0, 1\}^{|\mathcal{U}| \times |\mathcal{I}|}$  為由  $\mathcal{R}$  衍生的使用者—物品互動矩陣，其中  $\mathbf{R}_{u,i} = 1$  當且僅當  $(u, i) \in \mathcal{R}$ 。據此建構二部圖鄰接矩陣

$$\mathbf{A} = \begin{bmatrix} \mathbf{0} & \mathbf{R} \\ \mathbf{R}^\top & \mathbf{0} \end{bmatrix} \in \mathbb{R}^{(|\mathcal{U}|+|\mathcal{I}|) \times (|\mathcal{U}|+|\mathcal{I}|)}, \quad (3.5)$$

並施加對稱歸一化

$$\tilde{\mathbf{A}} = \mathbf{D}^{-1/2} \mathbf{A} \mathbf{D}^{-1/2}, \quad \mathbf{D} = \text{diag}(\mathbf{A} \mathbf{1}). \quad (3.6)$$

此歸一化降低了與高度使用者或熱門物品相鄰之邊的權重，於實務上有助於穩定長尾互動分布下的訓練。

### 3.5.3 傳播

令  $\mathbf{E}^{(0)} \in \mathbb{R}^{(|\mathcal{U}|+|\mathcal{I}|) \times d}$  為初始嵌入表，前  $|\mathcal{U}|$  列為使用者嵌入，其餘  $|\mathcal{I}|$  列為物品嵌入；兩區塊皆以 Xavier-normal 初始化。第  $\ell$  層由單次歸一化鄰居聚合得到：

$$\mathbf{E}^{(\ell+1)} = \tilde{\mathbf{A}} \mathbf{E}^{(\ell)}, \quad \ell = 0, 1, \dots, K-1. \quad (3.7)$$

過程中無任何可學習權重矩陣、無非線性、無自迴圈偏置，整個區域視角所有可學習參數即為  $\mathbf{E}^{(0)}$  的  $|\mathcal{U}|d + |\mathcal{I}|d$  個元素。

### 3.5.4 層平均與輸出

採用 LightGCN 標準的層平均

$$\bar{\mathbf{E}} = \frac{1}{K+1} \sum_{\ell=0}^K \mathbf{E}^{(\ell)}, \quad (3.8)$$

並由  $\bar{\mathbf{E}}$  對應列讀出  $u_{\text{loc}}$  與  $i_{\text{loc}}$ 。本論文使用  $K = 2$ ，與原始 LightGCN 論文一致，亦為我們純區域驗證損失趨於平台的深度。

如此得到的嵌入對僅由使用者—物品互動圖提供資訊；區域視角僅透過第 3.8 節之融合階段參與最終分數  $\hat{y}(u, i)$ ，訓練過程中不容許任何 KG 訊號改變  $u_{\text{loc}}$  或  $i_{\text{loc}}$ 。




Figure 2: KG-SVD 初始化流程。

### 3.6 全域視角：KG-SVD 初始化

全域視角引入一獨立的使用者側嵌入  $u_{\text{glo}}$ （直接查表，見下文）與一物品側參數張量以儲存各物品之 KG 語意。此物品側張量為 RA-GARK 中唯一容許 KG 內容進入模型之處。本節說明該張量之參數化方式及其值如何初始化。圖 2 提供四階段初始化流程之視覺概觀，其餘內容則將每階段形式化。

#### 3.6.1 面向槽作為物品側 KG 表示

每件物品  $i$  在全域視角中由面向槽張量

$$\mathbf{a}_i \in \mathbb{R}^{A \times d}, \quad A = 4 \quad (3.9)$$

表示，將所有物品的張量集合為一可學習參數  $\mathbf{A}_{\text{KG}} \in \mathbb{R}^{|I| \times A \times d}$ 。初始化（下節說明）之後， $\mathbf{A}_{\text{KG}}$  即如其他參數般以梯度下降更新。

此處有一關鍵釐清：槽位數  $A = 4$  為模型超參數，不對應於每件物品的固定原始面向標籤數。在本論文使用的評論衍生 KG 中，每件物品平均僅持有 2.4 條面向邊，全域面向標籤詞彙遠大於  $A$  ( $|\mathcal{A}| \gg A$ )。此四個槽位為面向誘導語意子空間中的潛在方向，跨全體物品共同學習，而非綁定於特定標籤。

### 3.6.2 共現矩陣

從二值物品—面向共現矩陣  $\mathbf{M} \in \{0, 1\}^{|I| \times |A|}$  出發：

$$\mathbf{M}_{i,a} = \begin{cases} 1, & (i, a) \in \mathcal{G}_{\text{KG}}, \\ 0, & \text{否則} \end{cases} \quad (3.10)$$

$\mathbf{M}$  的每一列因此是一個稀疏指示向量：每件物品至多只有少數幾個非零項；經剪枝後（第 4.1 節）全域密度對應於每列平均 2.4 個 1。

### 3.6.3 IDF 加權

部分面向標籤橫跨許多物品（如「文筆優美」、「引人入勝」），其他則高度特定（如某個利基類型或主題）。若不修正，後續 SVD 將由高頻標籤主導，所產生的潛在方向實質上只是熱門度先驗。我們以標準的逆文件頻率（IDF）重新加權緩解此問題：

$$\text{idf}(a) = \log \left( \frac{|I|}{|\{i : \mathbf{M}_{i,a} = 1\}| + 1} \right) + 1, \quad (3.11)$$

並依 IDF 重新縮放  $\mathbf{M}$  各行：

$$\tilde{\mathbf{M}}_{i,a} = \text{idf}(a) \cdot \mathbf{M}_{i,a}. \quad (3.12)$$

分母中之 +1 避免對所有物品支持已被剪除之面向除以零；對數外之 +1 防止最大頻率面向的 IDF 退化為零。兩項調整皆為標準作法。

### 3.6.4 截斷 SVD

對  $\tilde{\mathbf{M}}$  計算秩  $k$  之截斷 SVD：

$$\tilde{\mathbf{M}} \approx \mathbf{U}_k \mathbf{\Sigma}_k \mathbf{V}_k^\top, \quad \mathbf{U}_k \in \mathbb{R}^{|I| \times k}, \quad (3.13)$$

其中  $k = A \cdot d$ 。左奇異矩陣  $\mathbf{U}_k$  每件物品一列；各列位於一  $k$  維潛在子空間，於其中 IDF 加權的面向共現於秩  $k$  下被最佳解釋。

接著形成每件物品的潛在嵌入，將每個分量以對應奇異值之平方根縮放：

$$\mathbf{E}_{\text{KG}} = \mathbf{U}_k \mathbf{\Sigma}_k^{1/2} \in \mathbb{R}^{|I| \times k}. \quad (3.14)$$

此平方根縮放使譜能量均勻分布於左右因子，為標準選擇，所得嵌入之兩兩內積近似 IDF 加權共現內容。

### 3.6.5 重塑為槽位與量值縮放

寬度為  $k = Ad$  的展平嵌入  $\mathbf{E}_{\text{KG}}$  被重塑為每件物品  $A$  個寬度  $d$  的槽：

$$\mathbf{A}_{\text{KG}}^{(0)}[i, k, :] = \mathbf{E}_{\text{KG}}[i, kd : (k+1)d], \quad k = 0, \dots, A-1. \quad (3.15)$$

槽因此是 SVD 輸出中互不相交的連續區塊；它們不對應於可獨立解讀的面向標籤。

由於  $\mathbf{E}_{\text{KG}}$  之量值依賴於  $|\mathcal{I}|$ 、 $|\mathcal{A}|$  與  $\tilde{\mathbf{M}}$  的譜，未經縮放的 SVD 輸出與模型他處 Xavier 初始化參數不在同一量級。我們因此將整個  $\mathbf{A}_{\text{KG}}^{(0)}$  重新縮放，使其經驗標準差匹配 Xavier-normal 目標  $\sigma = \sqrt{2/(A+d)}$ 。此縮放保留 SVD 輸出的角度幾何（也正是我們想注入的）同時使槽位量值與其餘最佳化過程相容。

### 3.6.6 演算法

完整初始化可總結為五步：

1. 由  $\mathcal{G}_{\text{KG}}$  建構二值共現矩陣  $\mathbf{M}$ （式 (3.10)）。
2. 套用 IDF 列加權得  $\tilde{\mathbf{M}}$ （式 (3.12)）。
3. 計算秩  $k = Ad$  之截斷 SVD： $\tilde{\mathbf{M}} \approx \mathbf{U}_k \Sigma_k \mathbf{V}_k^\top$ （式 (3.13)）。
4. 形成  $\mathbf{E}_{\text{KG}} = \mathbf{U}_k \Sigma_k^{1/2}$  並重塑為  $\mathbf{A}_{\text{KG}}^{(0)} \in \mathbb{R}^{|\mathcal{I}| \times A \times d}$ （式 (3.15)）。
5. 整體重新縮放使標準差匹配 Xavier-normal 目標。

若  $|\mathcal{A}| < Ad$ ，SVD 秩被限制為  $|\mathcal{A}| - 1$ ，剩餘槽維度於縮放前以小量高斯雜訊（標準差 0.01）填補；在我們的實驗中  $|\mathcal{A}| \gg Ad$ ，故此降階路徑不被觸發。

### 3.6.7 此初始化所帶來的效益

KG-SVD 初始化的貢獻於第 4.4 節以消融衡量：將其替換為相同張量形狀之 Xavier-normal 隨機初始化會損失 5.3% NDCG@20。其解釋是：SVD 初始化在訓練起點即保留了面向誘導語意子空間的角度幾何；其後梯度下降可微調此幾何，但在我們的稀疏 KG 條件下，難以由隨機初始化恢復，能恢復此幾何的梯度訊號需流經對比損失（ $\lambda_{\text{CL}} = 0.005$ ），訊號微弱。

### 3.7 全域視角：Softmax 合理化遮罩

給定物品的面向槽張量  $\mathbf{a}_i \in \mathbb{R}^{A \times d}$  與使用者側全域嵌入  $u_{\text{glo}} \in \mathbb{R}^d$ ，合理化遮罩模組選取  $A$  個潛在槽中最能在該使用者下代表該物品者，得到全域視角物品嵌入  $i_{\text{glo}}$ 。使用者側全域嵌入本身為直接查表

$$u_{\text{glo}} = \mathbf{E}_u^{\text{glo}}, \quad \mathbf{E}^{\text{glo}} \in \mathbb{R}^{|\mathcal{U}| \times d}, \quad (3.16)$$

其中  $\mathbf{E}^{\text{glo}}$  為與區域視角使用者表分離的可學習參數；使用者側不施加任何合理化運算。

#### 3.7.1 動機

每件物品的 KG 語意分散儲存於  $\mathbf{a}_i$  的  $A$  個潛在槽中；不同槽位編碼 SVD 可見之不同語意面向。合理化模組的職責即在（使用者, 物品）配對之條件下，於全域視角中挑出最能代表該物品之槽。式 (3.17) 將槽 logit 同時條件於  $u_{\text{glo}}$  與槽嵌入，因此選擇於結構上為 per-(使用者, 物品)；至於訓練完成之模型是否實際運用使用者維度、抑或退化為物品條件之路由，則為實證問題，於第 4.7 節個案研究中檢視。

#### 3.7.2 使用者條件之注意力 logits

對每個槽  $k \in \{1, \dots, A\}$ ，計算一純量 logit

$$\ell_{u,i,k} = \text{MLP}([u_{\text{glo}} \parallel \mathbf{a}_{i,k}]) \in \mathbb{R}, \quad (3.17)$$

其中  $\parallel$  表沿嵌入維度串接，MLP 參數於所有槽與物品間共享。MLP 為兩層前饋區塊：

$$\text{MLP}(\mathbf{z}) = \mathbf{w}^\top \cdot \text{LeakyReLU}(\mathbf{W} \mathbf{z}), \quad (3.18)$$

其中  $\mathbf{W} \in \mathbb{R}^{d \times 2d}$ 、 $\mathbf{w} \in \mathbb{R}^d$ 。跨槽共享參數至關重要：它迫使 MLP 學到一個與槽無關的「此槽與此使用者契合程度」概念，而非為每個槽記憶各自的評分函數。

### 3.7.3 Softmax 歸一化

$A$  個 logit 透過溫度  $\tau$  之 softmax 歸一化為槽位之機率分布：

$$w_{u,i,k} = \frac{\exp(\ell_{u,i,k}/\tau)}{\sum_{k'=1}^A \exp(\ell_{u,i,k'}/\tau)}. \quad (3.19)$$

依建構  $\sum_k w_{u,i,k} = 1$ ， $A$  個槽位權重彼此競爭：增加某槽相對權重必使其餘槽位下降。我們使用  $\tau = 0.5$ ，相對於無資訊先驗（ $\tau = 1$  在  $\logit = 0$  時得完全均勻）銳化分布，將質量集中於對使用者最相關之槽。溫度掃描見第 4.5.1 節。

### 3.7.4 加權聚合

全域視角物品嵌入為槽加權平均

$$i_{\text{glo}} = \sum_{k=1}^A w_{u,i,k} \cdot \mathbf{a}_{i,k} \in \mathbb{R}^d. \quad (3.20)$$

實作上即為「合理化遮罩」步驟：softmax 權重作為槽維度上的軟遮罩，被遮罩之槽位再加總回單一  $d$  維向量。雖然式 (3.19) 與 (3.20) 概念上為兩步，但在程式中於單一模組（KGRationaleMasking）內以一次前向呼叫完成。

### 3.7.5 為何使用 Softmax 而非 Sigmoid

一個自然的替代是對每個槽獨立以 sigmoid 評分： $w_{u,i,k} = \sigma(\ell_{u,i,k})$ ，不施加跨槽歸一化。兩種運算於下游融合閘所關注之一項結構性質上不同：Softmax 產生之權重總和為 1，所得  $i_{\text{glo}}$  之模長無論 logit 尺度為何皆有界於  $\max_k \|\mathbf{a}_{i,k}\|$ ；sigmoid 之輸出總和不受限，所得  $i_{\text{glo}}$  之模長隨 logit 動態範圍縮放。

實證上 sigmoid 變體會使本基準 NDCG@20 下降 7.0%（第 4.4 節），是我們所觀察到單一元件影響最大者。第 4.7 節之個案研究暗示其因：合理化模組運作於刻意被節制之 KG 通道內，最終產生之是軟尖峰權重（ $\max_k w_k \approx 0.28$ 、其餘約 0.24），而非單由 Softmax 名稱所推測之近 one-hot 向量。於 Softmax 下此即意謂  $i_{\text{glo}}$  之模長維持有界且可預測，融合閘之校準（第 3.8.3 節）因而能穩定將 KG 貢獻維持於分數中所欲之小比例；於 sigmoid 下逐槽模長則隨 logit 漂移，恰好破壞了閘所依賴之「有界貢獻」性質。Softmax 之承載性角色因此為「為被節制之輔助通道提供模長受控之歸一化」，而非強制諸槽間之 one-hot 競爭。我們在第 5 章對此發現作更謹慎之討論，並明確將其定位為

單一資料集觀察，需多資料集複製驗證。

### 3.8 區域偏置融合閘

融合閘是將 RA-GARK 設計原則（KG 為可被閘控之旁路通道）落實為具體運算的架構機制。它將區域與全域表示結合為最終嵌入，並由其產生分數。圖 3 以使用者側為例呈現訊號流；圖中被標註的  $b = +5$  框預告了第 3.8.3 節將展開的偏置初始化設計，物品側結構完全相同。




Figure 3: 區域偏置融合閘（物品側同理）。

#### 3.8.1 雙側獨立閘

RA-GARK 使用兩個獨立融合閘，使用者側與物品側各一。兩者皆為純量閘，以該側區域與全域嵌入之串接為條件：

$$\alpha_u = \text{Gate}_u([u_{\text{loc}} \parallel u_{\text{glo}}]) \in (0, 1), \quad (3.21)$$

$$\alpha_i = \text{Gate}_i([i_{\text{loc}} \parallel i_{\text{glo}}]) \in (0, 1). \quad (3.22)$$

兩閘參數獨立；經驗上共享參數會劣化結果，因為在稀疏 KG 下 KG 訊號對使用者側與物品側嵌入的邊際資訊量不同。

最終各側嵌入為凸組合

$$u_{\text{final}} = \alpha_u u_{\text{loc}} + (1 - \alpha_u) u_{\text{glo}}, \quad i_{\text{final}} = \alpha_i i_{\text{loc}} + (1 - \alpha_i) i_{\text{glo}}, \quad (3.23)$$

最終分數為內積  $\hat{y}(u, i) = \langle u_{\text{final}}, i_{\text{final}} \rangle$ ，如式 (3.1) 已述。

#### 3.8.2 閘的結構

每個 Gate 為一帶 sigmoid 頭之小型 MLP：

$$\text{Gate}(\mathbf{z}) = \sigma(\mathbf{w}^\top \tanh(\mathbf{W}\mathbf{z}) + b), \quad (3.24)$$

其中  $\mathbf{W} \in \mathbb{R}^{d \times 2d}$ 、 $\mathbf{w} \in \mathbb{R}^d$ 、 $b$  為純量偏置、 $\sigma$  為邏輯函數。隱藏層寬度與嵌入維度一致。第一層權重  $\mathbf{W}$  以 Xavier-uniform 初始化、偏置為零；第二層權重  $\mathbf{w}$  同樣以 Xavier-uniform 初始化；第二層偏置  $b$  即下節要特別初始化者。

### 3.8.3 區域偏置初始化

關鍵設計選擇為式 (3.24) 中純量偏置  $b$  的初始化。當  $b = 0$ ，訓練起點之閘輸出約為  $\sigma(0) = 0.5$ ，即區域與全域 50/50 混合。由於全域視角部分由帶雜訊之 KG 初始化，50/50 起點將使區域表示整個訓練過程中皆暴露於 KG 雜訊；而第 1 章已觀察到此正是深度融合基線的失效模式。

我們改將兩個閘的偏置皆初始化為  $b = +5$ 。訓練起點之閘輸出因此為

$$\alpha^{(0)} \approx \sigma(b) = \sigma(5) \approx 0.993, \quad (3.25)$$

初始混合約為

$$u_{\text{final}}^{(0)} \approx 0.993 u_{\text{loc}}^{(0)} + 0.007 u_{\text{glo}}^{(0)}, \quad (3.26)$$

物品側類似。換言之，RA-GARK 訓練起點實質為純 LightGCN。KG 通道起初僅開啟 0.7%；唯當 BPR 損失對  $b$  之梯度將  $b$  向下推動時（亦即拓寬 KG 通道能降低損失時）通道才會被擴大。偏置作為一個學習得到的、傾向安全預設之先驗。

### 3.8.4 優雅退化

區域偏置初始化提供結構性保證：若 KG 結果為完全無資訊，閘將維持於  $\alpha \approx 1$  附近，KG 項對分數的貢獻被上界約為  $0.007 \cdot \|\mathbf{a}\| \cdot \|\mathbf{u}\|$ ，模型於經驗上與純 LightGCN 無從區分。第 1 章所列之四個基線皆無此性質：每個都強制 KG 實體嵌入無論其是否具資訊量皆參與傳播路徑。

此即 Highway Networks [10] 嚴格架構意義下的優雅退化性質，自網路內部跳接移植至視角間融合。據我們所知，尚無 KG-aware 推薦器採此設計。

### 3.8.5 為何選 $+5$ 而非 $+\infty$

偏置量值之選擇依單一原則：大到使初始閘輸出絕對偏向區域、小到使  $b$  之梯度非零而能於訓練中調整閘。於  $b = +5$ ， $\sigma'(5) = \sigma(5)(1 - \sigma(5)) \approx 0.007$ ，雖小但未消失。 $b = +10$  之後  $b$  上之梯度於數值上可忽略，閘無法學會開啟。 $b = +5$  為使  $\alpha^{(0)} > 0.99$  同

時保持  $\sigma'(b) > 10^{-3}$  之最小整數，並通過敏感性掃描不需進一步調整（第 4.5.3 節）。完全移除偏置初始化（設  $b = 0$ ）會損失 5.3% NDCG@20（第 4.4 節）。

## 3.9 跨視角對比正則化

區域與全域視角於結構上異質：一者為來自互動的協同表示，另一者為 KG 衍生表示，二者位於不同歸納子空間。若無任何明確對齊，兩表示在訓練過程中可能漂移至  $\mathbb{R}^d$  中彼此不相容之區域，此時融合閘所合併的向量並非直接可比。跨視角對比正則化即在處理此幾何錯位。

### 3.9.1 在架構中的角色

於 RA-GARK 中，對比損失扮演刻意受限之角色。它們並非主要整合機制，此角色由融合閘擔任（第 3.8 節），而是將兩視角推向共享角度幾何的正則化項。具體而言，我們刻意不使用對比學習讓 KG 通道「掙得」其進入模型之資格，如 KGCL [5] 與 MCCLK [6] 所為；那將重新引入「將 KG 訊號視為必經主融合路徑」的失效模式。

### 3.9.2 面向層級對比損失

對訓練批次中每件物品  $i$ ，將其投影後的區域嵌入與其  $A$  個面向槽分別對比：

$$\mathcal{L}_{\text{aCL}} = \frac{1}{A} \sum_{k=1}^A \text{InfoNCE}(g(i_{\text{loc}}), \text{sg}[\mathbf{a}_{i,k}]), \quad (3.27)$$

其中  $g: \mathbb{R}^d \rightarrow \mathbb{R}^d$  為可學習投影頭（兩層 MLP 加 ReLU），僅施加於區域側輸入； $\text{sg}[\cdot]$  表示 stop-gradient；InfoNCE 為標準對比目標

$$\text{InfoNCE}(\mathbf{x}, \mathbf{y}) = -\log \frac{\exp(\langle \mathbf{x}, \mathbf{y} \rangle / \tau_{\text{CL}})}{\sum_{j=1}^B \exp(\langle \mathbf{x}, \mathbf{y}_j \rangle / \tau_{\text{CL}})}, \quad (3.28)$$

$\tau_{\text{CL}} = 0.2$ 、 $B$  為批次大小（負例為批次內其餘物品）。向量於內積之前皆作  $\ell_2$  歸一化。

### 3.9.3 使用者層級對比損失

對稱之使用者層級損失對齊區域與全域使用者嵌入：

$$\mathcal{L}_{\text{uCL}} = \text{InfoNCE}(g(u_{\text{loc}}), \text{sg}[u_{\text{glo}}]). \quad (3.29)$$

投影頭  $g$  與  $\mathcal{L}_{aCL}$  共享，因兩損失皆作用於區域側輸入，且我們希望投影編碼單一之「區域視角如何映射至全域視角角度幾何」變換。

### 3.9.4 全域側 Stop-Gradient

式 (3.27) 與 (3.29) 中 KG 側之 stop-gradient 在結構上至關重要。若無，對比梯度會反向傳遞至 SVD 初始化的面向槽與全域使用者表，逐漸破壞 KG-SVD 初始化所安裝之角度幾何（第 3.6 節）。配合 stop-gradient 後，對比損失作用不對稱：能將區域視角拉向全域視角已有之幾何，但無法把全域視角向任何方向推動。KG 衍生語意子空間被保留為外部參照，由區域視角承擔對齊代價。

### 3.9.5 損失權重

式 (3.3) 中對比權重  $\lambda_{CL}$  固定為 0.005。此值小到使對比損失於總梯度中貢獻一非主導比例（BPR 仍為主要訊號），亦與第 3.9.1 節所賦予對比正則化之角色一致：幾何先驗，非主要學習目標。我們不對  $\lambda_{CL}$  作資料集相關調參。

## 3.10 訓練與計算複雜度

### 3.10.1 總目標

完整訓練損失已於式 (3.3) 給出，此處為完整性重述：

$$\mathcal{L} = \mathcal{L}_{BPR} + \lambda_{CL}(\mathcal{L}_{aCL} + \mathcal{L}_{uCL}). \quad (3.30)$$

BPR 損失提供主要排序訊號；對比項提供跨視角幾何對齊。

### 3.10.2 最佳化

以 Adam（預設  $\beta_1 = 0.9, \beta_2 = 0.999, \epsilon = 10^{-8}$ ）最佳化式 (3.30)，學習率  $10^{-3}$ 、批次大小 128，最多訓練 30 epochs。以驗證集 NDCG@20 之耐心 10 早停。每批次包含 128 組三元組  $(u, i^+, i^-)$ ，其中  $i^-$  自  $\mathcal{R}_u$  之外的物品均勻取樣。式 (3.7)–(3.8) 之 LightGCN 傳播於每批次重新計算一次，並於該批次內正負例評分時共用。

### 3.10.3 推論

推論時，於評估開始時計算 LightGCN 傳播一次並快取  $\bar{\mathbf{E}}$ 。對每個查詢使用者  $u$ ，以單次批次矩陣乘法計算全部物品集合之分數：面向槽、合理化權重、 $i_{\text{glo}}$ 、物品閘以及與  $u_{\text{final}}$  之內積，皆於整個物品集合上以向量化形式同時評估。

### 3.10.4 計算複雜度

令  $B$  為批次大小、 $|\mathcal{E}_{\mathcal{UI}}|$  為已觀察使用者—物品互動數、 $|\mathcal{I}|$  為物品數、 $A$  為槽位數、 $d$  為嵌入維度、 $K$  為 LightGCN 層數。每批次訓練成本分解如下：

Table 6: 各模組每批次訓練成本。

| 模組                  | 成本                                    |
|---------------------|---------------------------------------|
| LightGCN 傳播         | $O( \mathcal{E}_{\mathcal{UI}}  d K)$ |
| $u_{\text{glo}}$ 查表 | $O(B d)$                              |
| 面向槽讀取               | $O(B A d)$                            |
| 合理化遮罩               | $O(B A d)$                            |
| 使用者與物品融合閘           | $O(B d^2)$                            |
| BPR 與對比損失           | $O(B d)$                              |

LightGCN 傳播項主導訓練成本，與純 LightGCN 基線完全一致。KG 側之新增（面向讀取、合理化遮罩、融合閘）貢獻為  $A$  與  $d$  之線性項，皆相對於傳播為小。RA-GARK 之每 epoch 牆鐘時間因此於純 LightGCN 之小常數倍以內，並於同一硬體與相同嵌入維度下與 KGRec 大致相等（精確牆鐘數字見第 4.8 節）。

全集合推論由使用者條件之物品側合理化遮罩步驟  $O(B \cdot |\mathcal{I}| \cdot A \cdot d)$  主導，於本論文使用之資料集規模下可行。

# Chapter 4

## 實驗

本章在第 1 章所動機之稀疏評論衍生 KG 上評估 RA-GARK。第 4.1 節描述資料集與 KG 建構流程（沿用既有工作，非本文貢獻）。第 4.2 節固定評估協議與 baseline 重現設定。第 4.3 與 4.4 節報告主結果與逐元件消融。第 4.5 至 4.6 節探討讀者最可能質疑的兩個面向：超參數敏感性與種子穩定性。第 4.7 節以個別（使用者, 物品）配對展示合理化模組的可解釋性，第 4.8 節報告計算成本。

### 4.1 資料集與 KG 建構

#### 4.1.1 資料集

我們的實驗使用 Amazon Books 評論語料的一個子集，處理為使用者—物品互動圖與物品—面向知識圖譜。表 7 摘要過濾後之統計。移除低互動使用者與物品、剪裁罕見面向標籤後（見下文），工作資料集包含 905 位使用者、1,399 件物品、22,265 筆正向互動，以及散佈於 2,098 個獨立面向標籤上的 3,370 條 KG 邊。每件物品平均攜帶 2.4 條面向邊，在此稀疏程度下，我們所測之四個 KG-aware baseline 均敗給純 LightGCN（第 1 章）。

互動以使用者分層方式切為 70/15/15 之 train/validation/test，確保每位至少觀察到三件物品的使用者皆出現於三個切分。產生切分之隨機種子固定為 42，且於所有 baseline 重現中共用，以排除切分變異作為混淆因子。

Table 7: 前處理後之資料集統計。

| 統計          | 數值     |
|-------------|--------|
| # 使用者       | 905    |
| # 物品        | 1,399  |
| # 互動        | 22,265 |
| #KG 邊 (過濾後) | 3,370  |
| # 獨立面向      | 2,098  |
| 每物品平均邊數     | 2.4    |
| 互動密度        | 1.76%  |

### 4.1.2 知識圖譜建構

本文所用之物品一面向 KG 由 [20] 之流程自原始商品評論建構，我們不加修改地直接使用。由於建構本身非本文貢獻，僅作扼要描述：對每本書，物品側視覺特徵以 ResNet 與 Qwen-VL 自封面影像萃取，再由 BART 與 Mistral 自評論池生成統一文字摘要；隨後自摘要抽出面向出現，形成  $(item, has\_aspect, aspect)$  三元組。原始抽取共得 13,905 條候選邊。

兩道過濾將其縮減為工作 KG。其一，移除頻率前 2% 之面向標籤（這些經驗上歸結為「well-written」「engaging」等通用讚詞）理由是此類標籤幾乎不攜帶物品鑑別資訊，且會主導其後之 SVD 譜（第 3.6 節）。其二，以一份小型手工策劃之停用詞清單移除領域特定通用詞（如「character\_development」「highly\_recommended」）。兩道一同丟棄 75.7% 之原始邊，留下分布於 2,098 個獨立標籤之 3,370 條具體面向附著。

此過濾後之 KG 為所有 KG-aware 方法（含 RA-GARK）於本評估中之唯一外部訊號。過濾在各方法間以相同方式套用，使比較反映模型差異而非 KG 清潔度差異。

## 4.2 實驗設定

### 4.2.1 Baseline

我們將 RA-GARK 與五個 baseline 比較：純 LightGCN [1] 作為非 KG 對照，以及四個代表性 KG-aware 推薦器，KGAT [4]、KGCL [5]、MCCLK [6]、KGRec [7]。此四個 KG-aware baseline 涵蓋第 2 章所綜述之主要整合範式：深度聚合器融合（KGAT）、跨視角對比學習（KGCL、MCCLK）、邊層級合理化學習（KGRec）。

所有 baseline 皆由作者公開程式碼於相同處理後之 KG（第 4.1.2 節）與相同使用者分層切分上重現。我們保留各 baseline 已發表之超參數預設，而非逐一重新調參，原因

在於針對四種不同超參數空間重新調參會引入比較偽影；推定原作者最瞭解自己模型之最佳配置。唯一介入為固定嵌入維度  $d = 128$ （與 RA-GARK 一致），並對齊最佳化預算（epoch、early stopping patience）。此選擇刻意保守：可能低估 baseline 於本資料集所能達之上限，但確保比較不為調參投入不均所污染。

#### 4.2.2 評估協議

我們採用全項目排序協議：對每位測試使用者，於  $\mathcal{I}$  中排除其訓練集已觀察項後對其餘所有物品評分，將排序後之候選清單與留存測試正樣本比對計算 top- $K$  指標。此為嚴格協議；採樣式評估（如對 100 隨機負樣本排序）等變體未使用，因其於隱式回饋設定下已被證實會誇大模型差異。

我們以 NDCG@20 為主要指標，Recall@20、HR@20、MAP@20 為次要指標。Early stopping 以 validation NDCG@20 為依據（patience 10），測試指標於最佳 validation NDCG@20 之 epoch 讀取。本章所報數字皆為此協議下之測試指標。

#### 4.2.3 超參數設定

RA-GARK 之超參數總結於表 8。各值未經聯合調參：最佳化設定與嵌入維度沿用 LightGCN 預設；合理化溫度  $\tau = 0.5$  與融合閘偏置  $b = +5$  為第 3.7.3 與 3.8.3 節所論證之設計選擇；面向槽數  $A = 4$  由第 3.6.1 節之設計理據固定；對比權重  $\lambda_{\text{CL}} = 0.005$  為第 3.9.5 節所論證之小量輔助值。

Table 8: 所有實驗報告所用之 RA-GARK 超參數設定。

| 超參數                           | 值                                     |
|-------------------------------|---------------------------------------|
| 嵌入維度 $d$                      | 128                                   |
| LightGCN 層數 $K$               | 2                                     |
| 面向槽數 $A$                      | 4                                     |
| 合理化溫度 $\tau$                  | 0.5                                   |
| 融合閘偏置 $b$ （初始化）               | +5                                    |
| 對比權重 $\lambda_{\text{CL}}$    | 0.005                                 |
| InfoNCE 溫度 $\tau_{\text{CL}}$ | 0.2                                   |
| 最佳化器                          | Adam ( $\beta_1=0.9, \beta_2=0.999$ ) |
| 學習率                           | $10^{-3}$                             |
| Batch size                    | 128                                   |
| 最大 epoch                      | 30                                    |
| Early-stopping patience       | 10                                    |
| 隨機種子                          | 42                                    |

#### 4.2.4 硬體與軟體

所有實驗於單張 NVIDIA RTX 級 GPU (24 GB 記憶體) 上執行。模型以 PyTorch 2.x 實作，以單精度訓練。每 epoch 牆鐘時間於第 4.8 節報告。

### 4.3 主要結果

表 9 報告主要測試集結果。RA-GARK 取得  $\text{NDCG@20} = 0.1238$ ，較最強 KG-aware baseline (KGRec) 提升 +13.1%，較純 LightGCN 提升 +5.0%。提升於各次要排序指標 (HR@20、Recall@20、MAP@20) 皆一致；最大相對增益為 MAP@20 之 +18.2%，顯示正確檢索物品之排序品質亦優於 baseline。

Table 9: 主要測試結果 (全項目排序， $K = 20$ ，種子 = 42)。

| 模型                   | NDCG@20       | HR@20         | Recall@20     | MAP@20        |
|----------------------|---------------|---------------|---------------|---------------|
| MCCLK [6]            | 0.1067        | 0.4530        | 0.1720        | 0.0497        |
| KGCL [5]             | 0.1073        | 0.4696        | 0.1827        | 0.0479        |
| KGAT [4]             | 0.1079        | 0.4773        | 0.1807        | 0.0491        |
| KGRec [7]            | 0.1095        | 0.4729        | 0.1834        | 0.0500        |
| LightGCN [1] (無 KG)  | 0.1179        | 0.4884        | 0.1965        | 0.0573        |
| <b>RA-GARK (本文)</b>  | <b>0.1238</b> | <b>0.4961</b> | <b>0.2014</b> | <b>0.0591</b> |
| $\Delta$ vs KGRec    | +13.1%        | +4.9%         | +9.8%         | +18.2%        |
| $\Delta$ vs LightGCN | +5.0%         | +1.6%         | +2.5%         | +3.1%         |

此表有兩種讀法值得分開敘述。其一 (較 KGRec +13.1%) 顯示於相同 KG 下，RA-GARK 之設計選擇於同筆資料上產生比最強既發表 KG-aware 方法顯著更佳之推薦器。其二 (較純 LightGCN +5.0%) 方法論上更具意義。在同一稀疏 KG 情境中，四個 KG-aware baseline 皆低於無 KG 對照；RA-GARK 是此處所評之五個 KG-aware 配置中，唯一將 KG 訊號自淨負債轉為淨資產者。促成此翻轉之架構機制 (將 KG 通道置於偏置初始化之融合閘後，僅於其貢獻降低損失時啟用) 將於下一節詳細審視。

### 4.4 消融研究

我們對三項核心設計選擇，KG-SVD 初始化 (第 3.6 節)、Softmax 合理化遮罩 (第 3.7 節)、區域偏置融合閘 (第 3.8 節)，逐一還原並於其他設定固定下從頭重新訓練以衡量其貢獻。另外加入三組診斷列：完全移除全域視角 (純 CL 雙視角)、以單

一可學習純量  $\alpha$  取代 per-(使用者, 物品) 閘、以及分別丟棄兩條對比通道。純 LightGCN 以無 KG 底線重現。所有列皆使用種子 = 42。

Table 10: 消融：每列翻轉 RA-GARK 之一個元件並重新訓練。 $\Delta$  為相對於完整模型之 NDCG@20 變化。

| 配置                                | NDCG@20       | $\Delta$  | 所移除者                    |
|-----------------------------------|---------------|-----------|-------------------------|
| <b>RA-GARK (完整)</b>               | <b>0.1238</b> | <b>0%</b> | <b>無</b>                |
| – Softmax $\rightarrow$ sigmoid 頭 | 0.1152        | –7.0%     | 跨槽競爭 (§3.7.5)           |
| – KG-SVD 初始化 $\rightarrow$ Xavier | 0.1173        | –5.3%     | 初始角度幾何 (§3.6)           |
| – 融合閘偏置 $b=5 \rightarrow 0$       | 0.1173        | –5.3%     | 區域偏置安全預設 (§3.8.3)       |
| – MLP 閘 $\rightarrow$ 純量 $\alpha$ | 0.1178        | –4.8%     | per-(u,i) 閘條件化 (§3.8.1) |
| – 使用者 CL ( $\mathcal{L}_{uCL}$ )  | 0.1187        | –4.1%     | 使用者側跨視角對齊               |
| – 面向 CL ( $\mathcal{L}_{aCL}$ )   | 0.1207        | –2.5%     | 物品側面向級對齊                |
| – 全域視角 (純 CL 雙視角)                 | 0.1214        | –1.9%     | 計分時整段 KG 流程             |
| – 啟用合理化 $\rightarrow$ 均勻平均        | 0.1222        | –1.3%     | 使用者條件之面向選擇              |
| 僅 LightGCN (無 KG 底線)              | 0.1179        | ref.      | 無全域視角；僅 CF              |
| 修復前配置 (sigmoid + $b=0$ )          | 0.1067        | –13.8%    | 兩項預設皆還原為損壞值             |

表 10 支持三項觀察。

**三項核心設計皆獨立承重。** 移除 Softmax 合理化 (–7.0%)、KG-SVD 初始化 (–5.3%)、或區域偏置融合 (–5.3%) 任一項，皆使 RA-GARK 降至純 LightGCN 底線 0.1179 以下。對 per-(u,i) MLP 閘亦然 (–4.8%，對應 0.1178)。換言之，此四項設計選擇皆非裝飾性：缺其一者，RA-GARK 於本資料集上即非正貢獻之 KG-aware 方法。

**Softmax 與 sigmoid 之選擇為單一元件影響最大者。** 將跨槽 Softmax 換為元素級 sigmoid 之 –7.0% NDCG@20 降幅為表中最大個別消融，且相對於一般超參數調參之 1–3% 擺動為大。此即我們於第 5 章發展之方法論觀察的實證基礎：於本合理化模組中，注意力歸一化之選擇非調參細節，而為與合理化語意假設 ( $A$  個槽位互相競爭，而非各自獨立相關) 綁定之設計選擇。

**修復前配置回復至損壞 baseline 情境。** 同時還原兩處修復 (sigmoid 合理化與  $b=0$ ) 使 RA-GARK 崩壞至  $\text{NDCG@20} = 0.1067$ ，此值低於所有四個 KG-aware baseline。合併降幅 (–13.8%) 大於兩項個別降幅之加總 (–7.0% + –5.3% = –12.3%)；兩項損壞預設互相強化，當  $b=0$  使 KG 通道未受抑制時，sigmoid 頭恰好失去壓抑無關槽位之能力，雜訊被同時放大。此顯示 RA-GARK 之架構骨架 (兩平行視角 + 後期融合) 本身不

足；缺核心設計選擇下，此骨架復現 baseline 之失敗模式，正如第 3.1 節之設計原則所預期。

對比損失之貢獻較小但非零碎：使用者側 CL 為  $-4.1\%$ 、面向級 CL 為  $-2.5\%$ 。我們解讀此量級與第 3.9.1 節賦予對比正則化之輔助角色一致：其推動幾何，但不承擔整合負荷。

## 4.5 敏感性分析

我們沿讀者最可能質疑之四個超參數軸探究 RA-GARK 之敏感性：Softmax 溫度  $\tau$ 、潛在面向槽數  $A$ 、融合閘偏置  $b$ 、對比權重  $\lambda_{CL}$ 。各軸於其他設定固定為表 8 之值、種子 = 42 下掃描。

### 4.5.1 Softmax 溫度 $\tau$

表 11 報告  $\tau \in \{0.05, 0.1, 0.5, 1.0\}$  之 NDCG@20。預設  $\tau = 0.5$  取得最佳 NDCG@20 (0.1238)， $\tau = 1.0$  僅落後  $-0.5\%$  (0.1232)，兩個較銳之設定 ( $\tau = 0.1$  與  $\tau = 0.05$ ) 則落在約 0.1222–0.1223 之共同平台上 ( $-1.3\%$ )。此圖像與第 3.7.3 節之分析一致： $\tau = 1.0$  時 Softmax 接近均勻，因 MLP logit 動態範圍小，合理化模組被推向跨槽之物品級平均； $\tau = 0.5$  時差異被放大至足以產生鑑別性權重而不塌縮於單一槽； $\tau \leq 0.1$  時進一步銳化不再有助益（合理化已近似 one-hot）但亦未明顯惡化，故曲線趨於平坦而非繼續下滑。

Table 11: 對 Softmax 溫度  $\tau$  之敏感性。

| $\tau$          | NDCG@20       |
|-----------------|---------------|
| 1.0             | 0.1232        |
| <b>0.5 (預設)</b> | <b>0.1238</b> |
| 0.1             | 0.1222        |
| 0.05            | 0.1223        |

### 4.5.2 面向槽數 $A$

我們掃描  $A \in \{2, 4, 8\}$ ，並對應縮放 SVD 秩  $k = A \cdot d$ 。NDCG@20 自  $A = 4$  起基本平坦： $A = 2$  略差， $A = 8$  與  $A = 4$  於雜訊範圍內。我們採  $A = 4$  為平台內之小值，使合理化遮罩成本  $O(B \cdot A \cdot d)$  相對 LightGCN 傳播仍可忽略。此曲線之平坦顯示合理化模組於本資料集上不為槽數所瓶頸；更多槽位所增加之容量無法被最佳化器在每物品 2.4 條面向邊之條件下有效利用。

### 4.5.3 融合閘偏置 $b$

偏置掃描為四者中最具資訊量者。表 12 顯示  $b$  於  $\{0, +2, +5, +10\}$  之 NDCG@20。預設  $b = +5$  最佳。於  $b = 0$ （無區域偏置）下模型損失 5.3% NDCG@20，與消融表所報一致。於  $b = +10$  下  $\sigma'(b)$  已數值上小至閘無法於訓練中適應，NDCG@20 降回  $b = 0$  情境之 0.001 內。此設計可運作之窗  $b \in (0, +10]$  為窄；以  $b = +5$  作為  $\alpha^{(0)} > 0.99$  且  $\sigma'(b) > 10^{-3}$  之最小整數（第 3.8.5 節）的選擇於此獲得實證驗證。

Table 12: 對融合閘偏置  $b$  之敏感性。

| $b$    | NDCG@20       |
|--------|---------------|
| 0      | 0.1173        |
| +2     | 0.1206        |
| +5（預設） | <b>0.1238</b> |
| +10    | 0.1175        |

### 4.5.4 對比權重 $\lambda_{CL}$

我們掃描  $\lambda_{CL} \in \{0, 0.001, 0.005, 0.01, 0.05\}$ 。最佳 NDCG@20 出現於  $\lambda_{CL} = 0.005$  附近；於  $\lambda_{CL} = 0$  下模型損失約 2–3% NDCG@20，與消融表中兩條對比通道合併效果一致；於  $\lambda_{CL} = 0.05$  下對比梯度開始主導 BPR，NDCG@20 惡化。我們不逐資料集調  $\lambda_{CL}$ ；該值於所有實驗中固定為 0.005，以將對比正則化維持於設計所賦予之輔助角色（第 3.9.1 節）。

## 4.6 結果穩定性

我們報告主結果對非本質之最佳化細節之穩健性。於架構與資料集切分固定、僅變動最佳化細節（weight decay 開關、scheduler 開關、multi-negative sampling、額外之  $\mathcal{L}_{kgCL}$  正則化）之探索性實驗，皆於所報 0.1238 之  $\pm 0.003$  NDCG@20 內。本資料集之有效效能上限因此約為 0.124，且表 9 之方法質性排序與表 10 之消融效應排序於此誤差帶內均穩健。

資料集規模較小（905 使用者、1,399 物品），測試集變異之主要來源為使用者分層切分本身而非最佳化隨機性。固定切分後即移除較大之變異來源，其後切分內殘餘變異約與我們所報較小消融效應之量級相當，並不影響第 4.3 與第 4.4 節所得之比較性結論。

## 4.7 個案研究

為檢視合理化模組實際學到什麼，我們自訓練集中取樣 5 件熱門物品（每件至少 3 條 KG 面向邊），並列出訓練完成之模型對其中三位互動使用者所產生之 Softmax 面向權重  $w_{u,i,k}$ 。結果摘要於表 13。

Table 13: 訓練完成之合理化模組於 5 件取樣物品上之 Softmax 面向權重  $w_{u,i,k}$ 。粗體標示 argmax 槽。同一物品之不同使用者權重幾乎相同；不同物品之 argmax 槽則互異。

| 物品 (asin)  | 主要 KG 面向                                                               | 使用者 | $w_0$        | $w_1$        | $w_2$ | $w_3$        |
|------------|------------------------------------------------------------------------|-----|--------------|--------------|-------|--------------|
| 1594633665 | character_complexity,<br>unreliable_narrators,<br>psychological_themes | 458 | 0.230        | <b>0.282</b> | 0.231 | 0.257        |
|            |                                                                        | 112 | 0.227        | <b>0.284</b> | 0.231 | 0.257        |
|            |                                                                        | 1   | 0.229        | <b>0.284</b> | 0.231 | 0.256        |
| 0553418025 | science_fiction_genre,<br>survival_stories,<br>space_exploration       | 416 | <b>0.285</b> | 0.239        | 0.241 | 0.235        |
|            |                                                                        | 580 | <b>0.284</b> | 0.240        | 0.241 | 0.235        |
|            |                                                                        | 859 | <b>0.287</b> | 0.240        | 0.241 | 0.233        |
| 0312641893 | cyberpunk_genre,<br>cyborg_elements,<br>future_setting                 | 89  | 0.250        | <b>0.267</b> | 0.250 | 0.232        |
|            |                                                                        | 256 | 0.251        | <b>0.265</b> | 0.251 | 0.232        |
|            |                                                                        | 828 | 0.250        | <b>0.268</b> | 0.250 | 0.232        |
| 0062024027 | dystopian_worlds,<br>post_apocalyptic_settings,<br>action_and_suspense | 249 | <b>0.284</b> | 0.238        | 0.239 | 0.238        |
|            |                                                                        | 153 | <b>0.283</b> | 0.239        | 0.240 | 0.238        |
|            |                                                                        | 728 | <b>0.284</b> | 0.237        | 0.240 | 0.239        |
| 0307887448 | dystopian_sci_fi,<br>video_games, 80s_culture                          | 467 | 0.238        | 0.246        | 0.240 | <b>0.276</b> |
|            |                                                                        | 51  | 0.239        | 0.245        | 0.241 | <b>0.275</b> |
|            |                                                                        | 740 | 0.238        | 0.248        | 0.242 | <b>0.272</b> |

由表 13 可得兩項明確之經驗模式，二者皆與一般對合理化模組所期之強 per-(使用者, 物品) 選擇敘事不符。

**物品層級之槽位專化存在。** 五件取樣物品之 argmax 槽各異（槽 1、槽 0、槽 1、槽 0、槽 3），主導槽承載一個小但穩定之質量超額（通常 0.27–0.29 對其餘約 0.24）。合理化模組因此學得了物品條件之四槽偏好：不同物品將其 KG 貢獻路由至不同槽向，且該選擇於所有與該物品互動之使用者間穩定。

**使用者條件之選擇性實質不存在。** 對任一物品，三位取樣使用者所產生之權重向量幾乎相同，物品內跨使用者之差異至多  $\pm 0.003$ 。式 (3.17) 之使用者條件化結構上存在，但於訓練完成之模型中，使用者輸入對槽分布之擾動不超過量測雜訊。權重雖明顯高於主導槽上之均勻值，但並非使用者特定。

**詮釋：刻意被節制之通道不會發展出細粒度行為。** 此模式與第 3.1 節之設計原則一致而非衝突。融合閘以偏置初始化，使 KG 通道於訓練起點開啟約 0.7%，整個訓練過程中亦僅佔分數之一小部分；表 10 之消融顯示移除整個全域視角僅損失 1.9% NDCG@20，移除合理化僅損失 1.3%。回傳至合理化模組之梯度因而相應為小，足以決定每件物品該用哪個槽（一個大小為  $|I| \times A$  之物品層級選擇問題）但不足以在其之上再學得使用者特定之再加權，因後者需於緊縮 KG 貢獻下區分  $|\mathcal{U}| \times |I| \times A$  個槽權重。個案研究因此不應讀為合理化模組之失敗，而是優雅退化性質之直接證據：KG 通道僅學得開允許其影響損失之結構量。

對純 LightGCN 之 5.0% 提升（表 9）因此可歸因於在 KG-SVD 初始化幾何之上之物品層級槽路由，而非 per-user 合理化指派。我們明確區別此點，俾後續於較稠密 KG 上使用合理化模組之工作（其中較寬閘原則上能允許使用者層級分化湧現）知曉應觀察何種訊號。

## 4.8 計算成本

於本文硬體上，RA-GARK 每 epoch 訓練牆鐘時間約 1.5 秒，與純 LightGCN (1.4 s) 及匹配嵌入維度之 KGRec (1.5 s) 幾乎不可區分。三者主導成本皆為 LightGCN 傳播  $O(|\mathcal{E}_{\mathcal{UI}}| \cdot d \cdot K)$ ，RA-GARK 與 baseline 共享此項。KG 側額外項（面向槽讀取  $O(B \cdot A \cdot d)$ 、合理化遮罩  $O(B \cdot A \cdot d)$ 、兩個融合閘  $O(B \cdot d^2)$ ）於  $A = 4$ 、 $B = 128$  下相對傳播甚小，已於第 3.10.4 節之複雜度表分析。

全項目推論主導於 per-user 之物品側合理化步驟，成本為  $O(|I| \cdot A \cdot d)$ ；於本資料集 ( $|I| = 1,399$ 、 $A = 4$ 、 $d = 128$ ) 此值遠在 GPU 記憶體預算內，對所有測試使用者計分每 epoch 不到一秒。RA-GARK 因此並非比所改進之 baseline 更昂貴；表 9 之增益來自設計選擇，而非更大之計算預算。

# Chapter 5

## 結論與未來工作

### 5.1 結論

本論文始於一個具體之經驗異常：於本文所用之稀疏評論衍生知識圖譜上，四個代表性 KG-aware 推薦器（KGAT、KGCL、MCCLK、KGRec）均一致地敗給純 LightGCN（第 1 章，並於第 4.3 節重現）。我們所主張之共通架構成因為：這些 baseline 將 KG 配置為計分管線中之強制元件，KG 嵌入參與訊息傳遞，且模型結構上不存在可在 KG 不可靠時將其脫接之開關。原本期望以語意訊號姿態被收割之噪音，因此進入產生協同表示之同一梯度流；當 KG 品質低於某門檻時，此交易即轉為淨負。

我們的回應 RA-GARK（第 3 章）圍繞單一設計原則組織（第 3.1 節）：KG 應作為一條旁路通道，其對最終分數之貢獻由一可學習閘決定，此閘於初始化即偏向安全預設（純協同過濾），僅在訓練訊號指示 KG 通道能降低損失時才被打開。三項具體設計選擇落實此原則，並於第 4.4 節逐一衡量：

- **KG-SVD 初始化**逐物品面向槽，於訓練起點即保留面向誘導語意子空間之角度幾何。移除其代價為 5.3% NDCG@20。
- **Softmax 合理化遮罩**對  $A$  個潛在槽進行歸一化，編碼「使用者對某物品之偏好由少數互相競爭之語意面向所主導」之假設。將跨槽 Softmax 換為元素級 sigmoid 之代價為 7.0% NDCG@20，是本論文中單一元件影響最大者。
- **區域偏置融合閘**，其純量偏置  $b = +5$  之初始化使  $\alpha^{(0)} \approx 0.993$ ，RA-GARK 訓練起點本質上即為純 LightGCN。還原為  $b = 0$  之代價為 5.3% NDCG@20。

三項齊備下，RA-GARK 於本基準上取得  $\text{NDCG@20} = 0.1238$ ，較最強 KG-aware baseline（KGRec）提升 +13.1%，較純 LightGCN 提升 +5.0%，且每 epoch 牆鐘成本基

本相當（第 4.8 節）。其中 +5.0% 在方法論上更具意義：於同一筆資料上，四個既發表之 KG-aware 方法將 KG 訊號變為淨負債，RA-GARK 之設計選擇則將其翻回淨資產。

因此本論文之一句話總結為：當 KG 不可靠時，架構最需要的不是更好的 KG 聚合器，而是一個能將 KG 結構性脫接之開關。

本論文之價值，與其說在於具體數字，不如說在於此一重新定位：它將稀疏 KG 推薦的困難歸因於架構而非 KG 本身，在強制融合下成為負擔的同一個 KG，一旦其使用被設計為結構上可選，便能在不更動 KG 的前提下轉為助益。循此觀點，優雅退化（將輔助通道於初始化偏向安全預設、僅在訓練訊號足以支持時才開啟）是一種可重用的設計原則，用以整合任何事先無法保證可靠性之訊號，而非僅適用於評論衍生知識圖譜之特定手段。此原則能否推廣至本文所研究之單一稀疏基準以外，則為第 5.4 節所探討之經驗問題。

## 5.2 方法論啟示：注意力歸一化

本論文觀察到之單一元件最大影響並不在 RA-GARK 所貢獻之任何新架構元件，而在於推薦文獻中常被視為調參細節之選擇：合理化模組之注意力頭採用 Softmax（跨面向競爭）或 sigmoid（逐面向獨立）。於本基準上，僅將此單一模組之 Softmax 替換為 sigmoid 即損失 7.0% NDCG@20（第 4.4 節），相對於一般超參數調參之 1-3% 擺動為大。

推薦文獻對此選擇無共識。DIN [16] 對歷史物品採用 per-target sigmoid 注意力；NAIS [17]、AFM [18] 對特徵互動採用 Softmax 歸一化；KGRec [7] 採邊層級 Bernoulli 決策，結構上接近 sigmoid。此等選擇皆與其目標任務之語意內部一致。我們於第 4.7 節之個案研究檢視顯示，本設定下訓練完成之 Softmax 權重並非近 one-hot，而僅為軟尖峰（四槽中  $\max_k w_k \approx 0.28$ ），因此實際發揮作用之機制不可能為 one-hot 之競爭選擇。Softmax 提供而 sigmoid 不具之性質實為結構性者：權重和為 1 之歸一化使全域視角物品嵌入之模長無論 logit 尺度為何皆有界於  $\max_k \|\mathbf{a}_{i,k}\|$ ，而 sigmoid 所產生之模長則隨 logit 漂移。於 KG 通道刻意被融合閘節制（第 3.8.3 節）之設計中，將通道貢獻維持有界且可預測，正為閘之校準所依賴；sigmoid 引入之模長漂移即為我們所相信導致 7.0% 退化之原因。

我們將此定位為假說而非方法論主張。證據僅來自單一資料集，於其他資料集、其他被節制方式不同之架構上其效應大小與機制皆未知。此假說具體至足以由複製驗證證偽：當合理化式之注意力頭饋入一輔助通道，且其貢獻由融合閘約束為分數中一小

比例時，承載性之性質為該頭之模長控制（和為一之歸一化），而非 *one-hot* 競爭；以獨立 *sigmoid* 頭替換 *Softmax* 頭將以遠超一般超參數雜訊之幅度降低排序品質。若此於我們的設定之外仍成立，歸一化對競爭即成為合理化結構之顯式設計軸，而非調參細節。

## 5.3 限制

本論文之貢獻受三項限制所界定，我們明確陳述以避免主張範圍模糊。

**單一稀疏基準。** 本論文所有量化結果皆於單一資料集上報告：Amazon Books 評論之一子集，含 905 位使用者、1,399 件物品，以及 2,098 個面向標籤上之 3,370 條物品一面向 KG 邊（第 4.1 節）。選擇此基準是因其展現本論文所動機之經驗異常，但並未主張 RA-GARK 之設計選擇可不變地轉移至其他推薦資料集或其他 KG 架構。特別是，核心觀察（純 LightGCN 勝過所測四個 KG-aware baseline）於 KG 較稠密、較經策劃、或與推薦訊號較對齊之資料集上未必成立。

**KG 建構為前作。** 物品一面向 KG 本身由 [20] 之流程建構，結合視覺與文字編碼器（ResNet、Qwen-VL、BART、Mistral）以抽取評論衍生面向出現。我們直接採用此 KG，不對建構流程提出修改。本論文之貢獻完全位於建模面，視 KG 為固定輸入。

**未驗證稠密 KG 情境。** RA-GARK 為稀疏 KG 情境而設計並評估，此情境下 KG 訊號不可靠。我們不對其於 KG 稠密且準確時之行為作任何主張。在該情境（KGAT、KGIN 之傳統主場）「預設 KG 關閉」之偏置初始化開正是錯誤之歸納先驗，而我們所批評之深度融合 baseline 反而可能為合適選擇。第 5.4 節討論開應如何重新配置以處理對稱情境。

## 5.4 未來工作

由以上貢獻與限制，自然引出四個方向。

**注意力歸一化發現之多資料集複製。** 第 5.2 節所表述之方法論假說具體至足以於其他合理化感知推薦基準、其他物品屬性架構、以及相鄰領域之合理化模組（順序推薦、對話式推薦）上測試。一次乾淨複製（固定資料集與模型其餘部分、僅切換合理化頭之歸一化）將使其自單一資料集觀察提升為一般設計指引，或銳化其成立之條件。

**稠密 KG 驗證。** 如限制所提，RA-GARK 尚未於 KG 稠密且策劃良好之資料集上評估。自然之後續為將 RA-GARK 與 KG-aware baseline 並列執行於標準稠密 KG 基準（如 Amazon-Book / Last-FM 配 Freebase 衍生 KG）。預期結果為區域偏置融合閘優雅退化為與純 LightGCN 加小幅 KG 貢獻相當之行為而不崩壞；至於 RA-GARK 是否於該情境匹敵深度融合 baseline，為一個值得回答之經驗問題。

**閘控原則之跨領域轉移。** 區域偏置融合閘背後之架構原則（於初始化偏向安全預設、僅在訓練訊號指示輔助通道能降低損失時打開）並不專屬於 KG-aware 推薦。同樣構造原則上可轉移至任何主訊號穩健、輔助訊號高變異之情境：含側資訊之冷啟動、單一模態雜訊時之多模態融合、異質預測器之集成式後期融合。我們所觀察之核心效應是否能在等轉移下倖存，為開放問題。

**反向稀疏情境：CF 稀疏配 KG 稠密。** 本論文所研究情境之對稱反面，為使用者—物品互動圖稀疏（如冷啟動、新使用者、新領域）而 KG 稠密可靠之情況。彼時閘所應編碼之安全預設與本文所用者相反：LightGCN 此時為不可靠之一側，KG 衍生之全域視角應為預設打開之通道。此為 KGAT、KGIN 等稠密 KG 工作之傳統設定；本文分析暗示於初始化偏向安全預設此項設計動作可跨兩情境轉移，而偏置之具體方向則由資料集決定。

具體而言，將 RA-GARK 改造至此情境需三項協同變更：融合偏置應自 +5 翻轉為負值，使 KG 通道預設打開；KG-SVD 之角色可能由初始化轉為主要推論路徑；區域視角則可能需要不同之正則化，方能於互動訊號稀少時維持有用。對反向情境之完整架構處理需同時重新設計區域視角與閘方向性，留待後續研究。

# Bibliography

- [1] X. He, K. Deng, X. Wang, Y. Li, Y. Zhang, and M. Wang, “LightGCN: Simplifying and powering graph convolution network for recommendation,” in *Proc. ACM SIGIR*, 2020, pp. 639–648.
- [2] X. Wang, X. He, M. Wang, F. Feng, and T.-S. Chua, “Neural graph collaborative filtering,” in *Proc. ACM SIGIR*, 2019, pp. 165–174.
- [3] J. Wu, X. Wang, F. Feng, X. He, L. Chen, J. Lian, and X. Xie, “Self-supervised graph learning for recommendation,” in *Proc. ACM SIGIR*, 2021, pp. 726–735.
- [4] X. Wang, X. He, Y. Cao, M. Liu, and T.-S. Chua, “KGAT: Knowledge graph attention network for recommendation,” in *Proc. ACM SIGKDD*, 2019, pp. 950–958.
- [5] Y. Yang, C. Huang, L. Xia, and C. Li, “Knowledge graph contrastive learning for recommendation,” in *Proc. ACM SIGIR*, 2022, pp. 1434–1443.
- [6] D. Zou, W. Wei, X.-L. Mao, Z. Wang, M. Qiu, F. Zhu, and X. Cao, “Multi-level cross-view contrastive learning for knowledge-aware recommender system,” in *Proc. ACM SIGIR*, 2022, pp. 1358–1368.
- [7] Y. Yang, C. Huang, L. Xia, and C. Huang, “Knowledge graph self-supervised rationalization for recommendation,” in *Proc. ACM SIGKDD*, 2023, pp. 3046–3056.
- [8] X. Ren, L. Xia, J. Zhao, D. Yin, and C. Huang, “Disentangled contrastive collaborative filtering,” in *Proc. ACM SIGIR*, 2023, pp. 1137–1146.
- [9] A. van den Oord, Y. Li, and O. Vinyals, “Representation learning with contrastive predictive coding,” *arXiv preprint arXiv:1807.03748*, 2018.
- [10] R. K. Srivastava, K. Greff, and J. Schmidhuber, “Highway networks,” *arXiv preprint arXiv:1505.00387*, 2015.

- [11] J. Ma, Z. Zhao, X. Yi, J. Chen, L. Hong, and E. H. Chi, “Modeling task relationships in multi-task learning with multi-gate mixture-of-experts,” in *Proc. ACM SIGKDD*, 2018, pp. 1930–1939.
- [12] H. Tang, J. Liu, M. Zhao, and X. Gong, “Progressive layered extraction (PLE): A novel multi-task learning model for personalized recommendations,” in *Proc. ACM RecSys*, 2020, pp. 269–278.
- [13] Z. Wang, G. Lin, H. Tan, Q. Chen, and X. Liu, “CKAN: Collaborative knowledge-aware attentive network for recommender systems,” in *Proc. ACM SIGIR*, 2020, pp. 219–228.
- [14] H. Wang, F. Zhang, M. Zhao, W. Li, X. Xie, and M. Guo, “Multi-task feature learning for knowledge graph enhanced recommendation,” in *Proc. The Web Conference (WWW)*, 2019, pp. 2000–2010.
- [15] X. Wang, T. Huang, D. Wang, Y. Yuan, Z. Liu, X. He, and T.-S. Chua, “Learning intents behind interactions with knowledge graph for recommendation,” in *Proc. The Web Conference (WWW)*, 2021, pp. 878–887.
- [16] G. Zhou, X. Zhu, C. Song, Y. Fan, H. Zhu, X. Ma, Y. Yan, J. Jin, H. Li, and K. Gai, “Deep interest network for click-through rate prediction,” in *Proc. ACM SIGKDD*, 2018, pp. 1059–1068.
- [17] X. He, Z. He, J. Song, Z. Liu, Y.-G. Jiang, and T.-S. Chua, “NAIS: Neural attentive item similarity model for recommendation,” *IEEE Transactions on Knowledge and Data Engineering*, vol. 30, no. 12, pp. 2354–2366, 2018.
- [18] J. Xiao, H. Ye, X. He, H. Zhang, F. Wu, and T.-S. Chua, “Attentional factorization machines: Learning the weight of feature interactions via attention networks,” in *Proc. International Joint Conference on Artificial Intelligence (IJCAI)*, 2017, pp. 3119–3125.
- [19] S. Rendle, C. Freudenthaler, Z. Gantner, and L. Schmidt-Thieme, “BPR: Bayesian personalized ranking from implicit feedback,” in *Proc. Conference on Uncertainty in Artificial Intelligence (UAI)*, 2009, pp. 452–461.
- [20] I.-N. Ho, “Llm-enhanced multimodal product recommendation with review aspect-specific knowledge graphs,” Master’s thesis, Institute of Information Management, National Yang Ming Chiao Tung University, 2024.